Proyecto Final de Carrera - 16.30

Desarrollo de aplicación para apoyo diagnóstico basada en redes neuronales para la clasificación automática de etiologías de HVI en imágenes de ECG

Autoras

Catalina Jonquieres (63369)

Victoria Orsi (62526)

Tutora

Victoria Reppucci

Asesor

Juan Pablo Costabel

Institución

Instituto Cardiovascular de Buenos Aires

2026

Resumen del Proyecto

El presente proyecto propone el desarrollo de una herramienta basada en redes neuronales para la clasificación automática de cuatro patologías cardíacas: amiloidosis cardíaca, hipertensión arterial, estenosis aórtica y miocardiopatía hipertrófica, utilizando imágenes de electrocardiograma (ECG) de 12 derivaciones.

La motivación surge de la complejidad diagnóstica asociada a estas enfermedades. Las cuatro patologías producen hipertrofia ventricular izquierda (HVI), por lo que suelen generar patrones eléctricos similares entre sí y, por lo tanto, requieren de estudios complementarios para lograr un diagnóstico diferencial preciso. Esto puede prolongar el proceso diagnóstico y retrasar el inicio del tratamiento adecuado del paciente. En este contexto, el proyecto busca potenciar el ECG incorporando algoritmos de *deep learning* capaces de identificar patrones sutiles que resultan difíciles de distinguir a simple vista, ayudando así a su interpretación y brindando apoyo al médico en la toma de decisiones clínicas.

El proyecto contempla el desarrollo, entrenamiento y evaluación de redes neuronales a partir de un dataset provisto por el Instituto Cardiovascular de Buenos Aires (ICBA). Debido al tamaño reducido de este conjunto de datos, se desarrolló además un dataset adicional de imágenes sintéticas a partir de señales provenientes de datasets públicos, reproduciendo el formato de representación utilizado por los estudios del ICBA. Este dataset fue utilizado para preentrenar los modelos, con el objetivo de que adquirieran representaciones generales de las señales electrocardiográficas antes del ajuste fino sobre el dataset objetivo.

Se evaluaron cinco arquitecturas diferentes: dos redes convolucionales de diseño propio y tres modelos preentrenados en ImageNet (ResNet50, EfficientNetB0 y ConvNeXtTiny). El modelo final de diseño propio alcanzó una *balanced accuracy* (BA) de 0,6673 sobre el conjunto de prueba, mientras que el basado en ConvNeXtTiny alcanzó una BA de 0,7309. El ensamble de ambos modelos obtuvo una BA de 0,7809.

Adicionalmente, el trabajo incluye el diseño y desarrollo de una aplicación de escritorio, denominada VentrIA, que integra estos modelos de clasificación junto con herramientas de interpretabilidad basadas en mapas de calor, con el objetivo de facilitar su utilización como herramienta de apoyo diagnóstico en contextos clínicos.

Glosario

AL	Amiloidosis por cadenas ligeras de inmunoglobulina
Am	Amiloidosis cardíaca
AR	Relación de aspecto (*Aspect Ratio*)
ATTR	Amiloidosis por transtiretina
AUROC	Área bajo la curva característica operativa del receptor (*Area Under the Receiver Operating Characteristic Curve*)
AV	Auriculoventricular
BA	Exactitud balanceada (*Balanced Accuracy*)
BN	Normalización por lotes (*Batch Normalization*)
CD	Trastornos de conducción (*Conduction Disturbance*)
CNN	Red neuronal convolucional (*Convolutional Neural Network*)
CV	Validación cruzada (*Cross-Validation*)
DPI	Puntos por pulgada (*Dots Per Inch*)
EAo	Estenosis aórtica
ECG	Electrocardiograma
FT	Ajuste fino (*Fine-Tuning*)
GAP	Agrupamiento promedio global (*Global Average Pooling*)
GELU	Unidad lineal de error gaussiano (*Gaussian Error Linear Unit*)
Grad-CAM	Mapeo de activación de clase ponderado por gradiente (*Gradient-weighted Class Activation Mapping*)
HTA	Hipertensión arterial
HVI	Hipertrofia ventricular izquierda
HYP	Hipertrofia (*Hypertrophy*)
ICBA	Instituto Cardiovascular de Buenos Aires
LP	Sondeo lineal (*Linear Probing*)
MCH	Miocardiopatía hipertrófica
MI	Infarto de miocardio (*Myocardial Infarction*)
NORM	ECG normal (*Normal ECG*)
PTB-XL	Base de datos pública de ECG de 12 derivaciones del *Physikalisch-Technische Bundesanstalt*
ReLU	Unidad lineal rectificada (*Rectified Linear Unit*)
RMC	Resonancia magnética cardíaca
SA	Sinoauricular
STTC	Alteraciones de la repolarización (*ST/T Change*)
TPE	Estimador de Parzen estructurado en árbol (*Tree-structured Parzen Estimator*)
UX	Experiencia de usuario (*User Experience*)

Índice

1. Introducción **1**
1.1. Contexto clínico y motivación 1
1.2. Objetivos 2
1.2.1. Objetivo general 2
1.2.2. Objetivos específicos 2
a. Objetivos de mínima 2
b. Objetivos de máxima 2

2. Marco Teórico **3**
2.1. Fundamentos del electrocardiograma 3
2.1.1. Fisiología eléctrica del corazón 3
2.1.2. Registro y obtención de la señal 3
2.1.3. Ondas y segmentos característicos 5
2.1.4. Limitaciones diagnósticas del ECG 6
2.2. Hipertrofia ventricular izquierda 6
2.2.1. Definición e importancia clínica 6
2.2.2. Etiologías 7
a. Hipertensión arterial 7
b. Estenosis aórtica 7
c. Miocardiopatía hipertrófica 8
d. Amiloidosis cardíaca 8
2.2.3. Diagnóstico electrocardiográfico 9
2.2.4. Diagnóstico ecocardiográfico 11
2.2.5. Estudios complementarios 12
2.3. Deep learning en diagnóstico médico 13
2.3.1. Redes neuronales convolucionales 13
2.3.2. Aprendizaje por transferencia 14
2.3.3. Métricas de evaluación de modelos 16
2.3.4. Interpretabilidad de modelos 17

3. Estado del arte **18**
3.1. Modelos basados en señales 18
3.2. Modelos basados en imágenes 19

4. Materiales y métodos **20**
4.1. Dataset ICBA 20
4.1.1. Unificación del formato de archivo 21
4.1.2. Recorte automático de márgenes 22
4.1.3. Redimensionamiento 23
4.2. Construcción de Dataset Sintético 24
4.2.1. Fuentes de señales 25
4.2.2. Remapeo de etiquetas 25
4.2.3. Generación de imágenes 27
4.2.4. Partición y composición final del dataset 28
4.3. Selección de arquitecturas de red 29
4.3.1. Modelos entrenados desde cero 29
a. Red convolucional plana 29
b. Red convolucional residual 30

4.3.2. Modelos preentrenados 30
a. ResNet50 31
b. EfficientNetB0 31
c. ConvNeXtTiny 31
4.4. Entrenamiento de modelos 31
4.4.1. Entorno de desarrollo 31
4.4.2. Configuración general del entrenamiento 32
a. Búsqueda de hiperparámetros 32
b. Reproducibilidad 32
c. Mecanismos de control del entrenamiento 32
4.4.3. Preentrenamiento en imágenes sintéticas 33
4.4.4. Ajuste fino sobre el dataset ICBA 34
4.4.5. Experimento de ablación 36
4.4.6. Criterio de selección de modelos 37
4.5. Interpretabilidad mediante Grad-CAM 37
4.6. Interfaz gráfica 39
4.6.1. Uso previsto 39
4.6.2. Diseño y funcionamiento 39
4.6.3. Evaluación de experiencia de usuario 40

5. Resultados 41
5.1. Evaluación de los modelos base sobre el dataset sintético 41
5.2. Evaluación de los modelos finales sobre el dataset ICBA 43
5.3. Ensamble de modelos 45
5.4. Impacto del preentrenamiento con imágenes sintéticas 47
5.5. Mapas de calor obtenidos mediante Grad-CAM 49
5.6. Evaluación de la interfaz por profesionales médicos 51

6. Discusión 52
6.1. Análisis de resultados 52
6.1.1. Comparación entre arquitecturas de los modelos base 52
6.1.2. Transferencia de los modelos base al problema clínico 53
6.1.3. Contribución del preentrenamiento con imágenes sintéticas 54
6.1.4. Mejora obtenida a partir del ensamble 55
6.1.5. Análisis de errores 56
6.1.6. Interpretación clínica de las regiones de activación Grad-CAM 57
6.1.7. Usabilidad y utilidad clínica de la interfaz 58
6.2. Limitaciones y alcance de los modelos 58
6.2.1. Limitaciones asociadas a los datos 58
6.2.2. Limitaciones del diseño experimental 59
6.2.3. Alcance de la herramienta 60
6.3. Justificación del enfoque basado en imágenes 60
6.4. Comparación con trabajos previos de la literatura 61
6.5. Posibles mejoras y perspectivas futuras 61

7. Conclusiones 63

8. Bibliografía 64

Anexo

A. Esquema de etiquetado del dataset sintético 71
B. Material complementario de VentrIA 74
B.1 Informe de resultados 74
B.2 Cuestionario de evaluación 75
B.3 Respuestas del cuestionario 77
C. Estudios de Optuna 78
C.1 Preentrenamiento en imágenes sintéticas 78
C.2 Ajuste fino sobre el dataset ICBA 81
C.3 Experimento de ablación 82
D. Resultados adicionales del preentrenamiento en imágenes sintéticas 84
D.1 Curvas de entrenamiento 84
D.2 Métricas de desempeño 89
D.3 Matrices de confusión 90
E. Detalle de las predicciones de los modelos finales 92
F. Mapas de activación Grad-CAM 98

1 Introducción

1.1 Contexto clínico y motivación

Las enfermedades cardiovasculares representan la principal causa de mortalidad a nivel mundial. Según la Organización Mundial de la Salud, aproximadamente 19,8 millones de personas fallecieron por esta causa en 2022, lo que equivale a cerca de un tercio de todas las defunciones globales [1]. Una proporción significativa de estas muertes podría evitarse o retrasarse con un diagnóstico oportuno que permita iniciar tratamientos dirigidos antes de que la enfermedad progrese de forma irreversible.

En este contexto, el electrocardiograma (ECG) ocupa un lugar central en la práctica clínica. Su bajo costo, rapidez de obtención, amplia disponibilidad y carácter no invasivo lo convierten en el estudio de primera línea en prácticamente cualquier consulta cardiológica. El trazado electrocardiográfico puede revelar alteraciones del ritmo, trastornos de la conducción y cambios morfológicos asociados a diversas patologías estructurales del corazón. Sin embargo, aunque el ECG es una herramienta de gran utilidad para la detección inicial y la estratificación clínica, su capacidad para establecer un diagnóstico diferencial preciso en presencia de alteraciones estructurales complejas es limitada [2][3].

Una situación clínica que ejemplifica esta limitación es la evaluación de pacientes con hipertrofia ventricular izquierda (HVI). Su prevalencia mundial se estima entre el 10 % y el 20 % de la población adulta y constituye un importante marcador independiente de eventos cardiovasculares adversos, incluyendo arritmias, insuficiencia cardíaca y muerte súbita [4]. La HVI representa un fenotipo común que puede ser consecuencia de distintas enfermedades cardiovasculares, entre ellas la hipertensión arterial (HTA), la estenosis aórtica (EAo), la miocardiopatía hipertrófica (MCH) y la amiloidosis cardíaca (Am). Aunque estas cuatro condiciones producen un engrosamiento ventricular de apariencia similar, sus mecanismos fisiopatológicos, pronósticos y tratamientos difieren de manera sustancial, por lo que su correcta identificación tiene implicancias terapéuticas directas.

La similitud clínica y electrocardiográfica entre estas patologías representa un importante desafío diagnóstico. El ECG, e incluso el ecocardiograma, con frecuencia no son suficientes para determinar con certeza la etiología subyacente, por lo que suele ser necesario recurrir a estudios complementarios de mayor complejidad, como la resonancia magnética cardíaca, la evaluación genética o estudios de medicina nuclear [5][6]. Estos estudios son más costosos, requieren equipamiento especializado y pueden no estar disponibles en todos los centros asistenciales, especialmente en contextos con recursos limitados. Como consecuencia, estas enfermedades pueden ser erróneamente diagnosticadas o permanecer sin reconocimiento durante un tiempo prolongado [7][8]. La identificación temprana de la etiología resulta, por lo tanto, fundamental para orientar el tratamiento adecuado y mejorar el pronóstico de los pacientes.

En los últimos años, el aprendizaje profundo ha emergido como una herramienta prometedora para ampliar el valor diagnóstico del ECG. Diversos estudios han demostrado que las redes neuronales profundas son capaces de identificar patrones electrocardiográficos sutiles que resultan imperceptibles para la interpretación convencional, permitiendo detectar enfermedades con un rendimiento superior al de los métodos tradicionales [9][10]. Sin embargo, la gran mayoría de estos desarrollos opera sobre señales digitales, una modalidad no siempre disponible en la práctica clínica. En la mayoría de los casos, los ECG se almacenan y transmiten principalmente en formato de imagen, ya sea como documentos PDF o impresiones físicas, lo que limita considerablemente la aplicabilidad de los modelos existentes basados exclusivamente en la señal digital.

En este contexto, el presente trabajo propone el desarrollo de un clasificador multiclase basado en redes neuronales convolucionales capaz de distinguir las cuatro etiologías de HVI directamente a partir de imágenes de ECG de 12 derivaciones. El objetivo no es reemplazar al cardiólogo ni suprimir los estudios complementarios, sino potenciar el ECG como instrumento de primera evaluación,

orientando el diagnóstico diferencial desde el inicio del proceso clínico. De esta manera, se favorece una derivación más temprana hacia estudios confirmatorios adecuados, optimizando el uso de recursos diagnósticos y contribuyendo a una atención más precisa y oportuna.

Asimismo, este proyecto no surge únicamente de un interés académico, sino de una necesidad clínica concreta identificada por el Instituto Cardiovascular de Buenos Aires (ICBA), que planteó específicamente la conveniencia de contar con una herramienta capaz de asistir en la diferenciación de estas patologías. De este modo, el trabajo se desarrolla en el marco de una demanda real del ámbito asistencial, orientada a explorar el potencial del aprendizaje profundo como complemento de la práctica clínica habitual.

1.2 Objetivos

1.2.1 Objetivo general

Desarrollar una herramienta, con interfaz de usuario, basada en redes neuronales para la clasificación automática de cuatro patologías cardíacas (amiloidosis cardíaca, hipertensión arterial, estenosis aórtica y miocardiopatía hipertrófica) a partir de imágenes de ECG de 12 derivaciones, con el propósito de apoyar el diagnóstico clínico y la toma de decisiones médicas.

1.2.2 Objetivos específicos

a. Objetivos de mínima

1. Desarrollar una red neuronal que permita la clasificación de las cuatro patologías previamente mencionadas, a partir de imágenes de ECG, alcanzando un desempeño mínimo del 70 % de exactitud global.
2. Evaluar el desempeño del modelo mediante métricas estandarizadas de clasificación, incluyendo exactitud, precisión, sensibilidad, F1-score y matriz de confusión.
3. Desarrollar una interfaz de usuario que permita cargar imágenes de ECG, ejecutar el modelo entrenado y visualizar el resultado de la clasificación junto con la probabilidad asociada a cada patología.

b. Objetivos de máxima

1. Analizar la interpretabilidad del modelo mediante la generación de heatmaps sobre las imágenes de ECG del conjunto de prueba, con el fin de identificar qué regiones influyen en cada predicción.
2. Integrar la visualización de los heatmaps en la interfaz de usuario, proporcionando explicaciones visuales que permitan a los profesionales médicos interpretar las decisiones del modelo.
3. Evaluar la experiencia de usuario (UX) de la interfaz mediante pruebas con profesionales médicos.

2 Marco Teórico

2.1 Fundamentos del electrocardiograma

2.1.1 Fisiología eléctrica del corazón

El corazón posee un sistema de conducción especializado integrado por células y fibras conductoras con capacidad de autoexcitación. En condiciones fisiológicas normales, este sistema regula la propagación ordenada del impulso eléctrico, asegurando contracciones coordinadas y un ciclo cardíaco estable. La Figura 1 muestra un esquema de las principales estructuras que lo componen.

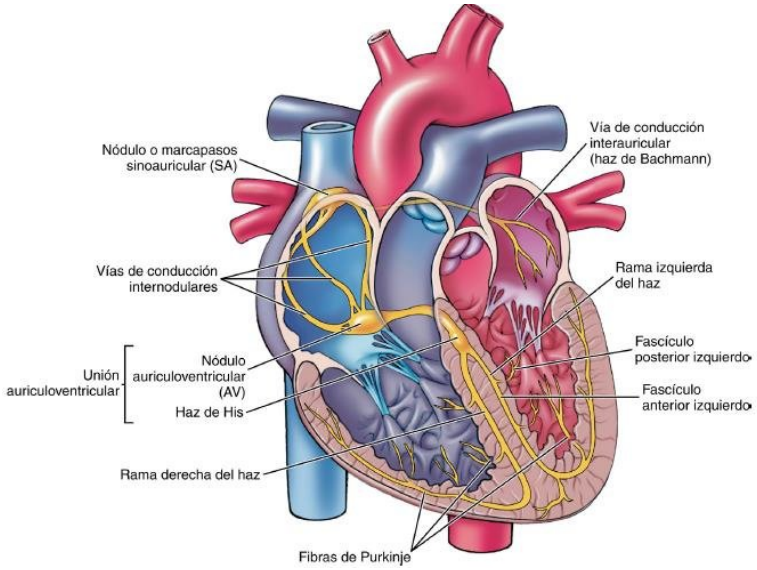

Figura 1: Esquema del sistema de conducción eléctrica del corazón [11].

El impulso eléctrico se inicia en el nodo sinoauricular (SA), ubicado en la aurícula derecha. Esta estructura actúa como el marcapasos fisiológico gracias a su capacidad intrínseca para generar potenciales de acción con la mayor frecuencia espontánea de todo el sistema. Desde este, el estímulo se propaga a través del miocardio auricular y viaja por vías de conducción especializadas hacia el nodo auriculoventricular (AV), ubicado en la porción inferior del septo interauricular.

Este nodo constituye la única vía fisiológica por la cual los impulsos eléctricos pueden pasar de las aurículas a los ventrículos, ya que entre ambas cavidades existe una estructura fibrosa no conductora que bloquea otras rutas alternativas. A este nivel se produce un retardo característico que permite que las aurículas completen su contracción y contribuyan al llenado ventricular antes del inicio de la contracción de los ventrículos.

Tras este retardo, el impulso desciende por el haz de His, que se bifurca en las ramas derecha e izquierda, y finalmente se distribuye a través de la red de fibras de Purkinje, asegurando una despolarización casi simultánea de ambos ventrículos [12].

2.1.2 Registro y obtención de la señal

Cuando el impulso eléctrico se desplaza a través del corazón, la actividad bioeléctrica generada no solo se propaga por el tejido cardíaco, sino que también se extiende hacia las estructuras que lo rodean. Una fracción de esta corriente alcanza la superficie corporal, lo que permite medirla

mediante electrodos adheridos a la piel. Al registrar las diferencias de potencial detectadas entre distintos puntos del cuerpo, se obtiene el electrocardiograma, una representación gráfica de la actividad eléctrica cardíaca a lo largo del tiempo [13].

La morfología de la señal registrada depende de la dirección en la que el impulso eléctrico atraviesa el corazón con respecto a los electrodos utilizados para la medición. En cada registro se define un polo positivo y un polo negativo, de modo que, cuando el frente de despolarización se desplaza hacia el polo positivo, la señal presenta una deflexión positiva, cuando se dirige hacia el polo negativo, la deflexión es negativa, y cuando se propaga aproximadamente en dirección perpendicular al eje definido entre ambos polos, la señal adquiere una morfología bifásica [14]. Como consecuencia, un mismo evento eléctrico genera señales de distinta morfología según la orientación desde la que se registre.

En la práctica clínica, el estándar corresponde al ECG de 12 derivaciones, obtenido a partir de diez electrodos: cuatro ubicados en las extremidades y seis sobre el tórax, tal como se muestra en la Figura 2. Cada derivación observa el corazón desde un ángulo diferente, proporcionando así información complementaria sobre la propagación del impulso eléctrico [15].

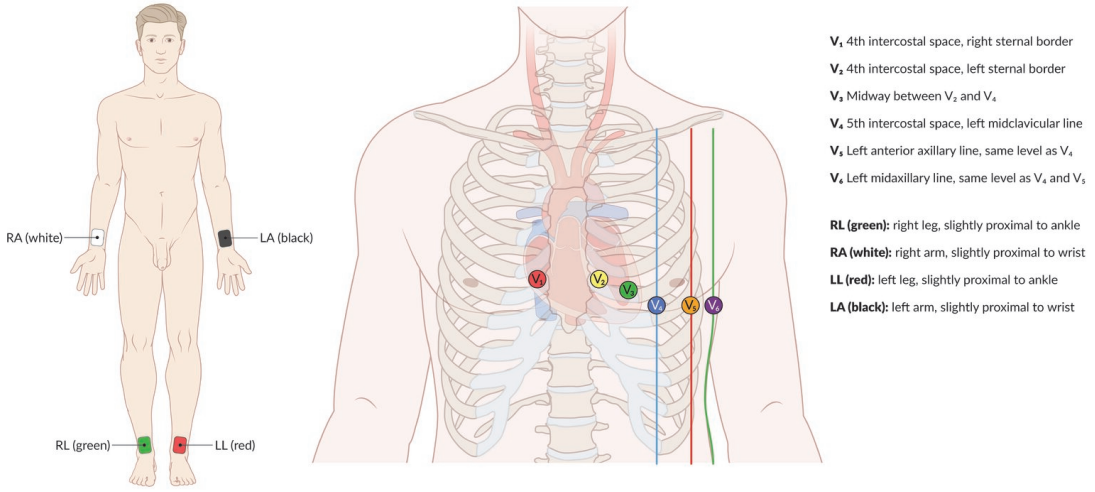

Figura 2: Ubicación de los electrodos para electrocardiograma estándar de 12 derivaciones [14].

En el plano frontal se encuentran las derivaciones bipolares (I, II y III), que registran la diferencia de potencial entre dos electrodos específicos, y las derivaciones unipolares aumentadas (aVR, aVL y aVF), que comparan el potencial de un electrodo con un punto de referencia formado por la combinación de los otros. Los electrodos de extremidades se ubican típicamente en el brazo derecho (BD), brazo izquierdo (BI), pierna izquierda (PI) y pierna derecha (PD), siendo este último utilizado como tierra para reducir interferencias.

En el plano horizontal se registran las derivaciones precordiales V1 a V6, cada una correspondiente a un electrodo colocado en una posición específica del tórax. Estas derivaciones se comparan con un punto de referencia denominado central de Wilson, definido como el promedio de los potenciales de BD, BI y PI. Gracias a esta disposición, las derivaciones precordiales permiten analizar la despolarización y repolarización ventricular desde una perspectiva transversal.

2.1.3 Ondas y segmentos característicos

Por convención, el trazado electrocardiográfico se organiza en ondas, intervalos y segmentos que reflejan las distintas fases de la activación cardíaca, tal como se ilustra en la Figura 3. La interpretación clínica del ECG se basa en el análisis de la amplitud, duración, morfología y eje eléctrico de estos componentes. Variaciones en estos parámetros permiten reconocer alteraciones en la conducción, sobrecargas de cavidades, crecimiento ventricular, bloqueos de rama y patrones de isquemia, entre otros hallazgos [13][16][17][18].

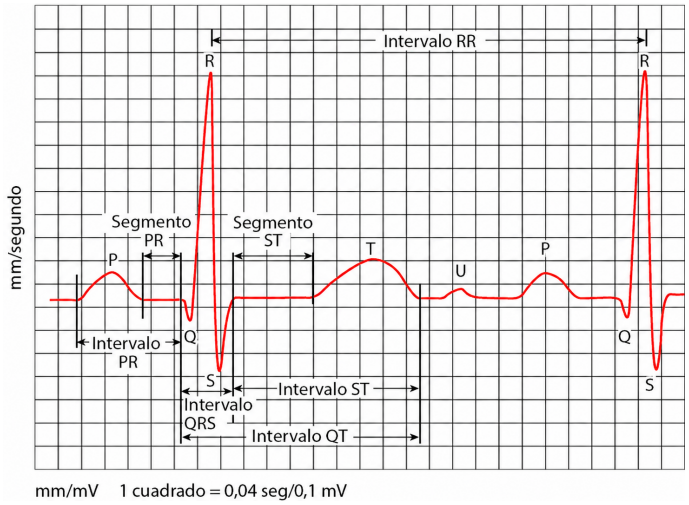

Figura 3: Ondas, segmentos e intervalos del trazado electrocardiográfico [18].

La onda P corresponde a la despolarización auricular. En condiciones normales es de pequeña amplitud, forma redondeada y positiva en la mayoría de las derivaciones. Su duración y morfología informan sobre el tiempo de activación auricular y pueden alertar sobre agrandamiento de la aurícula izquierda o derecha.

El intervalo PR mide el tiempo transcurrido desde el inicio de la despolarización auricular hasta el comienzo del complejo QRS, e incluye la conducción a través del nodo AV, el haz de His y sus ramas. En condiciones normales oscila entre 120 y 200 ms. Su prolongación indica un retraso en la conducción auriculoventricular.

El complejo QRS refleja la despolarización ventricular. En condiciones normales su duración es inferior a 120 ms. Un QRS ensanchado sugiere un trastorno de conducción intraventricular. La amplitud de las ondas R y S en las distintas derivaciones sirve como indicador del voltaje ventricular.

El segmento ST conecta el final del QRS con el inicio de la onda T y corresponde al período en que el ventrículo está completamente despolarizado. En condiciones normales es isoeléctrico. Su elevación o depresión puede ser signo de isquemia o necrosis miocárdica, aunque también ocurre en otras condiciones como pericarditis o desequilibrios electrolíticos.

La onda T representa la repolarización ventricular. En la mayoría de las derivaciones es positiva y asimétrica. Su morfología puede alterarse por isquemia, sobrecargas ventriculares o trastornos electrolíticos.

El intervalo QT abarca desde el inicio del QRS hasta el final de la onda T y representa la duración total de la actividad eléctrica ventricular. Su prolongación se asocia a mayor riesgo de arritmias ventriculares graves.

2.1.4 Limitaciones diagnósticas del ECG

El electrocardiograma es una de las herramientas diagnósticas más empleadas en cardiología, gracias a su simplicidad, rapidez y carácter no invasivo. Este estudio permite identificar alteraciones del ritmo, trastornos de la conducción y diversas patologías cardíacas, convirtiéndose en una técnica fundamental para evaluar el funcionamiento eléctrico del corazón. Sin embargo, a pesar de su valor clínico, presenta limitaciones inherentes a la propia naturaleza del estudio, que condicionan su desempeño como herramienta de diagnóstico diferencial.

Por un lado, la variabilidad interobservador en la interpretación del trazado puede ser significativa. La concordancia entre médicos al interpretar un mismo ECG es moderada o baja, especialmente ante hallazgos sutiles, trazados atípicos o patologías de baja prevalencia. Esta variabilidad se ve acentuada por la falta de estandarización en los criterios diagnósticos y por la curva de aprendizaje requerida para una lectura experta [19][20][21].

Por otro lado, múltiples enfermedades cardíacas pueden producir alteraciones electrocardiográficas similares o incluso indistinguibles a simple vista, lo que limita la especificidad diagnóstica del método. Hallazgos como la hipertrofia ventricular izquierda, los trastornos de la repolarización o los bloqueos de rama pueden presentarse en condiciones con fisiopatologías completamente distintas, dificultando el diagnóstico diferencial basado exclusivamente en el ECG. Esta situación obliga en muchos casos a recurrir a estudios complementarios que resultan más costosos, menos accesibles y, en ocasiones, invasivos [5][22].

2.2 Hipertrofia ventricular izquierda

2.2.1 Definición e importancia clínica

La hipertrofia ventricular izquierda (HVI) se define como el aumento anormal de la masa miocárdica del ventrículo izquierdo, que se manifiesta anatómicamente como un engrosamiento de la pared ventricular. Como ilustra la Figura 4, este engrosamiento es consecuencia principalmente del incremento del tamaño de los cardiomiocitos, acompañado en grado variable por fibrosis intersticial y remodelado de la matriz extracelular [23].

En la mayoría de las situaciones, la HVI constituye una respuesta adaptativa del miocardio frente a un aumento crónico de la carga de trabajo ventricular. Cuando éste se encuentra sometido de manera sostenida a una sobrecarga de presión o de volumen, se producen cambios estructurales destinados inicialmente a mantener la función cardíaca. La magnitud y distribución de estos cambios dependen del tipo y de la intensidad del estímulo que los origina [24][25].

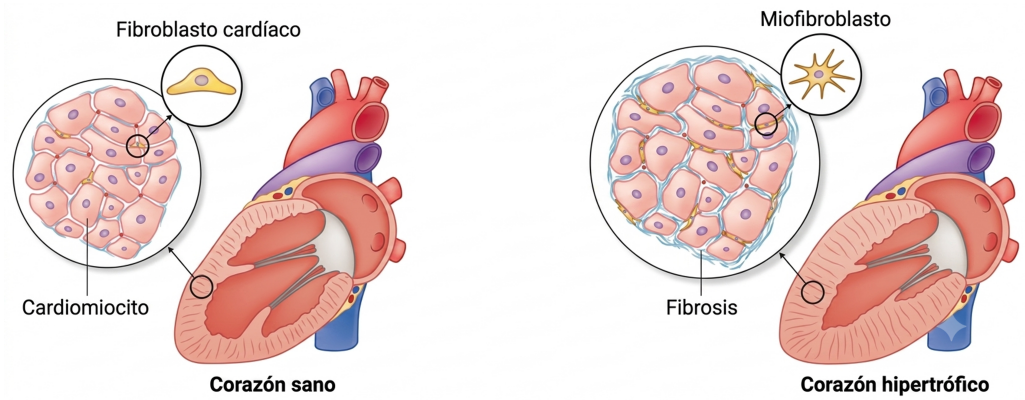

Figura 4: Esquema comparativo entre un corazón sano y un corazón con HVI [23].

Los cambios estructurales producidos por la HVI modifican tanto las propiedades mecánicas como eléctricas del tejido cardíaco. Por un lado, el engrosamiento progresivo de la pared y la fibrosis aumentan la rigidez del ventrículo, dificultando su relajación durante la diástole y favoreciendo la elevación de las presiones de llenado. En etapas avanzadas, pueden contribuir también al deterioro de la función sistólica al comprometer la capacidad contráctil de la cavidad. Por otro lado, la fibrosis también actúa como barrera para la propagación normal del impulso eléctrico, generando zonas de conducción lenta o bloqueos que aumentan la susceptibilidad a arritmias [26][27].

Por estos motivos, la HVI constituye un marcador independiente de riesgo cardiovascular elevado asociado a mayor incidencia de eventos como infarto de miocardio, insuficiencia cardíaca y muerte súbita. Su identificación temprana resulta, por lo tanto, clínicamente relevante, ya que permite orientar el tratamiento antes de que el daño estructural se vuelva irreversible [28][29].

2.2.2 Etiologías

La HVI no constituye una enfermedad en sí misma, sino una manifestación fenotípica que puede ser consecuencia de múltiples patologías cardiovasculares de diversa naturaleza. A pesar de que el engrosamiento ventricular puede presentar una apariencia morfológicamente similar independientemente de su causa, las distintas etiologías que lo originan difieren de manera sustancial en su mecanismo, pronóstico y tratamiento. En este trabajo se consideran cuatro de ellas, las cuales constituyen las de mayor prevalencia e impacto clínico en la práctica cardiológica adulta y representan los principales diagnósticos diferenciales a resolver frente a un paciente con HVI [30].

a. Hipertensión arterial

La hipertensión arterial (HTA) se define como la elevación sostenida de la presión arterial por encima de los valores normales. Constituye uno de los trastornos crónicos más prevalentes en el mundo, afectando aproximadamente al 33 % de la población adulta global [31].

La exposición prolongada a una presión arterial elevada obliga al ventrículo izquierdo a trabajar contra una resistencia aumentada, desencadenando una hipertrofia concéntrica compensatoria en la que la pared de la cavidad se engrosa. La HVI se desarrolla en aproximadamente el 40 % de los pacientes hipertensos y constituye la manifestación más característica del daño cardíaco en esta enfermedad [32]. En la mayoría de los casos, la HVI permanece asintomática durante años, lo que favorece una progresión silenciosa del daño cardiovascular. La identificación precoz de esta alteración posee especial relevancia clínica, ya que el tratamiento antihipertensivo adecuado puede detener e incluso revertir parcialmente el remodelado ventricular en estadios tempranos [33][34].

b. Estenosis aórtica

La estenosis aórtica (EAo) es una valvulopatía degenerativa caracterizada por el estrechamiento progresivo de la válvula aórtica, lo que produce la obstrucción del flujo de salida de sangre desde el ventrículo izquierdo hacia la aorta [35]. Es una de las valvulopatías más frecuentes en adultos mayores y su prevalencia aumenta marcadamente con la edad. En personas mayores de 75 años, se ha estimado una prevalencia de aproximadamente 12 % cuando se consideran todos los grados de severidad [36][37].

Si bien el mecanismo causal difiere del de la HTA, la obstrucción valvular impone sobre el ventrículo izquierdo una sobrecarga de presión crónica funcionalmente equivalente, por lo que desencadena una hipertrofia morfológicamente similar. La HVI se desarrolla en aproximadamente el 50 % de los pacientes con EAo severa cuando se aplican criterios formales de masa, sin embargo, más del 70 % presenta algún grado de remodelado geométrico concéntrico en el tejido [38][39].

A diferencia de la HTA, la EAo no dispone de un tratamiento farmacológico capaz de revertir por completo la obstrucción de la válvula. La única intervención definitiva es el reemplazo valvular, ya sea mediante cirugía (SAVR) o mediante un procedimiento transcatéter (TAVI) [40][41].

c. Miocardiopatía hipertrófica

La miocardiopatía hipertrófica (MCH) es una enfermedad miocárdica de origen genético caracterizada por el aumento del espesor de la pared ventricular izquierda en ausencia de una causa hemodinámica que lo justifique. Constituye la miocardiopatía hereditaria más frecuente y su prevalencia se estima en aproximadamente el 0,2 % de la población adulta, aunque formas leves o subdiagnosticadas podrían hacer que su frecuencia real sea mayor a la documentada [42][43].

La enfermedad se asocia predominantemente a mutaciones en genes que codifican proteínas del sarcómero cardíaco. Hasta el momento se han identificado entre 25 y 30 genes asociados a la MCH, siendo las variantes en *MYH7* y *MYBPC3* las responsables de aproximadamente el 75 % de los casos [44]. Desde el punto de vista estructural, se manifiesta como una hipertrofia miocárdica progresiva, cuyo patrón es típicamente asimétrico, con afectación predominante del tabique interventricular. Este patrón contrasta con la hipertrofia concéntrica observada habitualmente en la HTA y la EAo, y constituye un elemento de utilidad para el diagnóstico diferencial entre estas patologías [45].

A diferencia de las etiologías causadas por sobrecarga de presión, el tratamiento no se orienta a corregir una causa externa reversible, sino al control de los síntomas, la reducción de la obstrucción del tracto de salida cuando está presente, y la prevención de muerte súbita mediante la colocación de cardiodesfibrilador implantable en pacientes de alto riesgo [46].

d. Amiloidosis cardíaca

La amiloidosis cardíaca (Am) es una enfermedad infiltrativa causada por el depósito de proteínas mal plegadas en forma de fibrillas amiloides en el miocardio. Las formas clínicamente más relevantes son la amiloidosis por cadenas ligeras de inmunoglobulina (AL) y la amiloidosis por transtiretina (ATTR), que en conjunto representan más del 95 % de los casos de compromiso cardíaco [47]. Si bien históricamente fue considerada una enfermedad rara, con una prevalencia estimada inferior al 0,05 % de la población general, estudios recientes han evidenciado un subdiagnóstico significativo. En personas mayores de 75 años sin sospecha clínica previa, se ha reportado una prevalencia del 2,28 %, observándose además un incremento con la edad [48].

A diferencia de las demás etiologías consideradas, el engrosamiento de las paredes ventriculares en la Am no refleja un incremento de la masa de los cardiomiocitos, sino la acumulación de material amiloide en el espacio extracelular. Sin embargo, pese a esta diferencia en su origen, la infiltración produce un fenotipo de hipertrofia similar al generado por otras causas de HVI. En particular, los patrones de engrosamiento septal asimétrico pueden simular los de la MCH, y se ha estimado que más del 50 % de los pacientes con ATTR reciben inicialmente un diagnóstico incorrecto, siendo la MCH el más frecuente [49].

Si bien las cuatro etiologías consideradas presentan mecanismos fisiopatológicos diferentes, no son necesariamente excluyentes y pueden coexistir en un mismo paciente. La hipertensión arterial resulta particularmente frecuente como comorbilidad de otras enfermedades capaces de producir HVI. Se ha reportado su presencia en aproximadamente el 78 % de los pacientes con EAo [50] y entre el 40 % y el 60 % de aquellos con MCH [51]. Esta coexistencia puede dificultar la identificación de una etiología adicional, ya que la elevada prevalencia de HTA y su capacidad para producir HVI por sí sola pueden llevar a atribuirle el engrosamiento ventricular de manera exclusiva.

Otro caso de coexistencia bien documentado es el de la amiloidosis cardíaca con la EAo. Estudios en pacientes con EAo severa candidatos a reemplazo valvular han identificado ATTR concomitante en alrededor del 11 % de los casos [52]. En estos pacientes, la amiloidosis suele pasar desapercibida porque la obstrucción valvular domina el cuadro clínico. Sin embargo, el reemplazo valvular corrige únicamente la sobrecarga de presión mecánica, por lo que si la enfermedad infiltrativa no recibe tratamiento específico, continúa progresando y empeora el pronóstico. Por este motivo, la identificación de ambas condiciones resulta clínicamente relevante para orientar un tratamiento y

seguimiento adecuados [53].

2.2.3 Diagnóstico electrocardiográfico

Si bien la HVI constituye una alteración estructural, los cambios asociados al remodelado ventricular pueden modificar la actividad eléctrica cardíaca y, por lo tanto, manifestarse en el trazado electrocardiográfico. El aumento de la masa ventricular modifica la magnitud y la orientación de las fuerzas eléctricas generadas durante la despolarización. Como consecuencia, pueden observarse ondas R de mayor amplitud en las derivaciones que registran las fuerzas eléctricas dirigidas hacia la izquierda (I, aVL, V5 y V6), acompañadas de ondas S más profundas en las derivaciones que exploran el lado derecho del corazón (principalmente V1 y V2). Este fenómeno puede reflejarse como una desviación del eje eléctrico del QRS hacia la izquierda [54].

Por otro lado, la HVI también puede asociarse con alteraciones de la repolarización ventricular. El aumento de la masa miocárdica y el remodelado estructural pueden modificar la secuencia de recuperación eléctrica de los ventrículos, generando diferencias en la repolarización entre distintas regiones del miocardio. En el ECG, estas alteraciones pueden manifestarse con el denominado patrón de *strain*, caracterizado por un descenso del segmento ST seguido de una inversión asimétrica de la onda T, principalmente en las derivaciones izquierdas (V5 y V6) [55].

La Figura 5 ilustra algunas de estas manifestaciones mediante la comparación de un trazado electrocardiográfico correspondiente a un corazón con masa ventricular normal con otro que presenta hallazgos sugestivos de HVI.

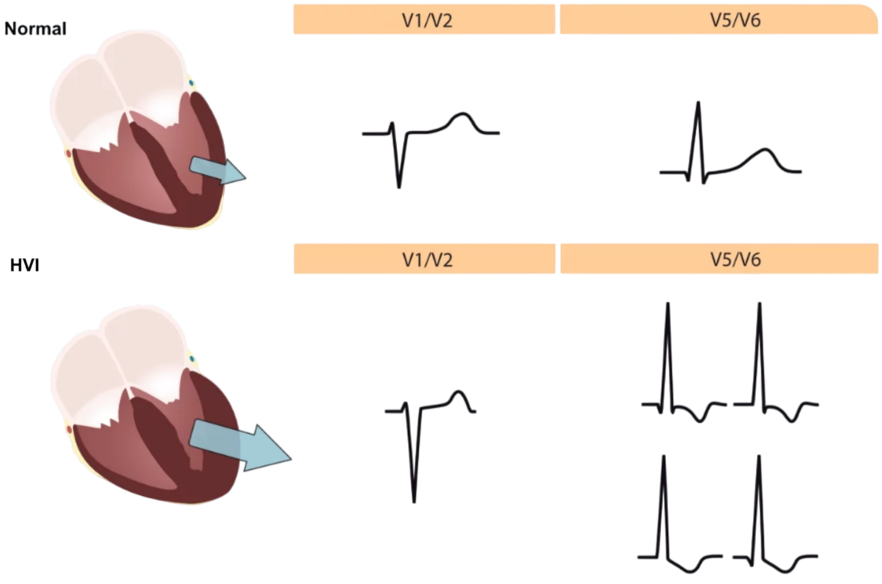

Figura 5: Comparación de los trazados electrocardiográficos en V1/V2 y V5/V6 entre un corazón con masa ventricular normal y uno con HVI [54].

Los diferentes hallazgos descritos han dado lugar al desarrollo de distintos criterios para el diagnóstico electrocardiográfico de la HVI. La mayoría de ellos se basa en la amplitud de los complejos QRS, aunque algunos incorporan también otras características del trazado o ajustan sus umbrales en función de características del paciente, como el sexo y la edad. Entre los más conocidos y utilizados se encuentra el criterio de Sokolow-Lyon, que establece la presencia de HVI cuando la

suma de la onda S en V1 y la onda R máxima en V5 o V6 supera los 35 mm ($SV_1 + RV_{5/V6} \geq$ 35 mm) [54][56].

Sin embargo, los criterios electrocardiográficos tradicionales presentan, en general, una elevada especificidad (∼90 %) pero una sensibilidad limitada, con valores que oscilan entre el 20 % y el 50 % [54]. Por lo tanto, aunque la presencia de un criterio electrocardiográfico puede aportar evidencia a favor de la presencia de HVI, su ausencia no permite descartarla. Esta limitación se relaciona, en parte, con la variabilidad de las manifestaciones electrocardiográficas entre sujetos. La presencia y magnitud de las alteraciones en el trazado dependen del grado y patrón de hipertrofia, así como de características individuales del paciente que pueden modificar la expresión del ECG.

Más allá de las limitaciones para la identificación de la HVI, existe una dificultad diagnóstica adicional de mayor relevancia: la determinación de la patología subyacente. Actualmente no existe un conjunto de criterios electrocardiográficos que permita establecer de manera confiable la causa de la HVI. No obstante, la etiología responsable del remodelado ventricular puede modificar en cierto grado la expresión electrocardiográfica, dando lugar a diferencias que, aunque no son exclusivas de una determinada enfermedad, pueden aportar información para orientar el diagnóstico [57].

En el caso de la HVI asociada a HTA y a EAo son frecuentes los aumentos del voltaje del QRS y las alteraciones de la repolarización mencionadas anteriormente. Dado que ambas patologías generan una sobrecarga crónica de presión sobre el ventrículo izquierdo, sus manifestaciones electrocardiográficas pueden resultar particularmente difíciles de diferenciar a partir del ECG de manera aislada. Si bien la EAo podría asociarse con un remodelado ventricular más marcado, en ambas patologías la magnitud de la hipertrofia depende de la severidad y del tiempo de evolución de la enfermedad, por lo que la intensidad de estos hallazgos no permite, por sí sola, distinguir entre ellas [58][59].

La MCH también puede presentar aumentos del voltaje del QRS y alteraciones de la repolarización, aunque su expresión electrocardiográfica es más heterogénea entre pacientes. Entre las manifestaciones descritas se encuentran ondas Q profundas y estrechas, inversiones de la onda T y alteraciones del segmento ST. En algunas variantes, como la MCH apical, las inversiones profundas y simétricas de la onda T pueden constituir un hallazgo característico. Sin embargo, estas manifestaciones no se presentan de manera uniforme entre diferentes sujetos y su ausencia no permite descartar la enfermedad, ya que entre un 5 % y un 10 % de los pacientes pueden presentar un ECG aparentemente normal [3].

La amiloidosis cardíaca, por su parte, puede presentar con mayor frecuencia un patrón electrocardiográfico diferente, ya que el aumento del espesor de la pared ventricular se debe principalmente al depósito de material amiloide en el espacio extracelular y no a un incremento proporcional de la masa de los cardiomiocitos. Esta diferencia puede traducirse en una discordancia entre el espesor de la pared ventricular observado mediante técnicas de imagen y la amplitud de los complejos QRS. Entre los hallazgos electrocardiográficos descritos se encuentran el bajo voltaje de los complejos QRS, particularmente en las derivaciones de los miembros, y el patrón de pseudo-infarto, definido por la presencia de ondas Q patológicas en dos derivaciones consecutivas, en ausencia de un infarto de miocardio previo. También pueden observarse trastornos de conducción y alteraciones en la progresión de la onda R en las derivaciones precordiales [60]. Sin embargo, ninguno de estos hallazgos está presente en la totalidad de los pacientes y su frecuencia puede variar según la población estudiada y el tipo de amiloidosis, lo que limita su utilidad como hallazgos aislados. Incluso, en algunos casos, pueden observarse criterios electrocardiográficos de HVI, por lo que la presencia de voltajes elevados tampoco permite excluir esta enfermedad [61][62].

En conjunto, las cuatro etiologías consideradas pueden presentar ciertos hallazgos orientativos, aunque existe una importante superposición entre sus manifestaciones electrocardiográficas. La Tabla 2 sintetiza las características más representativas de cada una descritas en esta sección.

Tabla 2: Principales manifestaciones electrocardiográficas asociadas a diferentes etiologías de HVI.

Hallazgo	**HTA**	**EAo**	**MCH**	**Am**
Voltajes elevados	++	++	+	+
Ondas Q profundas y estrechas	-	-	++	-
Patrón de pseudo-infarto	-	-	-	++
Bajo voltaje del QRS	-	-	-	+
Alteraciones de repolarización ST-T	++	++	++	+
Trastornos de conducción	+	+	+	++

Nota: ++ frecuente; + puede presentarse; - no característico.

La diversidad de manifestaciones descritas muestra que la información electrocardiográfica relevante se encuentra distribuida entre múltiples características del trazado. La interpretación conjunta de estas características puede aportar información útil para orientar la etiología de la HVI, pero su identificación e integración mediante inspección visual puede resultar compleja y depende en cierta medida de la experiencia del observador. En este contexto, el análisis computacional ofrece la posibilidad de reconocer patrones de asociación entre estas características que podrían no resultar evidentes a simple vista y, de este modo, contribuir a una interpretación más completa de la información contenida en el trazado.

Asimismo, el interés por aprovechar esta información se justifica en que el ECG es un estudio de bajo costo, ampliamente disponible y utilizado de manera rutinaria en la evaluación cardiológica. Además, se ha descrito que ciertas alteraciones electrocardiográficas pueden preceder a la aparición de cambios estructurales evidentes en los estudios de imagen, tanto en la MCH como en la amiloidosis cardíaca [3][63]. Por lo tanto, en determinadas circunstancias, el ECG puede aportar indicios relevantes sobre la enfermedad subyacente antes de que sus manifestaciones estructurales sean claramente identificables, lo que refuerza su valor en la evaluación de estas patologías.

2.2.4 Diagnóstico ecocardiográfico

La ecocardiografía constituye una herramienta fundamental para el estudio de la HVI, ya que permite evaluar de manera no invasiva la estructura y función cardíaca. A diferencia del ECG, que registra la actividad eléctrica del corazón, la ecocardiografía permite medir directamente el espesor de las paredes ventriculares, las dimensiones de la cavidad y otros parámetros estructurales, así como estimar la masa ventricular izquierda. Por este motivo, constituye una herramienta de referencia para la confirmación y caracterización estructural de la HVI. Esta se define, entre otros criterios, a partir de la masa ventricular izquierda indexada a la superficie corporal, considerando valores superiores a 115 g/m^2 en hombres y 95 g/m^2 en mujeres como indicativos de un aumento de la masa ventricular [64].

Además de caracterizar la presencia y el patrón de HVI, la ecocardiografía aporta información que puede orientar su etiología. En la HVI asociada a HTA suele observarse un engrosamiento predominantemente concéntrico, aunque también pueden presentarse otras configuraciones morfológicas, acompañado de alteraciones de la función diastólica. En la EAo, la evaluación del engrosamiento ventricular se complementa con el estudio de la válvula aórtica y del flujo transvalvular, lo que permite identificar la obstrucción responsable de la sobrecarga de presión. En la MCH, el engrosamiento puede presentar una distribución asimétrica, aunque también pueden encontrarse patrones más uniformes y otras formas de presentación. Por su parte, la amiloidosis cardíaca puede producir un engrosamiento más difuso de las paredes y suele asociarse con alteraciones de la función diastólica y otros signos de compromiso cardíaco [65].

Sin embargo, estos hallazgos no son exclusivos de una etiología en particular y los patrones pueden superponerse, especialmente entre MCH, HTA y Am [66]. Por este motivo, aunque la ecocardiografía aporta información fundamental para confirmar y caracterizar la HVI y para orientar

su etiología, no siempre resulta suficiente para establecer un diagnóstico definitivo. En la práctica, la orientación diagnóstica surge de la integración de los hallazgos ecocardiográficos y electrocardiográficos junto con los antecedentes clínicos y, cuando persiste la incertidumbre, con estudios complementarios de mayor especificidad.

2.2.5 Estudios complementarios

Cuando la evaluación clínica, el ECG y la ecocardiografía no son suficientes para establecer la etiología de la HVI, pueden requerirse estudios complementarios dirigidos a confirmar o descartar causas específicas. La elección de estos estudios depende de la patología sospechada y de los hallazgos obtenidos en la evaluación inicial.

En el caso de la EAo, la ecocardiografía habitualmente permite determinar la presencia de la estenosis mediante la evaluación de la válvula y de los parámetros hemodinámicos correspondientes. Sin embargo, pueden presentarse situaciones en las que estos parámetros sean discordantes, dificultando caracterizar la gravedad de la enfermedad. En estos casos, la tomografía computarizada puede complementar la evaluación mediante la cuantificación del calcio de la válvula aórtica, aportando información adicional para determinar la gravedad de la estenosis [40].

En la MCH, los estudios genéticos permiten identificar variantes patogénicas o probablemente patogénicas en genes asociados con las proteínas del sarcómero. La identificación de una variante causal puede aportar información relevante para establecer con mayor certeza la etiología y tiene especial importancia para el estudio de familiares en riesgo mediante pruebas genéticas en cascada. Sin embargo, solo entre el 30 % y 40 % de los pacientes con MCH presentan una variante sarcomérica identificable, por lo que los resultados del estudio genético deben interpretarse junto con la información clínica y fenotípica para establecer un diagnóstico [46].

En el caso de la amiloidosis cardíaca, los estudios complementarios permiten evaluar con mayor detalle la naturaleza del tejido que produce el engrosamiento ventricular. Si bien la ecocardiografía permite identificar el aumento del espesor de las paredes y otras alteraciones estructurales, no permite caracterizar directamente el tejido que origina estos cambios. La resonancia magnética cardíaca (RMC) aporta información adicional mediante la caracterización tisular, permitiendo identificar características compatibles con la presencia de material amiloide y contribuir a diferenciar este engrosamiento de otras causas de HVI [5][6]. Sin embargo, la RMC no permite establecer por sí sola el tipo de amiloidosis. Para diferenciar principalmente entre las formas ATTR y AL, se combina la gammagrafía cardíaca y la búsqueda de proteínas monoclonales en sangre y orina. En determinadas condiciones, la combinación de estos estudios permite establecer de manera no invasiva el diagnóstico de amiloidosis por ATTR, mientras que en casos en los que los resultados no son concluyentes puede ser necesaria una biopsia para confirmar y tipificar el depósito [67].

Por su parte, a diferencia de las demás etiologías, la HVI hipertensiva no cuenta con un estudio específico que la confirme de forma aislada. Su atribución se basa en la presencia documentada de hipertensión arterial junto con hallazgos estructurales y electrocardiográficos compatibles, en ausencia de elementos que orienten hacia una etiología alternativa. En este sentido, establecer el origen hipertensivo de la HVI puede ser clínicamente desafiante, ya que requiere de múltiples evaluaciones y seguimiento para descartar otras causas [6].

En conjunto, estos estudios permiten complementar la información obtenida mediante el ECG y ecocardiografía, y así aumentar la certeza sobre la etiología de la HVI. La necesidad de recurrir a estudios diferentes según la etiología pone de manifiesto la importancia de orientar tempranamente su causa para dirigir de manera más eficiente la evaluación posterior y reducir demoras en el proceso diagnóstico.

2.3 Deep learning en diagnóstico médico

2.3.1 Redes neuronales convolucionales

Las redes neuronales artificiales son modelos computacionales capaces de aprender relaciones complejas entre un conjunto de datos de entrada y una salida deseada mediante el ajuste de parámetros internos durante una etapa de entrenamiento. Su estructura se organiza en capas de neuronas artificiales interconectadas, donde cada neurona combina linealmente las señales recibidas y aplica posteriormente una función de activación no lineal. El proceso de aprendizaje consiste en actualizar iterativamente los pesos de estas conexiones con el objetivo de minimizar una función de pérdida, la cual cuantifica el error entre las predicciones del modelo y los valores esperados [68].

La arquitectura más simple corresponde a las redes densas o completamente conectadas (*fully connected*), en las que cada neurona de una capa se conecta con todas las neuronas de la capa anterior. Aunque este esquema resulta adecuado para datos de baja dimensionalidad, presenta importantes limitaciones cuando se aplica a imágenes. Por un lado, el número de parámetros crece rápidamente con el tamaño de la imagen, incrementando el costo computacional y el riesgo de sobreajuste. Por otro, al tratar cada píxel de manera independiente, estas redes no aprovechan la organización espacial propia de las imágenes [68].

En este contexto, surgieron las redes neuronales convolucionales (CNN, del inglés *Convolutional Neural Networks*), las cuales fueron desarrolladas para abordar específicamente este tipo de datos. Su arquitectura incorpora mecanismos que permiten aprovechar la información espacial de las imágenes. En particular, las operaciones convolucionales procesan regiones locales de la imagen y capturan relaciones entre píxeles cercanos, permitiendo así aprender patrones como bordes, texturas y formas. Asimismo, el uso de filtros compartidos permite detectar un mismo patrón independientemente de su posición en la imagen, favoreciendo la invarianza traslacional [69]. Debido a estas características, las CNN logran reducir significativamente el número de parámetros y aprender representaciones visuales más eficientes y robustas que las obtenidas mediante redes completamente conectadas.

Una CNN típica se organiza en dos etapas principales, esquematizadas en la Figura 6.

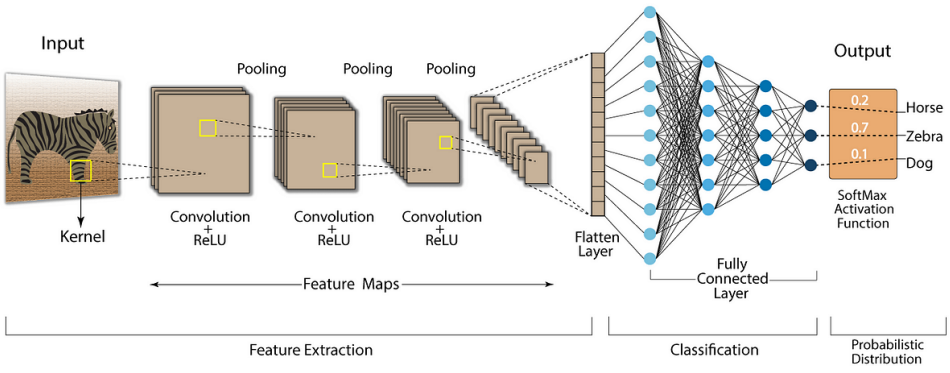

Figura 6: Arquitectura general de una red neuronal convolucional [70].

La primera etapa corresponde al extractor de características (*backbone*), cuya función es transformar progresivamente la imagen de entrada en una representación cada vez más abstracta. Para ello, emplea capas convolucionales formadas por un conjunto de filtros o *kernels*, pequeñas matrices de pesos cuyos valores se aprenden durante el entrenamiento. Cada filtro se desplaza sobre la imagen calculando, en cada posición, la suma de los productos entre sus pesos y los valores de la región local correspondiente. Como resultado se obtiene un mapa de características (*feature map*),

cuyos valores indican el grado de presencia del patrón aprendido en cada posición de la imagen [69][70].

Una misma capa convolucional aplica simultáneamente múltiples filtros, cada uno especializado en detectar un patrón diferente. A medida que la información avanza a través de la red, las primeras capas aprenden características simples, como bordes y líneas, mientras que las capas más profundas combinan estas representaciones para detectar texturas, formas y estructuras de mayor complejidad. Las capas convolucionales suelen combinarse con funciones de activación no lineal, como ReLU (*Rectified Linear Unit*), que introducen la no linealidad necesaria para aprender relaciones complejas, y con operaciones de reducción espacial (*pooling*), que disminuyen las dimensiones de los mapas de características conservando la información más relevante [70].

La segunda etapa corresponde a la cabeza clasificadora (*head*), que recibe la representación generada por el extractor de características y produce la predicción final. En tareas de clasificación multiclase, suele incluir una o más capas densas (*fully connected*) y finaliza con una función de activación *softmax*, que transforma las salidas del modelo en una distribución de probabilidad sobre todas las clases consideradas [69][70].

2.3.2 Aprendizaje por transferencia

El entrenamiento de una CNN desde cero requiere grandes volúmenes de datos etiquetados para que el modelo aprenda representaciones visuales útiles. En dominios donde disponer de tal cantidad de imágenes anotadas por expertos resulta difícil o inviable, como ocurre habitualmente en medicina, el aprendizaje por transferencia (*transfer learning*) constituye una estrategia para reducir esta dependencia de datos [71].

Esta técnica consiste en reutilizar el conocimiento adquirido por un modelo previamente entrenado sobre un conjunto de datos diferente, y generalmente para una tarea relacionada, empleándolo como punto de partida para resolver una nueva tarea. En lugar de inicializar todos los parámetros del modelo de manera aleatoria y aprender una representación desde cero, se parte de los pesos obtenidos durante el entrenamiento previo y se los adapta al nuevo problema [72]. Esto resulta posible debido a la naturaleza jerárquica de las representaciones aprendidas por las CNN. Las características de bajo nivel aprendidas en las capas tempranas, como bordes, texturas y contornos, son relativamente generales y pueden conservar su utilidad en tareas diferentes a aquella para la que el modelo fue originalmente entrenado, por lo que el modelo puede reutilizar gran parte del conocimiento ya adquirido y adaptar las capas finales, cuyas representaciones son más específicas, a la nueva tarea [73].

El proceso de transferencia puede realizarse mediante diferentes estrategias, como se ilustra en la Figura 7. Una de ellas consiste en utilizar el modelo preentrenado como extractor de características (*feature extraction*), manteniendo fijos sus parámetros y reemplazando la cabeza clasificadora por una nueva, adaptada a las clases de la tarea objetivo. Durante el entrenamiento, se modifican únicamente los parámetros de esta nueva capa, mientras que los parámetros del modelo de origen permanecen congelados [74].

Una segunda estrategia consiste en realizar un ajuste fino (*fine-tuning*), en el cual, además de adaptar la cabeza clasificadora, se actualizan total o parcialmente los pesos del *backbone*. De esta manera, las representaciones aprendidas inicialmente pueden ajustarse progresivamente a las características específicas del nuevo dominio. El ajuste puede limitarse a las últimas capas de la red o extenderse a una mayor proporción de la arquitectura, dependiendo de la cantidad de datos disponibles y de la similitud entre los dominios de origen y objetivo [74].

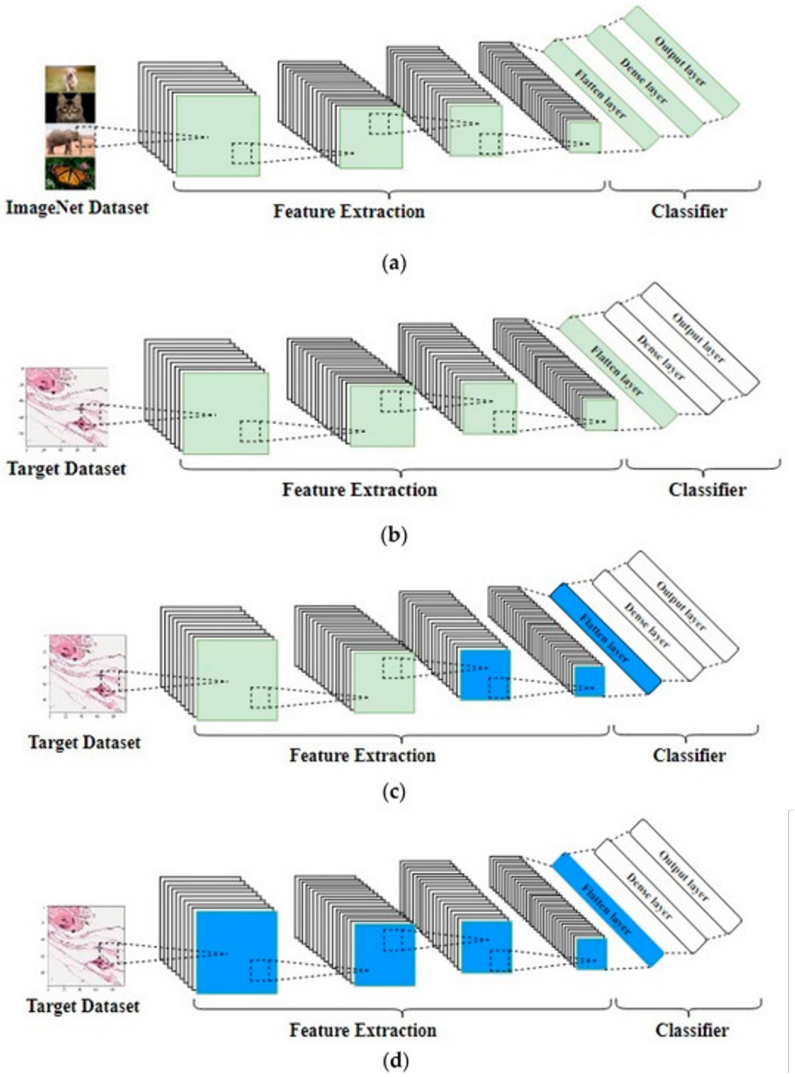

Figura 7: Técnicas de aprendizaje por transferencia: (a) CNN genérica entrenada en ImageNet (b) Extracción de características (c) Ajuste fino parcial (d) Ajuste fino total [74].

Una de las fuentes de preentrenamiento más utilizadas para redes convolucionales es ImageNet, un conjunto de datos de gran escala compuesto por millones de imágenes naturales organizadas en numerosas categorías [75]. Su gran volumen y diversidad permiten que los modelos aprendan representaciones visuales de distintos niveles de abstracción. Los modelos entrenados sobre este conjunto han demostrado ser capaces de aprender representaciones visuales reutilizables en una amplia variedad de tareas de clasificación y reconocimiento, incluso cuando el dominio objetivo es sustancialmente diferente [76]. Por este motivo, los pesos obtenidos mediante el entrenamiento sobre ImageNet se utilizan habitualmente como punto de partida para abordar otras tareas de visión por computadora, incluido el análisis de imágenes médicas.

2.3.3 Métricas de evaluación de modelos

La evaluación del desempeño de un clasificador multiclase requiere el uso de múltiples métricas complementarias. La métrica más inmediata es la exactitud (*accuracy*), que mide la proporción de muestras correctamente clasificadas sobre el total de muestras N. En un problema multiclase, la cantidad de muestras correctamente clasificadas corresponde a la suma de los verdaderos positivos de cada clase (VP_c), es decir, de las muestras de cada clase asignadas correctamente a ella.

$$\text{Accuracy} = \frac{\sum_c VP_c}{N}$$

Si bien esta métrica proporciona una medida general del desempeño, puede resultar poco representativa cuando existe un desbalance entre las clases, ya que un modelo puede obtener una exactitud elevada al clasificar correctamente las clases más frecuentes, aun cuando presente un desempeño deficiente en las clases minoritarias. Para abordar esta limitación, la exactitud balanceada (*balanced accuracy*, BA) calcula la media de la sensibilidad obtenida para cada clase, otorgando el mismo peso a todas ellas independientemente de su cantidad de muestras. Así, un clasificador que asigna las muestras al azar obtiene una BA cercana a $1/C$, mientras que un valor de 1 corresponde a una clasificación perfecta.

$$\text{BA} = \frac{1}{C} \sum_c \frac{VP_c}{VP_c + FN_c}$$

Adicionalmente, a nivel de cada clase se definen la precisión y la sensibilidad a partir de los verdaderos positivos (VP_c), falsos positivos (FP_c) y falsos negativos (FN_c) obtenidos al tratar dicha clase como positiva frente al resto. La precisión indica qué proporción de las muestras predichas como una clase pertenecen efectivamente a dicha clase, mientras que la sensibilidad indica qué proporción de las muestras reales de cada clase fueron correctamente identificadas por el modelo. En este sentido, la BA presentada anteriormente corresponde al promedio de la sensibilidad de todas las clases.

$$\text{Precisión}_c = \frac{VP_c}{VP_c + FP_c} \qquad \text{Sensibilidad}_c = \frac{VP_c}{VP_c + FN_c}$$

Dado que la precisión y la sensibilidad evalúan aspectos diferentes del desempeño de un clasificador, considerar una sola de ellas puede resultar insuficiente para caracterizar su rendimiento. En este sentido, el F1-score permite evaluar ambas de manera conjunta mediante su media armónica. Esta forma de combinación penaliza los valores bajos de cualquiera de las dos métricas, de modo que un valor elevado de precisión no compensa por completo una sensibilidad baja, ni viceversa.

$$\text{F1}_c = \frac{2 \cdot VP_c}{2 \cdot VP_c + FP_c + FN_c}$$

En aplicaciones clínicas, el análisis por clase resulta especialmente relevante, ya que permite identificar qué categorías son más propensas a error. En este sentido, la matriz de confusión constituye una herramienta complementaria, ya que muestra la cantidad de muestras asignadas a cada combinación de clase real y clase predicha. Los elementos de la diagonal principal corresponden a las clasificaciones correctas, mientras que los elementos fuera de ella representan las confusiones entre clases, lo que permite identificar fácilmente qué categorías tienden a confundirse entre sí.

2.3.4 Interpretabilidad de modelos

Más allá del desempeño de un modelo, resulta relevante comprender qué información utiliza para realizar sus predicciones. Si bien las métricas permiten cuantificar la capacidad del clasificador para distinguir correctamente entre las clases, no proporcionan información acerca de los patrones que sustentan sus decisiones. Esta opacidad constituye uno de los principales desafíos de los modelos de aprendizaje profundo en el ámbito clínico [77].

Para abordar esta limitación, se han desarrollado técnicas de interpretabilidad que permiten visualizar qué regiones de la imagen de entrada contribuyen a la predicción del modelo y evaluar si este basa sus decisiones en características visualmente plausibles o en elementos irrelevantes de la imagen. Entre ellas, Grad-CAM (del inglés, *Gradient-weighted Class Activation Mapping*) [78] es una de las más utilizadas, ya que se puede aplicar a cualquier arquitectura CNN sin necesidad de modificar el modelo ni el proceso de entrenamiento, tal como se muestra en la Figura 8.

Este método permite identificar qué regiones de una imagen contribuyen en mayor medida a la predicción de una clase determinada. Para ello, analiza las activaciones de una capa convolucional seleccionada de la red y determina cuáles de sus mapas de características tienen mayor influencia sobre la predicción de dicha clase. Para determinar la importancia de cada uno de estos mapas, Grad-CAM utiliza los gradientes de la puntuación de la clase seleccionada respecto de sus activaciones. A partir de una combinación ponderada de dichos mapas y la aplicación de una función ReLU para conservar únicamente las contribuciones positivas, se obtiene un mapa de relevancia que conserva la información espacial de la capa seleccionada. Este mapa se redimensiona hasta las dimensiones originales de la imagen y se superpone sobre ella en una representación tipo *heatmap*. Las regiones de mayor intensidad corresponden a aquellas que presentan una mayor contribución positiva a la predicción de la clase seleccionada. De esta manera, Grad-CAM permite complementar la salida de la red con una representación visual de las regiones de la imagen que resultaron relevantes para su decisión [78].

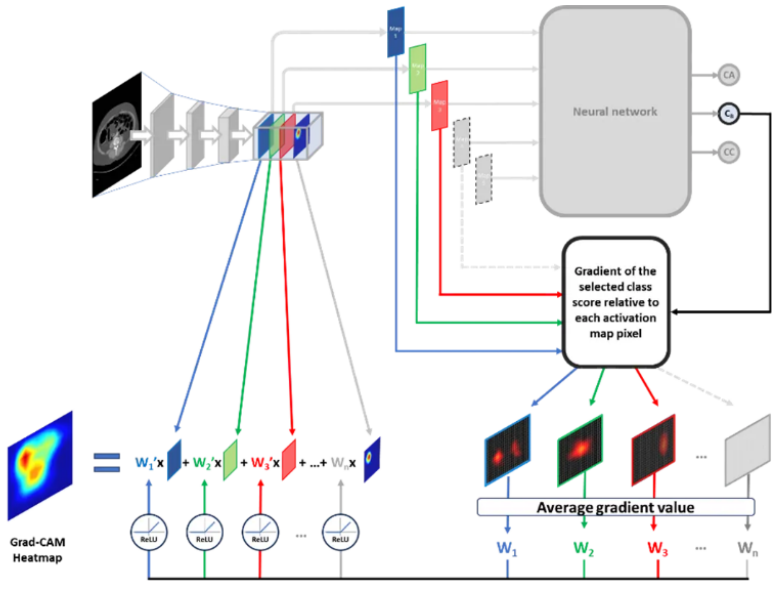

Figura 8: Esquema del funcionamiento de Grad-CAM. A la derecha se calculan los pesos de importancia mediante los gradientes promediados de la clase objetivo, y a la izquierda se realiza la combinación ponderada de los mapas de características y se aplica la función ReLU para obtener el mapa de calor final [79].

La posibilidad de visualizar el razonamiento del modelo resulta especialmente valiosa en el ámbito clínico, donde el desempeño cuantitativo por sí solo no es suficiente para garantizar su utilidad como herramienta de apoyo diagnóstico. En este contexto, las técnicas de interpretabilidad permiten proporcionar información adicional sobre los factores que contribuyen a una predicción, facilitando la comprensión de las decisiones generadas por modelos que, de otro modo, pueden comportarse como sistemas de caja negra. De esta manera, constituyen un complemento cualitativo a las métricas de desempeño, y pueden favorecer la confianza de los profesionales de la salud en su utilización [80].

3 Estado del arte

El *deep learning* ha transformado el diagnóstico médico durante la última década, impulsado por la capacidad de las redes neuronales profundas para aprender representaciones complejas directamente a partir de datos crudos, sin necesidad de ingeniería manual de características. Arquitecturas como las redes convolucionales, las redes recurrentes y, más recientemente, los *Transformers* han demostrado desempeños comparables o superiores a los de especialistas médicos en dominios que incluyen radiología, anatomía patológica, genómica y cardiología, y han comenzado a integrarse en flujos de trabajo clínicos como herramientas de apoyo al diagnóstico [81][82].

3.1 Modelos basados en señales

En el área de cardiología, el ECG constituye uno de los dominios en los que más se ha explorado la aplicación de modelos de aprendizaje profundo, con gran cantidad de trabajos orientados a la detección y clasificación de diversas enfermedades y alteraciones cardiovasculares [9][10]. En particular, la HVI ha sido abordada principalmente como un problema de clasificación binaria, orientado a distinguir entre pacientes con y sin esta alteración. Diversos estudios han empleado redes neuronales convolucionales sobre señales de ECG de 12 derivaciones, demostrando que estos modelos pueden identificar patrones asociados a la presencia de HVI, incluso superando la sensibilidad de los criterios electrocardiográficos convencionales basados en voltaje [83][84].

Sin embargo, la identificación de la causa responsable de la HVI constituye un problema considerablemente más complejo y menos explorado. Uno de los antecedentes más relevantes en este tema es el trabajo de Haimovich et al. [85], quienes desarrollaron LVH-Net, un modelo orientado a diferenciar distintas etiologías asociadas a la HVI, incluyendo HTA, EAo, MCH, Am, entre otras causas menos frecuentes. El modelo utiliza como entrada señales de ECG de 12 derivaciones complementadas con otras variables clínicas como la edad y el sexo. Para su desarrollo, los autores utilizaron como base una red neuronal convolucional preentrenada con aproximadamente 3 millones de ECG, sobre la cual incorporaron un clasificador que fue entrenado utilizando los datos de 34.258 pacientes con las distintas etiologías de HVI consideradas en el estudio. El modelo demostró un buen desempeño, alcanzando valores de AUROC, calculados frente a pacientes sin HVI, de 0,95 para Am, 0,92 para MCH, 0,90 para EAo, 0,76 para HVI hipertensiva, y 0,69 para otras causas.

En conjunto, estos antecedentes muestran que el ECG contiene información suficiente para abordar no solo la identificación de la HVI, sino también la diferenciación de las patologías que pueden originarla. En particular, el desarrollo de LVH-Net demuestra la posibilidad de realizar una clasificación etiológica mediante modelos de aprendizaje profundo, abriendo la posibilidad de continuar explorando soluciones para esta problemática clínica.

3.2 Modelos basados en imágenes

No obstante, en numerosos entornos clínicos el ECG puede encontrarse únicamente como una imagen impresa o digitalizada, sin que se conserve o se disponga de la señal original. En la práctica, estos registros pueden quedar incorporados a la historia clínica como documentos gráficos, lo que limita la aplicación directa de métodos desarrollados para trabajar sobre señales digitales. En este contexto, surge la necesidad de desarrollar herramientas capaces de analizar estas representaciones visuales y aprovechar el formato en el que los registros se encuentran efectivamente disponibles.

Una línea de trabajo ha abordado este problema mediante la extracción de la señal a partir de las imágenes de ECG. Para ello, se han desarrollado métodos basados tanto en técnicas de procesamiento de imágenes como en modelos de aprendizaje profundo, capaces de identificar el trazado dentro de la imagen y reconstruir las señales correspondientes a las distintas derivaciones [86][87][88][89]. Estos métodos han evolucionado desde procedimientos que requieren cierta intervención para identificar las regiones de interés hacia soluciones automatizadas capaces de procesar diferentes configuraciones de ECG y distintos niveles de degradación de la imagen. Los resultados obtenidos muestran que es posible recuperar con elevada precisión la señal original. Algunos trabajos han reportado correlaciones superiores a 0,90 entre las señales reconstruidas y las originales [88], mientras que otros han alcanzado valores cercanos a 0,99 [87]. Trabajos más recientes han extendido estos enfoques a imágenes escaneadas y fotografías de ECG obtenidas en condiciones clínicas reales, utilizando conjuntos de datos de mayor escala [90]. Así, las técnicas de reconstrucción permiten recuperar la señal cuando esta no se encuentra disponible y, posteriormente, aplicar sobre ella modelos de análisis desarrollados originalmente para señales de ECG.

Por otro lado, una alternativa a este procedimiento consiste en utilizar directamente la imagen del ECG como entrada a los modelos de aprendizaje profundo. Aunque este enfoque ha ganado interés creciente, aún constituye un área considerablemente menos explorada que el enfoque basado en señales [91]. En el contexto de las patologías asociadas a la HVI, se han desarrollado modelos capaces de identificar individualmente EAo, Am, HTA y MCH a partir de imágenes de ECG [92][93][94][95]. Estos trabajos han abordado el problema como una clasificación binaria, en la que el modelo debe distinguir entre pacientes con una determinada patología y pacientes que no la presentan. Si bien los estudios difieren considerablemente en cuanto al tamaño de las bases de datos, el tipo de arquitectura y la forma de representación de los registros, los resultados obtenidos muestran que es posible utilizar directamente la representación visual del ECG para identificar patrones asociados a estas enfermedades. En particular, se han reportado precisiones globales de 79,5 % para la detección de EAo [92] y de 93 % para la identificación de Am [93]. Para la detección de HTA, un modelo basado en una arquitectura residual con mecanismos de atención alcanzó un AUROC de 0,80 y una especificidad de 81 % [94]. Por su parte, un modelo desarrollado para la detección de MCH alcanzó un AUROC de 0,95 en la evaluación interna y valores de 0,94, 0,92 y 0,91 en tres conjuntos de validación externa [95].

En conjunto, estos antecedentes muestran que las imágenes de ECG pueden aportar información relevante para la identificación de EAo, Am, HTA y MCH. No obstante, la evidencia disponible se ha centrado en el estudio individual de estas patologías, mientras que este trabajo busca distinguir entre ellas. Esta tarea plantea una dificultad adicional, ya que las distintas etiologías de HVI pueden compartir manifestaciones electrocardiográficas y generar patrones más similares entre sí. Si bien LVH-Net demostró la posibilidad de realizar esta diferenciación a partir de señales digitales de ECG junto con variables clínicas, no se identificaron trabajos que hayan abordado la clasificación multiclase conjunta de las cuatro etiologías consideradas, únicamente a partir de imágenes de ECG. El presente trabajo, entonces, propone cubrir esta brecha mediante el desarrollo de un modelo capaz de realizar esta diferenciación directamente a partir de imágenes de ECG de 12 derivaciones.

4 Materiales y métodos

4.1 Dataset ICBA

Para el desarrollo del presente trabajo se utilizó una base de datos de imágenes de ECG provista por el Instituto Cardiovascular de Buenos Aires, compuesta inicialmente por 821 imágenes. Cada una de ellas se encuentra asociada a un diagnóstico informado por profesionales de la institución y corresponde a una de las etiologías de HVI consideradas: amiloidosis (Am), hipertensión arterial (HTA), estenosis aórtica (EAo) y miocardiopatía hipertrófica (MCH).

Una característica relevante del conjunto de datos, además de su tamaño reducido, es la heterogeneidad en el formato de presentación de los estudios. Si bien todas las imágenes corresponden a electrocardiogramas de 12 derivaciones, difieren en la distribución de las mismas dentro del informe (principalmente 6×2 y 12×1), así como en la orientación del documento exportado. La Figura 9 muestra ejemplos representativos de estas configuraciones.

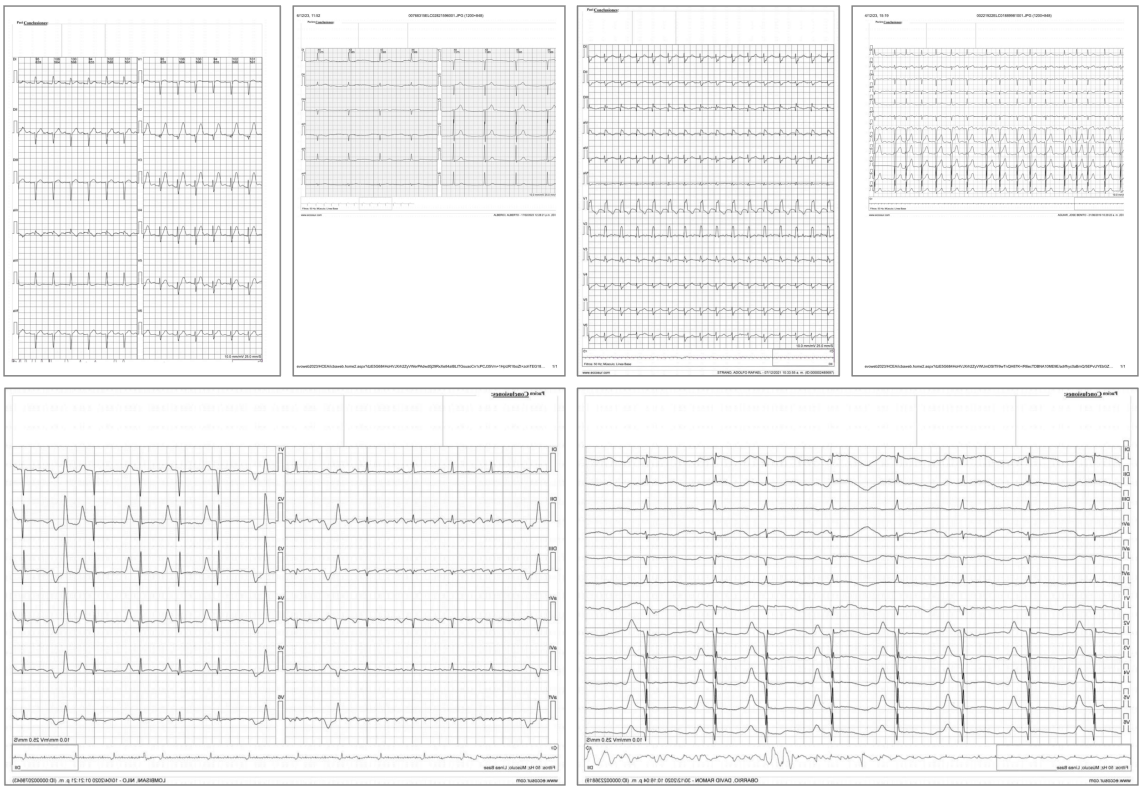

Figura 9: Formatos de presentación de los estudios de ECG presentes en el dataset ICBA. Las imágenes ilustran las distintas disposiciones de las 12 derivaciones (6×2 y 12×1) y las variaciones en la orientación del documento (hoja vertical o horizontal).

Sin embargo, no todos los formatos se encuentran representados de manera uniforme entre las distintas clases diagnósticas. Algunos de ellos aparecen en pocas imágenes o incluso están ausentes para determinadas patologías. La distribución de las imágenes según la clase y el formato de presentación se resume en la Tabla 3.

Tabla 3: Cantidad de imágenes del dataset ICBA según clase diagnóstica y formato de presentación del estudio, considerando la disposición de las derivaciones y la orientación del documento exportado.

Formato	Am	HTA	EAo	MCH	Total
6×2 horizontal (hoja horizontal)	50	18	100	100	268
6×2 horizontal (hoja vertical)	136	160	92	30	418
6×2 vertical (hoja vertical)	36	11	0	5	52
12×1 horizontal (hoja horizontal)	12	1	0	0	13
12×1 horizontal (hoja vertical)	24	8	5	5	42
12×1 vertical (hoja vertical)	6	1	0	3	10
Otros formatos	18	0	0	0	18
Total	**282**	**199**	**197**	**143**	**821**

Esta distribución desigual podría introducir un sesgo durante el entrenamiento, ya que el modelo podría aprender asociaciones entre determinados formatos de presentación y una clase diagnóstica específica, en lugar de basar su decisión en características propias del ECG. Por este motivo, se decidió restringir el estudio únicamente a las imágenes con disposición 6×2 horizontal, independientemente de la orientación de la hoja utilizada para la exportación del documento, ya que esta diferencia de orientación modifica únicamente el tamaño de los márgenes blancos presentes en la imagen, sin alterar la posición de las derivaciones ni el contenido clínico de la señal.

Como resultado de este proceso de selección, el conjunto de datos quedó conformado por un total de 686 imágenes. La Figura 10 muestra la distribución por clase de dicho conjunto final.

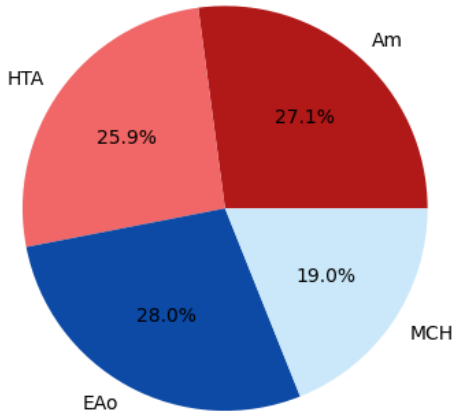

Figura 10: Distribución de las imágenes del dataset ICBA por clase diagnóstica tras la selección de los estudios con formato de presentación 6×2 horizontal.

4.1.1 Unificación del formato de archivo

El subconjunto de imágenes seleccionado estaba compuesto por archivos en tres formatos: PDF (493 imágenes), JPG (191 imágenes) y JPEG (2 imágenes). Con el objetivo de homogeneizar y facilitar el procesamiento posterior, todos los archivos fueron convertidos al formato JPG. Los archivos PDF fueron rasterizados a una resolución de 200 DPI, consistente con la resolución predominante en los archivos JPG ya presentes en el dataset.

Adicionalmente, en cumplimiento con las consideraciones éticas y de privacidad, todos los registros fueron anonimizados mediante el renombrado sistemático de los archivos, eliminando cualquier información personal o identificatoria de los pacientes.

4.1.2 Recorte automático de márgenes

Con el objetivo de eliminar de las imágenes los márgenes blancos, encabezados y pies de página que no contienen información relevante, se implementó una etapa de recorte automático. El procedimiento busca conservar únicamente la región correspondiente a la grilla del electrocardiograma, incluyendo las trazas de las derivaciones, los pulsos de calibración y sus respectivas etiquetas. Dado que los márgenes laterales presentes en el conjunto de datos son considerablemente menores que los márgenes superior e inferior, el recorte se aplica únicamente en la dirección vertical. Este criterio reduce además el riesgo de que un recorte erróneo elimine los pulsos de calibración, ubicados en el margen izquierdo de la imagen.

El algoritmo de recorte se basa en la detección de las líneas de la grilla del ECG, ya que estas se extienden a lo largo de toda la región de interés y permiten estimar de manera confiable los límites de la misma. En una primera etapa, la imagen se procesa mediante el detector de bordes de Canny para obtener un mapa binario de bordes. Sobre este mapa se aplica la Transformada de Hough Probabilística con el fin de identificar segmentos rectos. Para descartar segmentos originados por el trazado del electrocardiograma o por ruido presente en la imagen, se conservan únicamente aquellos cuya longitud supera el 30 % de la altura de la imagen. Posteriormente, se seleccionan los segmentos cuyo ángulo se encuentra entre 85° y 95°, a modo de considerar solo las líneas verticales correspondientes a la estructura de la grilla.

Una vez identificados estos segmentos, los límites superior e inferior del recorte se estiman a partir de la mediana de las coordenadas de los extremos superiores e inferiores de todos los segmentos seleccionados, respectivamente. El empleo de la mediana, en lugar del promedio, aporta robustez frente a segmentos detectados incorrectamente, ya que la gran cantidad de líneas presentes en la grilla hace que unos pocos valores atípicos no modifiquen significativamente la posición final de los límites.

La Figura 11 muestra un ejemplo del proceso de recorte automático aplicado sobre una imagen perteneciente al dataset.

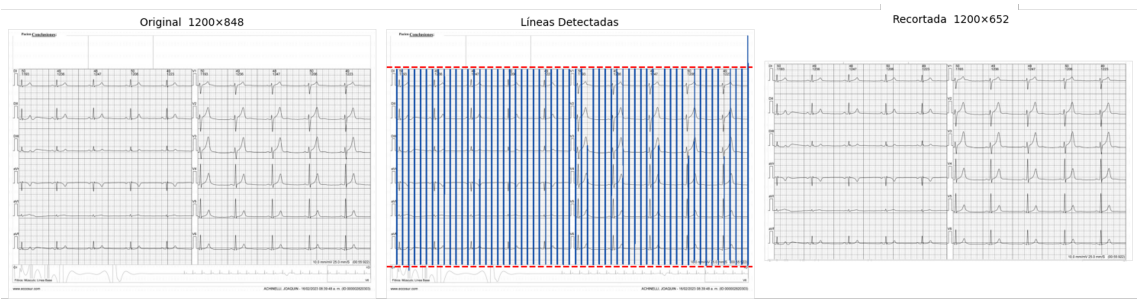

Figura 11: Recorte automático de imagen. La columna izquierda muestra la imagen original, la columna central los segmentos verticales detectados por la Transformada de Hough (resaltados en azul) junto con los límites de recorte superior e inferior (líneas rojas punteadas), y la columna derecha la imagen resultante tras el recorte.

La inspección visual de las imágenes recortadas confirmó que la región de interés fue delimitada correctamente en todos los casos. En consecuencia, se consideró que el procedimiento de recorte fue satisfactorio para el dataset completo, obteniéndose un conjunto de imágenes libre de márgenes, encabezados y pies de página, conservando únicamente la información relevante para el entrenamiento de los modelos.

4.1.3 Redimensionamiento

El entrenamiento de CNNs requiere que todas las imágenes de entrada posean las mismas dimensiones. En consecuencia, fue necesario definir una estrategia de redimensionamiento que permitiera reducir el costo computacional del entrenamiento, seleccionando el menor tamaño de imagen posible sin causar la pérdida de información diagnósticamente relevante.

Una práctica ampliamente extendida en visión computacional consiste en utilizar imágenes de dimensiones cuadradas como entrada a los modelos. Si bien las operaciones de convolución no requieren que las dimensiones espaciales de la entrada sean iguales, muchas arquitecturas más difundidas de clasificación de imágenes fueron diseñadas y preentrenadas utilizando imágenes en este formato [96]. Por este motivo, se consideró este formato como primera alternativa para estandarizar las dimensiones de las imágenes de entrada.

Para evaluar el impacto de este tipo de redimensionamiento, se comparó visualmente una misma imagen representada en distintos tamaños cuadrados, tal como se muestra en la Figura 12. Como es de esperarse, se puede observar una pérdida progresiva de resolución conforme disminuyen las dimensiones de la imagen.

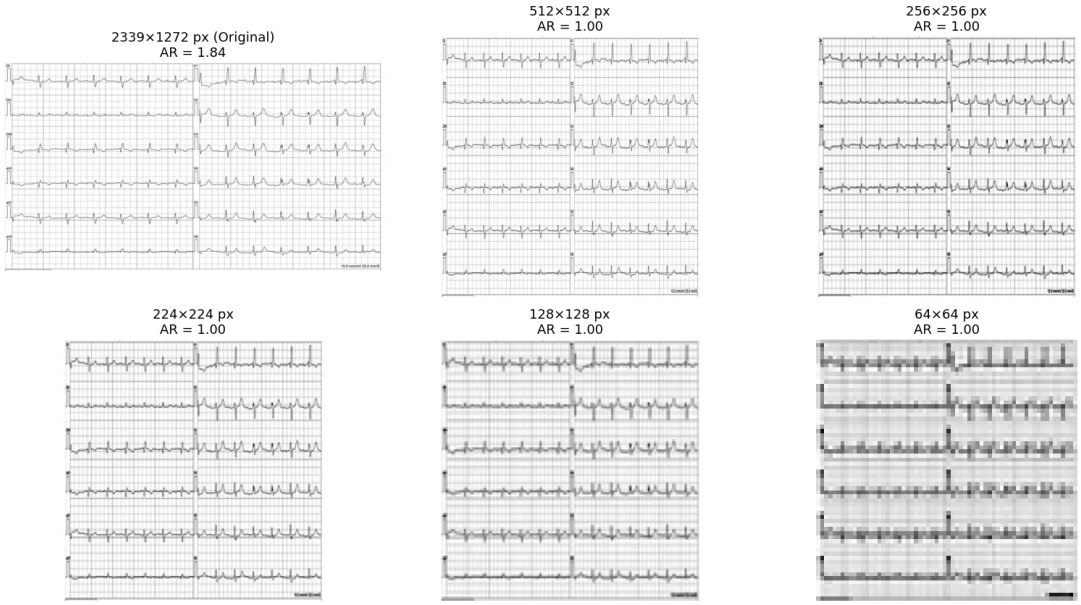

Figura 12: Comparación visual del redimensionamiento de una imagen de ECG a distintos tamaños cuadrados, respecto de la imagen original.

Sin embargo, las imágenes de ECG poseen una estructura naturalmente rectangular, asociada a la disposición de las derivaciones y a la representación temporal del trazado. Forzar su redimensionamiento a un formato cuadrado podría introducir una distorsión de la señal que dificulte la identificación de características diagnósticamente relevantes, como la duración del complejo QRS o el segmento ST. Por este motivo, se optó por emplear un redimensionamiento rectangular que preservara, en la mayor medida posible, la relación de aspecto original (AR) de las imágenes. De esta manera, las características espaciales y temporales del trazado se mantienen proporcionalmente representadas, independientemente de las dimensiones de la imagen.

Además, se consideraron únicamente tamaños cuyas dimensiones fueran múltiplos de 32, en concordancia con los factores de reducción espacial empleados por la mayoría de las arquitecturas convolucionales modernas [97][98][99]. Esta elección permite mantener dimensiones compatibles

con las sucesivas operaciones de reducción espacial de las redes, evitando ajustes adicionales de las dimensiones o la incorporación de *padding* durante el procesamiento.

En la Figura 13 se presenta una comparación visual de una misma imagen de ECG redimensionada a distintas resoluciones rectangulares.

Figura 13: Comparación visual del redimensionamiento de una imagen de ECG a distintos tamaños rectangulares, respecto de la imagen original.

De las resoluciones evaluadas, 352 × 192 y 416 × 224 píxeles (ancho × alto) presentaron las relaciones de aspecto más cercanas a la media del conjunto de imágenes del ICBA tras el recorte automático (AR=1,845). Dado que la resolución superior no presentó una mejora visual significativa que justificara el incremento en el consumo de memoria y el tiempo de entrenamiento, se optó finalmente por redimensionar las imágenes a 352 × 192 píxeles.

4.2 Construcción de Dataset Sintético

El dataset del ICBA, conformado por 686 imágenes, resulta insuficiente para entrenar modelos de *deep learning*, lo que motiva la búsqueda de fuentes de datos externas que permitan complementarlo. Sin embargo, la disponibilidad de bases de datos públicas de imágenes de ECG de 12 derivaciones es muy limitada. En particular, no se encontraron datasets que incluyeran simultáneamente las cuatro patologías abordadas en este trabajo. Asimismo, tampoco existen datasets de imágenes disponibles con un formato lo suficientemente similar al de los estudios provistos por el ICBA, lo que impide complementar directamente el entrenamiento con datos externos.

Ante esta limitación, se decidió construir un dataset de imágenes de ECG de 12 derivaciones a partir de señales de acceso público. Las imágenes generadas fueron diseñadas para reproducir el formato visual de los estudios del ICBA, con el propósito de proporcionar una etapa de preentrenamiento previa al ajuste fino sobre el dataset objetivo. De esta manera, los modelos pueden aprender representaciones específicas de imágenes electrocardiográficas para luego ser ajustados a las imágenes provistas por la institución. Cabe destacar que, si bien las imágenes del dataset fueron generadas artificialmente, las señales electrocardiográficas utilizadas como base corresponden a registros reales de ECG. Por lo tanto, el carácter sintético del dataset se refiere a la generación de la representación visual y no a la naturaleza de las señales utilizadas como entrada.

4.2.1 Fuentes de señales

Se utilizaron cuatro bases de datos públicas de señales de ECG de 12 derivaciones: PTB-XL [100], CPSC-2018 [101], Chapman-Shaoxing [102] y Georgia ECG Challenge [103]. Las tres últimas se obtuvieron a partir de los datos publicados para el PhysioNet/Computing in Cardiology Challenge 2021. La cantidad de registros aportados por cada fuente se resume en la Tabla 4. En conjunto, se recopiló un total de 52.720 registros.

Tabla 4: Cantidad de registros de ECG de 12 derivaciones recopilados según cada dataset público de señales.

Dataset	Señales
PTB-XL	21.799
CPSC-2018	10.330
Georgia ECG Challenge	10.344
Chapman-Shaoxing	10.247
Total	**52.720**

4.2.2 Remapeo de etiquetas

Las señales de los datasets elegidos no están clasificadas de acuerdo con el esquema de categorías requerido para este trabajo. En estos datasets, cada señal está anotada con uno o más códigos que describen hallazgos eléctricos del electrocardiograma. Algunos corresponden a diagnósticos patológicos concretos (como fibrilación auricular, bloqueos de rama o hipertrofia ventricular), mientras que otros son descriptores morfológicos del trazado (como desviación del eje eléctrico, alteraciones de la onda T o variaciones del voltaje del QRS) que no implican necesariamente una patología específica. Además, las distintas fuentes emplean diferentes esquemas de codificación: PTB-XL utiliza códigos diagnósticos propios definidos por sus autores [100], mientras que los otros datasets emplean SNOMED CT, un estándar internacional de terminología clínica [104]. Por lo tanto, para construir un dataset apto para el preentrenamiento fue necesario, por un lado, unificar estos esquemas de etiquetado heterogéneos y, por otro, transformar el problema multi-etiqueta en una clasificación multiclase donde cada señal quede asociada a una única categoría.

Para llevar esto a cabo, todas las etiquetas originales se remapearon a un esquema común. Se adoptó el sistema de clasificación en superclases propuesto por PTB-XL, ilustrado en la Figura 14. Este agrupa los diagnósticos en cinco categorías: normal (NORM), trastornos de conducción (CD), infarto de miocardio (MI), hipertrofias (HYP) y alteraciones de la repolarización (STTC).

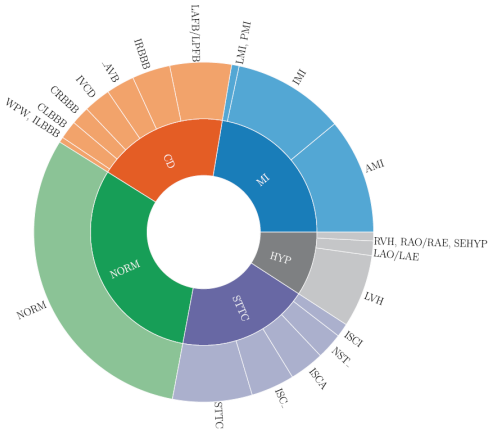

Figura 14: Esquema jerárquico de superclases diagnósticas del dataset PTB-XL, adoptado como referencia para el proceso de remapeo de etiquetas [100].

Para establecer la correspondencia entre los códigos SNOMED y las superclases, primero fue necesario determinar qué diagnósticos y categorías clínicas se encontraban incluidos en cada una de estas últimas. Para ello, se revisaron las distintas etiquetas diagnósticas presentes en PTB-XL junto con la asignación de superclase y subclase proporcionada por sus autores, obteniendo así un listado de las patologías que componen cada categoría. En la Tabla A.1 del Anexo A se detalla este listado.

A partir de esta referencia, se realizó el remapeo asignando una superclase a cada código SNOMED CT presente en los demás datasets, verificando previamente su significado clínico en el navegador oficial [105]. Así, se le asignó una superclase a aquellos códigos que:

- Presentan coincidencia exacta con los diagnósticos del esquema de referencia.
- Representan el mismo fenómeno fisiopatológico bajo una denominación diferente.
- Corresponden a una categoría clínica más general pero equivalente desde el punto de vista diagnóstico.

Por el contrario, no se le asignó ninguna superclase a los códigos que:

- No representan un diagnóstico clínico específico.
- Corresponden a descriptores morfológicos aislados o condiciones técnicas del registro.
- Refieren a hallazgos inespecíficos o ambiguos que no pueden asociarse de manera unívoca a una superclase.

De esta manera, cada código SNOMED CT utilizado en los datasets quedó asociado a una única superclase o bien sin correspondencia dentro del esquema de referencia. Esta distinción permitió separar las etiquetas que aportaban información diagnóstica suficiente para definir una categoría de aquellas que, por su naturaleza o falta de especificidad, no permitían realizar una asignación confiable. Esta decisión tuvo el propósito de mantener la coherencia clínica de las categorías, evitando así la introducción de ruido en el proceso de entrenamiento. El mapeo completo de todos los códigos SNOMED CT, incluyendo aquellos a los que no se les asignó ninguna superclase, se presenta en la Tabla A.2 del Anexo A.

Una vez determinada la correspondencia de cada código individual, fue necesario establecer la categoría final de cada señal. Dado que inicialmente cada una de ellas podía presentar múltiples etiquetas SNOMED CT, después del remapeo una señal podría haber quedado asociada a una o más superclases, o a ninguna de ellas cuando ninguna de sus etiquetas pudo ser mapeada. Entonces, para obtener un conjunto de señales con el esquema multiclase deseado, se aplicaron los siguientes criterios de selección:

- Si la señal queda asociada a **una única superclase**, se conserva con esa categoría. Esto ocurre cuando todas las etiquetas remapeadas corresponden a la misma superclase, independientemente de que algunas etiquetas originales no hayan podido ser remapeadas.
- Si la señal no queda asociada a **ninguna superclase** (*sin mapeo*), se descarta, ya que no es posible asignarle una categoría diagnóstica.
- Si la señal queda asociada a **dos o más superclases** diferentes (*multiclase*), se descarta por presentar una asignación diagnóstica ambigua.

Adicionalmente, se excluyeron las señales con una duración inferior a 6 segundos, ya que este umbral corresponde al mínimo de tiempo necesario para generar imágenes con el formato 6×2 utilizado en el dataset ICBA. La aplicación de todos estos criterios redujo el conjunto de datos de 52.720 señales originales a 34.192, conservando el 64,9 % del total.

4.2.3 Generación de imágenes

Como punto de partida, se tomó una imagen representativa del dataset del ICBA como referencia visual para identificar los elementos que debía replicar cada imagen sintética: fondo blanco con grilla en tonos grises, doce derivaciones organizadas en dos columnas de seis filas cada una, pulsos de calibración al inicio de cada señal junto con las etiquetas de derivación, e indicación de escala en la esquina inferior derecha. Algunos estudios presentan adicionalmente anotaciones numéricas sobre cada complejo QRS, correspondientes al valor de la frecuencia cardíaca instantánea y a la duración del intervalo RR. Estas no fueron incorporadas en las imágenes sintéticas dado que no están presentes en la totalidad de las imágenes del dataset y su inclusión habría incrementado significativamente la complejidad del proceso. A su vez, tampoco se replicaron las anotaciones presentes en los márgenes de la hoja ni la tira de ritmo extendida en la parte inferior, dado que ambos elementos son eliminados durante el proceso de recorte automático.

Además de reproducir los elementos visuales del ECG, se buscó conservar la escala física del trazado, de modo que las dimensiones de la grilla y las señales mantuvieran correspondencia entre sí. Por este motivo, el diseño se realizó con Matplotlib utilizando milímetros como unidad de medida para ubicar los distintos elementos. La resolución de las imágenes finales se estableció en 200 DPI, en concordancia con la resolución adoptada por la mayoría de las imágenes del dataset ICBA.

El proceso de generación de cada imagen se organizó en tres etapas:

1. **Construcción del fondo:** Se define la geometría de la hoja en coordenadas físicas y se dibuja la grilla del papel milimetrado, superponiendo tres niveles de grosor de línea para las divisiones de 1 mm, 5 mm y 25 mm, representadas además con distintos tonos de gris. Se incorpora también un borde perimetral que delimita el área de la grilla y el texto con la escala de amplitud y tiempo en la esquina inferior derecha.
2. **Elementos de referencia:** Se dibujan los pulsos de calibración y las etiquetas de las derivaciones. Los pulsos tienen una altura de 10 mm (equivalente a 1 mV) y un ancho de 2,5 mm (equivalente a 0,1 s), de acuerdo con el estándar de registro electrocardiográfico. Las etiquetas se ubican inmediatamente encima de dichos pulsos.
3. **Trazado de las señales:** Se grafican las doce derivaciones sobre la grilla, distribuyendo seis en la columna izquierda y las restantes en la derecha. Cada señal se transforma a coordenadas físicas aplicando las escalas estándar de registro (25 mm/s y 10 mm/mV).

La Figura 15 presenta una comparación visual entre una imagen de referencia del ICBA y una imagen sintética generada con este procedimiento. Cabe destacar que ambas corresponden a registros electrocardiográficos distintos.

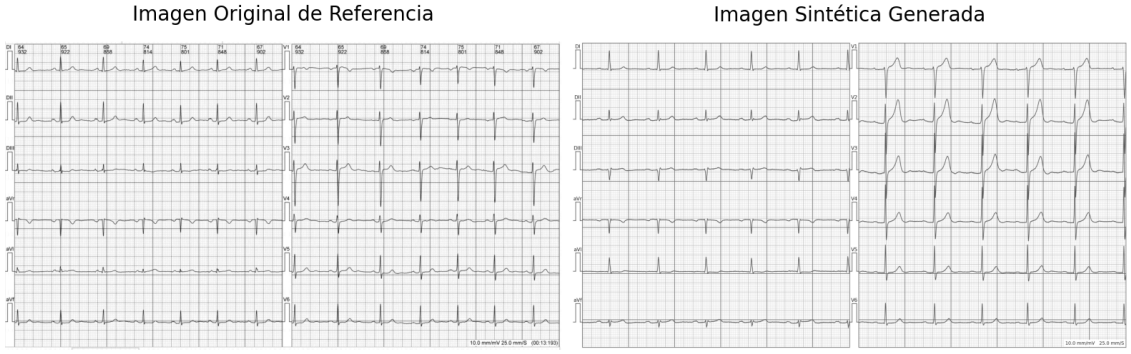

Figura 15: Comparación visual entre una imagen del dataset ICBA utilizada como referencia (izquierda) y una imagen sintética generada (derecha).

Además, con el fin de introducir cierta variabilidad en las dimensiones de las imágenes sintéticas, el margen vertical se seleccionó aleatoriamente en cada imagen dentro del intervalo [1,0 ; 2,5] mm, mientras que el margen lateral se fijó en 1 mm. De este modo, las imágenes generadas presentan pequeñas variaciones, similares a las observadas en el dataset del ICBA tras el recorte automático.

4.2.4 Partición y composición final del dataset

Una vez definido el proceso de generación de imágenes, este se aplicó de manera sistemática sobre el conjunto completo de señales previamente seleccionadas.

Para garantizar la reproducibilidad del proceso y evitar *data leakage*, la partición se realizó a nivel de señal antes de la generación, de modo que todas las imágenes derivadas de una misma señal pertenecieran siempre al mismo subconjunto. La partición se realizó de forma estratificada considerando simultáneamente la superclase diagnóstica y el dataset de origen. El 85 % de las señales se destinó al desarrollo del modelo. De este subconjunto, el 80 % se asignó al entrenamiento y el 20 % a la validación. El 15 % restante de las señales quedó reservado para evaluación. Como resultado, la partición final fue de aproximadamente 68 %, 17 % y 15 % para los conjuntos de entrenamiento, validación y prueba, respectivamente.

Además, con el objetivo de aprovechar al máximo las señales disponibles y maximizar el volumen de imágenes obtenidas, los registros cuya duración supera los 9,86 segundos se utilizaron para generar dos imágenes independientes, la primera a partir del inicio de la señal y la segunda a partir del final. Este umbral de tiempo garantiza una superposición máxima del 30 % entre ambos segmentos, limitando la redundancia entre las imágenes resultantes. Por su parte, los registros más cortos producen una única imagen. De este modo, se busca armar con los recursos disponibles un dataset propio de imágenes de ECG lo suficientemente amplio como para servir de base para el entrenamiento de los clasificadores.

El proceso completo produjo un total de 68.379 imágenes: 46.497 de entrenamiento, 11.624 para validación y 10.258 de prueba. La distribución por clase resultante fue: NORM (38,5 %), STTC (28,4 %), CD (17,7 %), MI (9,8 %) e HYP (5,6 %). La Figura 16 muestra esta distribución por clase diagnóstica y dataset de origen en cada subconjunto. Se observa que las proporciones relativas entre clases se mantienen consistentes respecto a la distribución original de señales, lo que confirma que la división de registros largos en dos imágenes no introdujo sesgos en la composición del dataset.

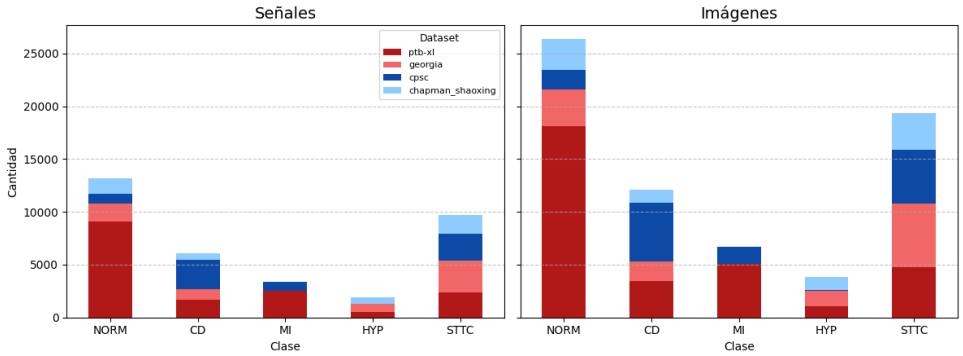

Figura 16: Distribución por clase diagnóstica y dataset de origen para el conjunto de señales seleccionadas tras el remapeo (izquierda) y el conjunto de imágenes sintéticas generadas a partir de ellas (derecha).

Finalmente, todas las imágenes generadas fueron redimensionadas a 352 × 192 píxeles, en concordancia con el procesamiento aplicado al dataset ICBA.

4.3 Selección de arquitecturas de red

Definidos los conjuntos de datos, el siguiente paso consistió en seleccionar las arquitecturas de los modelos a evaluar. Esta elección estuvo condicionada principalmente por el volumen reducido de imágenes disponibles. Si bien la incorporación del dataset sintético permite ampliar el volumen de datos utilizados durante el entrenamiento, la cantidad de imágenes del conjunto objetivo continúa siendo reducida en comparación con la requerida habitualmente por arquitecturas de alta complejidad entrenadas desde cero.

En este contexto, se planteó explorar dos estrategias. Por un lado, diseñar arquitecturas convolucionales de estructura simple y menor escala, que pudieran entrenarse desde cero. Por otro lado, utilizar arquitecturas de mayor complejidad con pesos preentrenados en grandes conjuntos de imágenes, lo que permite aplicar *transfer learning* y evaluar si, en este caso, las representaciones visuales previamente aprendidas contribuyen a compensar la escasez de datos clínicos.

4.3.1 Modelos entrenados desde cero

a. Red convolucional plana

Para la primera arquitectura, denominada CNN-A, se adoptó un diseño de red convolucional secuencial, en el que los datos fluyen por un único camino de entrada a salida sin conexiones entre capas no adyacentes. La Figura 17 ilustra esquemáticamente su estructura.

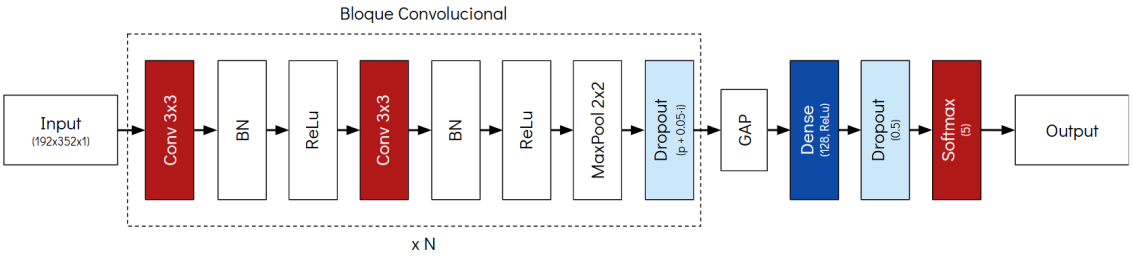

Figura 17: Esquema de la arquitectura de CNN-A (red convolucional plana).

La red se organiza en N bloques convolucionales apilados secuencialmente, seguidos de una cabeza clasificadora. Cada bloque está compuesto por dos capas convolucionales con filtros de tamaño 3×3, cada una seguida de una capa de *Batch Normalization* (BN) y una función de activación ReLU. La utilización de dos capas convolucionales consecutivas permite extraer características de manera progresiva empleando filtros de pequeño tamaño. El número de filtros se duplica en cada bloque, incrementando la capacidad de representación de la red a medida que disminuye la resolución espacial de los mapas de características.

Al final de cada bloque se aplica una capa de *MaxPooling* de 2×2, que reduce a la mitad las dimensiones espaciales de los mapas de características y disminuye el costo computacional de las capas posteriores. Luego, se incorpora una capa de *Dropout* como mecanismo de regularización. La tasa de *Dropout* aumenta progresivamente con la profundidad de la red, con el objetivo de reducir el riesgo de sobreajuste en las capas más profundas. Para ello, se define una tasa inicial para el primer bloque, que se incrementa en 0,05 en cada bloque siguiente hasta un máximo de 0,4.

Posterior a la extracción de características, se incorpora una capa de *Global Average Pooling* (GAP), la cual reemplaza el uso de una capa *Flatten*. En lugar de transformar todos los mapas de características en un único vector de gran dimensionalidad, GAP calcula el promedio espacial de cada mapa, generando una representación compacta. Esta estrategia reduce significativamente el número de parámetros de la cabeza clasificadora y contribuye a disminuir el riesgo de sobreajuste del modelo [106].

Finalmente, la cabeza clasificadora se compone de una capa densa de 128 neuronas con activación ReLU, seguida de una capa de *Dropout* con tasa 0,5. La capa de salida posee un número de neuronas igual a la cantidad de clases diagnósticas consideradas en cada fase de entrenamiento, con activación *softmax*.

b. Red convolucional residual

La segunda arquitectura, denominada CNN-B, mantiene la estructura general de CNN-A, pero incorpora conexiones residuales dentro de cada bloque convolucional, inspiradas en la arquitectura ResNet. La Figura 18 muestra su estructura general.

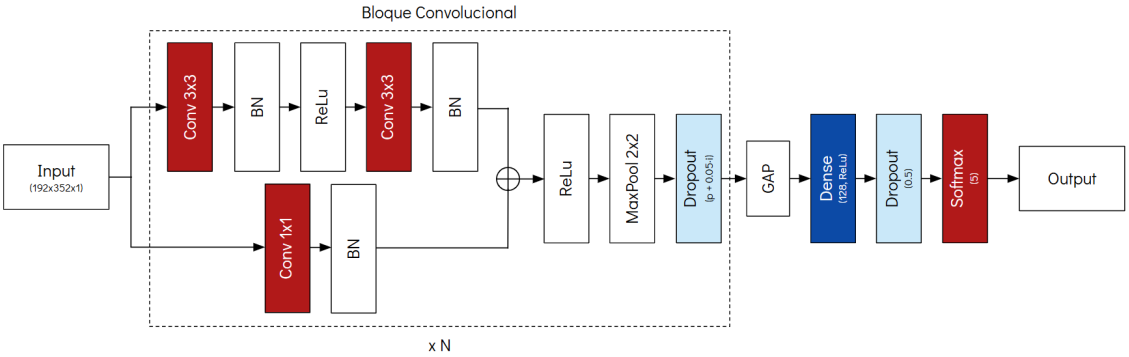

Figura 18: Esquema de la arquitectura de CNN-B (red convolucional residual).

Cada bloque también está formado por dos capas convolucionales de tamaño 3×3, cada una seguida de *Batch Normalization*. La conexión residual suma la entrada del bloque directamente a la salida de la segunda convolución, antes de aplicar la activación ReLU. Dado que el número de filtros se duplica en cada bloque, la rama residual se adapta mediante una convolución 1×1, seguida de *Batch Normalization*, de modo que ambas representaciones tengan dimensiones compatibles para realizar la suma. Esta estrategia permite que cada bloque aprenda una representación residual respecto de su entrada, en lugar de una transformación completamente nueva. Además, durante el entrenamiento, la conexión residual proporciona un camino directo para la propagación de los gradientes hacia las capas anteriores, mitigando el problema de desaparición del gradiente y facilitando el entrenamiento de redes más profundas [97].

Al igual que en CNN-A, cada bloque finaliza con una capa de *MaxPooling* de tamaño 2×2 y una capa de *Dropout*, cuya tasa aumenta progresivamente con la profundidad de la red. La etapa de extracción de características concluye con una capa de *Global Average Pooling*, seguida de una cabeza clasificadora idéntica a la de la CNN propuesta anteriormente.

4.3.2 Modelos preentrenados

Se seleccionaron tres arquitecturas representativas de distintas generaciones y enfoques en el diseño de redes convolucionales: ResNet50 [97], EfficientNetB0 [99] y ConvNeXtTiny [107]. La elección buscó abarcar un rango temporal y arquitectónico diverso, incluyendo tanto modelos consolidados como arquitecturas de desarrollo más reciente.

Los tres modelos se encuentran disponibles en Keras con pesos preentrenados en ImageNet-1k, que contiene aproximadamente 1,28 millones de imágenes naturales. En todos los casos se reemplazó la cabeza clasificadora original por una propia compuesta por una capa de *Global Average Pooling*, una capa densa con activación ReLU, una capa de *Dropout* con tasa 0,5 y una capa de salida con activación *softmax*.

a. ResNet50

ResNet50 es una arquitectura convolucional de 50 capas organizada en cuatro etapas de bloques residuales. Cada bloque utiliza una estructura de *bottleneck*, compuesta por tres convoluciones (1×1, 3×3 y 1×1), junto con una conexión residual que permite sumar la representación de entrada a la salida de las convoluciones [97].

ResNet50 cuenta con aproximadamente 25 millones de parámetros y es la variante de menor profundidad de la familia ResNet original que emplea bloques con estructura *bottleneck*, en contraste con los bloques básicos utilizados en ResNet18 y ResNet34. Su inclusión en el análisis permite incorporar a la comparación una arquitectura convolucional consolidada y ampliamente estudiada, que constituye una referencia habitual en tareas de visión por computadora y ha sido ampliamente utilizada en la clasificación de imágenes médicas [108].

b. EfficientNetB0

EfficientNetB0 es una arquitectura convolucional diseñada para lograr un buen equilibrio entre capacidad de representación y costo computacional. Su estructura fue obtenida mediante una búsqueda automática de arquitecturas y emplea convoluciones de bajo costo computacional, lo que le permite mantener una cantidad reducida de parámetros. Constituye el modelo base de la familia EfficientNet, a partir del cual se obtienen variantes de mayor tamaño mediante un esquema de escalado compuesto [99].

EfficientNetB0 cuenta con aproximadamente 5 millones de parámetros, siendo la arquitectura más compacta de la familia EfficientNet. Su inclusión en el análisis permite evaluar si una arquitectura con menor cantidad de parámetros resulta ventajosa en un escenario caracterizado por una disponibilidad limitada de datos clínicos.

c. ConvNeXtTiny

ConvNeXtTiny es una arquitectura convolucional desarrollada a partir de una revisión de los diseños tradicionales de las CNN a la luz de los avances introducidos por los *transformers* visuales. Su estructura se organiza en cuatro etapas, compuestas por 3, 3, 9 y 3 bloques, respectivamente. A medida que se avanza entre las etapas, la resolución espacial de las representaciones se reduce progresivamente, mientras aumenta el número de canales. Los bloques utilizan convoluciones en profundidad de tamaño 7×7, seguidas de normalización por capa y dos capas convolucionales 1×1 con una función de activación GELU entre ellas. Estas modificaciones permiten modernizar la estructura de las CNN manteniendo el carácter convolucional [107].

ConvNeXtTiny es la variante más pequeña de la familia ConvNeXt y cuenta con aproximadamente 28 millones de parámetros. Su inclusión en el análisis permite incorporar una arquitectura convolucional de desarrollo más reciente y evaluar si los enfoques modernos de diseño presentan ventajas frente a arquitecturas clásicas más consolidadas y estudiadas.

4.4 Entrenamiento de modelos

4.4.1 Entorno de desarrollo

El entrenamiento de todos los modelos se realizó en un servidor remoto, al que se accedió mediante SSH. El servidor cuenta con una GPU NVIDIA Quadro RTX 8000 con 48 GB de memoria de video y 8 GB de RAM disponible. Los experimentos se ejecutaron en un entorno Conda dedicado sobre Arch Linux, utilizando Python 3.11.15. Las versiones de las principales librerías de Python utilizadas se detallan en la Tabla 5. Para el procesamiento en GPU se emplearon CUDA 13.3 y cuDNN 9.20.0.

Tabla 5: Versiones de las principales librerías de Python empleadas en el código de entrenamiento.

Librería	**Versión**
TensorFlow	2.21.0
Keras	3.14.1
Optuna	4.8.0
scikit-learn	1.8.0
Pillow	12.2.0
NumPy	2.4.6
Pandas	3.0.3

4.4.2 Configuración general del entrenamiento

a. Búsqueda de hiperparámetros

La selección de hiperparámetros se realizó de manera independiente en cada experimento, según la arquitectura del modelo y el conjunto de datos utilizado. De esta manera, se buscó determinar la configuración que permitiera obtener el mejor desempeño bajo las condiciones específicas de cada caso en particular.

La búsqueda se llevó a cabo mediante Optuna [109], un marco de optimización de hiperparámetros que permite evaluar sucesivas configuraciones mediante *trials* independientes. Para determinar las configuraciones a evaluar, se empleó un muestreador TPE (*Tree-structured Parzen Estimator*), el cual propone automáticamente nuevas configuraciones a partir del desempeño observado en los *trials* anteriores. De esta manera, las evaluaciones previas permiten realizar propuestas cada vez más informadas y orientar progresivamente la búsqueda hacia regiones del espacio de hiperparámetros asociadas con un mejor desempeño.

La función objetivo utilizada para comparar las configuraciones se definió a partir de la pérdida de validación (*val_loss*), ya que constituye una medida continua del desempeño del modelo y tiene en cuenta no solo si la predicción es correcta, sino también la confianza asociada a la predicción. Esto proporciona una señal más informativa durante el proceso de optimización que una métrica discreta como la *accuracy*.

b. Reproducibilidad

Con el objetivo de favorecer la reproducibilidad de los experimentos, se fijó una semilla global (`SEED = 42`) para los distintos componentes estocásticos del entrenamiento y de la búsqueda de hiperparámetros, incluido el muestreador TPE. Además, se configuró el entorno de desarrollo para utilizar operaciones deterministas en GPU. Asimismo, el conjunto de datos de entrenamiento y validación se volvió a instanciar en cada *trial*, de manera que el estado del *shuffle* se reiniciara en cada evaluación y todas las configuraciones recibieran las imágenes en el mismo orden. De esta forma, se buscó reducir la variabilidad asociada al orden de presentación de los datos, la inicialización de los pesos y otras fuentes de aleatoriedad del entrenamiento.

c. Mecanismos de control del entrenamiento

En todos los experimentos se emplearon tres mecanismos comunes para controlar el proceso de entrenamiento y la búsqueda de hiperparámetros. La Tabla 6 resume la configuración de parámetros utilizada en cada uno de ellos.

El *EarlyStopping* interrumpe el entrenamiento cuando la *val_loss* deja de mejorar durante un número determinado de épocas y restaura los pesos correspondientes a la mejor época alcanzada. Por su parte, *ReduceLROnPlateau* reduce a la mitad la tasa de aprendizaje cuando la pérdida de validación permanece sin mejorar durante un período determinado. Su menor paciencia respecto de *EarlyStopping* permite reducir previamente la tasa de aprendizaje y dar al modelo una oportunidad adicional de mejorar antes de interrumpir el entrenamiento.

A nivel de la búsqueda de hiperparámetros, se empleó *MedianPruner*, perteneciente a Optuna, que permite detener anticipadamente aquellos *trials* cuyo desempeño intermedio resulta poco prometedor en comparación con los *trials* previamente completados. En particular, el criterio se basó en la comparación de la *val_loss* intermedia con la mediana observada, evitando continuar evaluaciones que difícilmente alcanzarían un desempeño competitivo y reduciendo así el costo computacional y tiempo de la búsqueda.

Tabla 6: Configuración de los mecanismos de control del entrenamiento y de la búsqueda de hiperparámetros.

Mecanismo	**Parámetro**	**Valor**
EarlyStopping	`monitor`	*val_loss*
	`patience`	8
	`min_delta`	10^{-4}
	`restore_best_weights`	*True*
ReduceLROnPlateau	`monitor`	*val_loss*
	`factor`	0,5
	`patience`	5
	`min_delta`	10^{-4}
	`min_lr`	10^{-7}
MedianPruner	`n_startup_trials`	8
	`n_warmup_steps`	10
	`interval_steps`	1
	`n_min_trials`	3

4.4.3 Preentrenamiento en imágenes sintéticas

Como primera etapa del entrenamiento, las cinco arquitecturas candidatas se entrenaron sobre el conjunto de imágenes sintéticas en la tarea de clasificar imágenes de ECG en una de las cinco superclases diagnósticas: CD, HYP, MI, NORM y STTC. Dado que los modelos propios y los modelos preentrenados parten de condiciones diferentes y requieren estrategias de entrenamiento distintas, los hiperparámetros a optimizar difirieron entre ambos.

En el caso de los modelos propios (CNN-A y CNN-B), los pesos se inicializaron aleatoriamente y se entrenaron completamente desde cero. Por este motivo, la búsqueda de hiperparámetros incluyó tanto decisiones arquitectónicas, como el número de bloques y la cantidad de filtros iniciales, así como también parámetros de regularización y optimización, tales como el *dropout* y la tasa de aprendizaje.

En cambio, los modelos preentrenados en ImageNet (ResNet50, EfficientNetB0 y ConvNeXt-Tiny) parten de pesos ajustados previamente a partir de imágenes naturales, por lo que se empleó una estrategia de adaptación progresiva mediante el protocolo LP-FT (*Linear Probing + Fine-Tuning*) [110]. Durante la etapa LP, el *backbone* permanece completamente congelado y se entrena únicamente la cabeza clasificadora durante 10 épocas, con una tasa de aprendizaje de 10^{-3}. Esto permite que la cabeza clasificadora se adapte a la nueva tarea antes de comenzar el ajuste fino, evitando que sus pesos aleatorios degraden las representaciones preentrenadas. Luego, en la etapa FT, se descongelan los últimos bloques del *backbone* y se continúa el entrenamiento de manera conjunta con la cabeza clasificadora, utilizando una tasa de aprendizaje menor. A partir de esto, la búsqueda de hiperparámetros se concentró en la configuración de la cabeza clasificadora, la cantidad de bloques del *backbone* a descongelar durante FT y la tasa de aprendizaje de esta etapa, mientras que la duración y la tasa de aprendizaje de LP se mantuvieron fijas.

En cuanto al optimizador, las arquitecturas propias se entrenaron con Adam [111], una opción habitual para redes de menor tamaño entrenadas desde cero. Para los modelos preentrenados, en cambio, se utilizó AdamW [112], que incorpora un término de decaimiento de pesos (*weight decay*) como mecanismo adicional de regularización. Esta elección se debe a que dichos modelos poseen, en

general, una cantidad de parámetros considerablemente mayor y se ajustan a partir de un volumen reducido de datos, lo que incrementa el riesgo de sobreajuste. Además, AdamW es ampliamente utilizado en el ajuste fino de modelos preentrenados y fue, por ejemplo, el optimizador empleado en el entrenamiento original de ConvNeXt [107].

La Tabla 7 presenta los hiperparámetros que fueron optimizados mediante Optuna y aquellos que fueron definidos explícitamente. No se incluyen los parámetros internos propios de las arquitecturas preentrenadas que permanecieron sin modificaciones respecto de su configuración original. La cantidad de *trials* de Optuna se estableció en función de las características de cada espacio de búsqueda, utilizando un menor número para los modelos preentrenados, debido a que estos requerían explorar un conjunto más reducido de configuraciones.

Tabla 7: Configuración de hiperparámetros utilizada durante el preentrenamiento sobre el dataset sintético.

Hiperparámetro	**Modelos propios**	**Modelos preentrenados**
Número de bloques	{4, 5}	—
Filtros iniciales	{32, 64}	—
Dropout inicial	[0,1; 0,4]	—
Unidades capa densa	128	{128, 256}
Dropout capa densa	0,5	0,5
Bloques descongelados	—	{1, 2}
Tasa de aprendizaje	$[10^{-4};\ 10^{-3}]$	$[10^{-6};\ 10^{-4}]$
Tamaño de lote	32	32
Optimizador	Adam	AdamW ($\lambda = 10^{-2}$)
Épocas máximas	100	100
Número de *trials*	30	20

Una vez finalizada la búsqueda, para cada arquitectura se seleccionaron las tres configuraciones con menor valor de *val_loss* en el ranking obtenido mediante Optuna. Estas configuraciones fueron consideradas como candidatas para la selección final y se evaluaron posteriormente sobre el conjunto de prueba sintético, el cual no fue utilizado durante el proceso de optimización. A partir de esta evaluación, se seleccionó la mejor configuración de hiperparámetros para cada arquitectura. De las cinco configuraciones seleccionadas, se eligieron finalmente el mejor modelo propio y el mejor modelo preentrenado. De este modo, la etapa concluyó con dos modelos base, cuyos pesos constituyeron el punto de partida para la etapa posterior de ajuste sobre el dataset objetivo.

4.4.4 Ajuste fino sobre el dataset ICBA

En esta etapa, los dos modelos base fueron adaptados al problema clínico utilizando el dataset del ICBA. El conjunto de datos se dividió en un 80 % destinado al entrenamiento de los modelos y un 20 % reservado para la evaluación final. Dado que cada imagen corresponde a un paciente distinto, esta partición garantiza que no existan registros de un mismo paciente en ambos conjuntos. Por su parte, el conjunto de entrenamiento se organizó en cinco *folds* mediante una partición estratificada, procurando conservar la distribución de las cuatro clases. A su vez, se decidió no aplicar técnicas de aumento de datos sobre estas imágenes, ya que transformaciones habituales, como rotaciones o reflexiones, podrían modificar la orientación y las características del trazado electrocardiográfico, alterando la información relevante para la clasificación.

Para adaptar cada uno de los modelos al nuevo problema, se conservaron los pesos del *backbone* obtenidos durante el preentrenamiento y se reemplazó la cabeza clasificadora por una nueva, con cuatro neuronas de salida correspondientes a las cuatro patologías de interés: Am, HTA, EAo y MCH. La adaptación se realizó mediante el mismo protocolo LP-FT descrito anteriormente. En particular, durante la etapa LP se mantuvo una tasa de aprendizaje de 10^{-3} durante 10 épocas, al igual que en la etapa de preentrenamiento.

Dado el cambio en la tarea de clasificación y el menor tamaño del conjunto de datos, los hiperparámetros determinados durante el preentrenamiento no se asumieron necesariamente óptimos para esta nueva etapa. Por este motivo, se realizó una nueva búsqueda de hiperparámetros mediante Optuna, de manera independiente para cada uno de los dos modelos. En ambos casos se utilizó el mismo espacio de búsqueda, dado que el procedimiento de adaptación aplicado a las dos arquitecturas fue equivalente. La única diferencia correspondió al optimizador, manteniendo en cada caso el utilizado durante los entrenamientos anteriores. Asimismo, debido al menor tamaño del conjunto de datos clínico respecto del utilizado durante el preentrenamiento, el tamaño de lote se redujo de 32 a 16. Los valores considerados para cada hiperparámetro se detallan en la Tabla 8.

Para reducir el costo computacional de la optimización, la búsqueda se realizó utilizando una única partición del conjunto de entrenamiento. En esta partición, los *folds* 1 a 4 se utilizaron como conjunto de entrenamiento propiamente dicho, mientras que el *fold* 5 se empleó como conjunto de validación.

Tabla 8: Configuración de hiperparámetros utilizada durante el ajuste fino sobre el dataset ICBA.

Hiperparámetro	**Modelo propio**	**Modelo preentrenado**
Unidades capa densa	{128, 256}	{128, 256}
Bloques descongelados	{1, 2}	{1, 2}
Tasa de aprendizaje	$[10^{-6};\ 10^{-4}]$	$[10^{-6};\ 10^{-4}]$
Tamaño de lote	16	16
Optimizador	Adam	AdamW ($\lambda = 10^{-2}$)
Épocas máximas	100	100
Número de *trials*	20	20

Una vez finalizada la búsqueda, se seleccionó para cada modelo la configuración mejor posicionada según la función objetivo de Optuna y se procedió a una segunda evaluación mediante validación cruzada (CV). En cada iteración, cuatro *folds* se utilizaron para el entrenamiento y el *fold* restante para la validación, rotando sucesivamente el utilizado para este último propósito. Cada entrenamiento se inicializó a partir de los pesos obtenidos al finalizar el preentrenamiento en el dataset sintético, de manera que los cinco modelos de cada arquitectura partieran del mismo punto de inicialización. Esta metodología permitió caracterizar el desempeño de las configuraciones seleccionadas frente a distintas particiones de los datos y estimar la variabilidad asociada al proceso de entrenamiento.

Finalmente, con el fin de maximizar el uso de los datos de entrenamiento disponibles, se realizó un entrenamiento final para cada arquitectura, utilizando los cinco *folds*. La configuración de hiperparámetros y los pesos de inicialización se mantuvieron idénticos a los empleados durante la validación cruzada, incluyendo la fase LP de 10 épocas con tasa de aprendizaje 10^{-3}. Al prescindir de un conjunto de validación, no fue posible aplicar *EarlyStopping* ni *ReduceLROnPlateau* como criterios de parada y ajuste de la tasa de aprendizaje. Por lo tanto, la cantidad de épocas de entrenamiento del modelo final se estableció a partir de la mediana de las épocas en las que cada modelo de la validación cruzada alcanzó su menor *val_loss*, una estrategia previamente utilizada en la literatura [113][114]. En este trabajo, se optó por utilizar la mediana en lugar de la media, la cual también se puede emplear para este propósito, debido a que esta medida es menos sensible a valores extremos entre los distintos *folds*.

La evaluación final de los modelos se realizó sobre el conjunto de prueba del ICBA, ya que corresponde al conjunto de datos clínicos que refleja directamente el problema de clasificación planteado en este trabajo. Dado que este conjunto no fue utilizado en ninguna instancia previa del proceso de desarrollo, los resultados obtenidos constituyen una estimación no sesgada del desempeño real de cada modelo. Finalmente, a partir de los resultados de esta evaluación se seleccionó el sistema de clasificación implementado en la interfaz desarrollada.

4.4.5 Experimento de ablación

Además del entrenamiento de los modelos destinados a la tarea de clasificación, se realizó un experimento adicional con el objetivo de evaluar el impacto de la etapa de preentrenamiento sobre el dataset sintético. Dado el tamaño reducido del dataset ICBA, resulta esperable que la omisión de esta etapa produjera una disminución marcada del desempeño, especialmente en el modelo propio, que al partir de una inicialización aleatoria podría no lograr aprender representaciones útiles a partir de tan pocas imágenes.

Para evaluar esta hipótesis, se realizó una prueba de ablación en la que se compararon los modelos finales con versiones equivalentes entrenadas sin dicha etapa. El modelo propio se entrenó únicamente sobre el dataset del ICBA a partir de una inicialización de pesos aleatoria, mientras que el modelo preentrenado en ImageNet se adaptó directamente al dataset del ICBA, omitiendo la etapa intermedia de adaptación al dominio de las imágenes electrocardiográficas.

Para garantizar una comparación adecuada entre los modelos, se realizó una nueva búsqueda de hiperparámetros mediante Optuna. De este modo, tanto el modelo que incorporó el preentrenamiento sobre el dataset sintético como su correspondiente modelo de ablación fueron optimizados de manera independiente bajo sus respectivas condiciones de entrenamiento. Esto permitió comparar el mejor modelo alcanzable en cada caso, sin asumir que la configuración de hiperparámetros óptima para el modelo con preentrenamiento sintético es también la más adecuada cuando dicha etapa es omitida. Los espacios de búsqueda se definieron tomando como referencia los utilizados en la etapa de preentrenamiento, manteniendo los hiperparámetros y rangos que resultaban aplicables y adaptando aquellos que requerían modificaciones debido al menor tamaño del dataset del ICBA. En particular, para la arquitectura propia se redujo el rango considerado para el número de bloques convolucionales, dado que una arquitectura excesivamente profunda podría resultar inadecuada para la cantidad limitada de imágenes disponibles. El conjunto completo de hiperparámetros y rangos evaluados se presenta en la Tabla 9.

Tabla 9: Configuración de hiperparámetros utilizada durante los experimentos de ablación.

Hiperparámetro	**Modelo propio**	**Modelo preentrenado**
Número de bloques	{1, 2, 3}	—
Filtros iniciales	{32, 64}	—
Dropout inicial	[0,1; 0,4]	—
Unidades capa densa	128	{128, 256}
Dropout capa densa	0,5	0,5
Bloques descongelados	—	{1, 2}
Tasa de aprendizaje	$[10^{-4};\ 10^{-3}]$	$[10^{-6};\ 10^{-4}]$
Tamaño de lote	16	16
Optimizador	Adam	AdamW ($\lambda = 10^{-2}$)
Épocas máximas	100	100
Número de *trials*	30	20

Al igual que en los procedimientos realizados previamente, la búsqueda de hiperparámetros se realizó sobre una única partición fija de entrenamiento y validación. Una vez finalizada la búsqueda, se seleccionó la configuración con mejor desempeño y se evaluó mediante validación cruzada estratificada de cinco *folds*.

Por último, para cada arquitectura se entrenó un modelo final utilizando la totalidad de los datos de entrenamiento disponibles. La cantidad de épocas se determinó a partir de la mediana de las mejores épocas obtenidas durante la validación cruzada, siguiendo el mismo criterio empleado en la etapa anterior. Una vez finalizado este entrenamiento, los modelos de ablación se evaluaron sobre el conjunto de prueba del ICBA, manteniendo el mismo esquema de evaluación utilizado para los modelos principales y permitiendo así comparar sus resultados bajo condiciones equivalentes.

4.4.6 Criterio de selección de modelos

Para la comparación y selección de los modelos evaluados se adoptó *balanced accuracy* (BA) como métrica principal. Esta elección se fundamenta en las características del problema y en el objetivo de su aplicación clínica.

En un problema de clasificación entre individuos sanos y enfermos, el objetivo principal es identificar correctamente a los individuos afectados. En este contexto, dependiendo de las consecuencias asociadas a cada tipo de error, podrían priorizarse métricas centradas en la capacidad de detectar los casos positivos, como la sensibilidad, con el objetivo de reducir la cantidad de casos enfermos que no son detectados, aun a costa de una menor precisión. En el problema abordado en este trabajo, en cambio, todas las clases corresponden a condiciones patológicas y la tarea consiste en diferenciarlas entre sí. Dado que confundir cualquiera de las etiologías puede tener implicancias directas en el tratamiento del paciente, ningún tipo de error resulta menos relevante que otro. Por este motivo, resulta apropiado utilizar un criterio que evalúe de manera equilibrada el desempeño del modelo sobre todas las clases, sin priorizar ninguna en particular.

Asimismo, la elección de la métrica también debe considerar la distribución de las clases en los conjuntos de datos utilizados. Ambos datasets, tanto el sintético como el del ICBA, presentan un desbalance entre clases. En estas condiciones, una métrica global como el *accuracy* puede verse influenciada por las clases con mayor representación y no reflejar adecuadamente el desempeño sobre las menos frecuentes. El BA, en cambio, al promediar la sensibilidad obtenida para cada clase, permite que cada una de ellas contribuya por igual a la medida global, independientemente de su frecuencia en el conjunto de datos. El *F1-macro* constituye también una alternativa adecuada para este tipo de problema, ya que, al promediar el F1 obtenido para cada clase, otorga igualmente la misma importancia a todas ellas. Además, el F1 combina la precisión y la sensibilidad, por lo que permite considerar tanto la capacidad del modelo para identificar correctamente los casos de una clase como la proporción de sus predicciones que efectivamente pertenecen a ella.

Si bien la incorporación de la precisión podría hacer que el *F1-macro* parezca, *a priori*, una medida más completa, ambas métricas presentan un comportamiento similar frente a una tendencia a sobreclasificar una determinada clase. En el caso del *F1-macro*, una sobreclasificación incrementa la cantidad de falsos positivos de la clase sobrepredicha, reduciendo su precisión y, en consecuencia, su F1. Por su parte, en un problema multiclase, esta misma sobreclasificación genera falsos negativos en las clases a las que pertenecían originalmente esas imágenes, reduciendo sus sensibilidades y, por lo tanto, afectando también el BA.

De esta manera, si bien ambas métricas capturan este comportamiento mediante mecanismos diferentes, una tendencia del modelo a favorecer una clase por sobre las demás impacta sobre el desempeño global en ambos casos. Por este motivo, se optó por utilizar BA como criterio principal de selección, dado que su interpretación resulta más directa en relación con el objetivo planteado.

4.5 Interpretabilidad mediante Grad-CAM

Con el objetivo de facilitar la interpretación de las predicciones de los modelos, se incorporó Grad-CAM como técnica de interpretabilidad. Este método permite generar, para una clase particular, un mapa de calor que indica las regiones de la imagen que presentan una mayor contribución a la probabilidad asignada por el modelo a dicha clase.

La implementación de Grad-CAM requiere seleccionar una capa convolucional objetivo sobre la cual calcular los gradientes utilizados para generar el mapa de activación. En general, se utilizan las capas más profundas debido a que sus representaciones incorporan características de mayor nivel y se encuentran más estrechamente relacionadas con la tarea de clasificación. Sin embargo, estas se obtienen luego de sucesivas operaciones de reducción espacial y, por lo tanto, la resolución de sus mapas de características es menor. Por el contrario, las capas más tempranas conservan

una mayor resolución espacial, pero sus activaciones representan principalmente características de menor nivel. Por este motivo, la elección de la capa objetivo implica un compromiso entre el nivel de abstracción de las características representadas y la resolución espacial del mapa obtenido. Esto resulta particularmente relevante en las imágenes de ECG utilizadas en este trabajo, pues para que el mapa de calor resulte útil como herramienta de interpretación, su resolución debe permitir distinguir entre las distintas derivaciones y localizar segmentos concretos del trazado.

Por este motivo, antes de seleccionar la capa objetivo para cada arquitectura, se evaluó la resolución espacial de los mapas de características producidos por sus distintas capas. Para ello, se representaron diferentes resoluciones mediante una grilla superpuesta sobre una imagen representativa de un ECG, tal como se muestra en la Figura 19. Esta representación permitió visualizar el tamaño de cada celda en relación con las dimensiones de la imagen y las señales del trazado, y evaluar si las celdas abarcaban regiones demasiado extensas que dificultaran la localización de características específicas dentro de una derivación.

En la arquitectura convolucional propia, la reducción espacial acumulada hasta la última capa convolucional es de un factor de $\times 8$. Esto se debe a que dicha capa se ubica después de tres operaciones de *MaxPooling*, cada una de las cuales reduce a la mitad las dimensiones de los mapas de características. Dado que las imágenes de entrada tienen una resolución de 352×192 píxeles, esta capa produce mapas de 44×24 posiciones espaciales (celdas de 8×8 px). Esta resolución es suficiente para identificar individualmente las distintas derivaciones del trazado, por lo que se seleccionó esta capa como capa objetivo para este tipo de modelos.

En cambio, las arquitecturas preentrenadas presentan una reducción espacial de un factor de $\times 32$. La última capa produce representaciones de solo 11×6 posiciones, con celdas de 32×32 píxeles, resolución que no permite localizar con precisión estructuras individuales del trazado. Cada celda abarca la altura completa del espacio de una derivación y aproximadamente un segundo de registro, es decir, cerca de un latido completo. Por este motivo, se evaluó el uso de capas anteriores con mayor resolución. Si bien sería posible retroceder a etapas más tempranas para alcanzar una resolución comparable a la de la arquitectura propia, esto implicaría utilizar representaciones de menor nivel semántico, que podrían aportar información menos relevante para la clasificación. Se seleccionó entonces una capa intermedia que produce mapas de 22×12 posiciones (celdas de 16×16 px), buscando así mantener el equilibrio entre nivel de abstracción y resolución espacial adecuada.

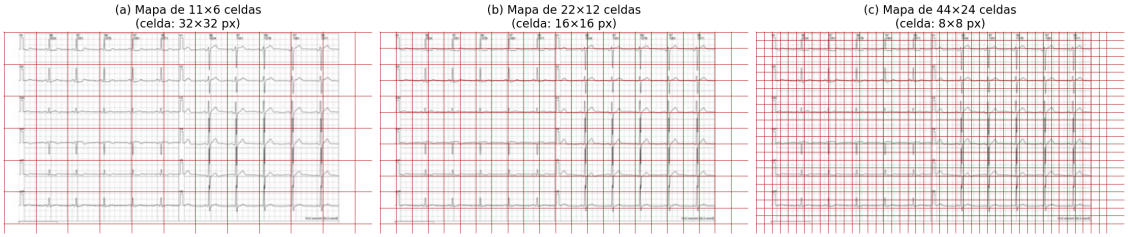

Figura 19: Resoluciones espaciales de los mapas de características, representadas mediante una grilla superpuesta sobre una imagen de ECG, correspondientes a: (a) la capa final de las arquitecturas preentrenadas; (b) una capa intermedia de las arquitecturas preentrenadas; y (c) la capa final de la arquitectura propia.

Una vez seleccionada la capa objetivo, se genera el mapa de Grad-CAM correspondiente a la clase predicha por el modelo. Para ello, se calculan los gradientes de la salida correspondiente a dicha clase respecto de las activaciones de la capa seleccionada, lo que permite estimar la contribución de las distintas posiciones espaciales del mapa de características. A partir de esta información se obtiene un mapa de relevancia que se redimensiona hasta alcanzar las dimensiones originales de la imagen y posteriormente se superpone sobre la misma, permitiendo así visualizar simultáneamente el ECG y las regiones destacadas por el modelo.

4.6 Interfaz gráfica

Con el objetivo de facilitar la utilización de los modelos de clasificación desarrollados, se desarrolló una aplicación de escritorio denominada **VentrIA**. La aplicación permite ejecutar de manera integrada el proceso de clasificación, desde la carga de la imagen de ECG hasta la visualización de resultados.

4.6.1 Uso previsto

VentrIA está destinada a profesionales médicos, particularmente cardiólogos, como herramienta de apoyo al diagnóstico diferencial de las etiologías asociadas a la HVI. Su uso se enmarca en el contexto de un paciente con HVI previamente identificada y para quien se dispone de un ECG de 12 derivaciones en formato digital. En este contexto, la herramienta permite estimar cuál de las cuatro etiologías consideradas resulta más compatible con el patrón electrocardiográfico observado.

La herramienta no tiene como objetivo establecer un diagnóstico definitivo ni reemplazar el juicio clínico del profesional. Los resultados obtenidos constituyen información complementaria que puede contribuir a orientar el diagnóstico diferencial y a considerar qué estudios adicionales podrían resultar de interés realizar para confirmar o descartar la sospecha clínica. La interpretación de los resultados debe realizarse en conjunto con la información clínica del paciente, quedando la decisión diagnóstica y terapéutica bajo responsabilidad del profesional tratante.

4.6.2 Diseño y funcionamiento

VentrIA es una aplicación de escritorio desarrollada en Python utilizando el framework PySide6. Se ejecuta localmente en el equipo del usuario, sin requerir conexión a internet. Esta decisión de diseño resulta especialmente relevante para su uso en entornos clínicos, ya que evita la necesidad de transferir información del paciente a servicios externos. La aplicación integra los modelos de clasificación entrenados, así como las herramientas de interpretabilidad y los procedimientos de preprocesamiento de imágenes desarrollados durante el trabajo.

El flujo se organiza en una serie de pantallas secuenciales, comenzando con la carga de un ECG en formato digital. El usuario puede seleccionar el archivo correspondiente mediante el explorador de archivos del sistema o arrastrándolo desde su ubicación en el equipo hasta el recuadro de carga (*drag and drop*). La aplicación admite archivos de imagen en formato PNG y JPG, así como documentos PDF. Una vez cargado el estudio, se presenta una vista previa del mismo que permite al usuario verificar que el ECG seleccionado sea el correcto antes de iniciar el análisis. En esta instancia, es posible ampliar la imagen para facilitar su visualización.

Al seleccionar la opción “Analizar ECG”, se procesa automáticamente la imagen. La pantalla de resultados, presentada en la Figura 20, reúne la información principal obtenida durante el análisis. En ella se muestra la imagen del ECG recortada, correspondiente a la región utilizada como entrada por el modelo, junto con el resultado final de la clasificación y las probabilidades estimadas para cada una de las cuatro patologías. Estas últimas se presentan mediante barras horizontales, acompañadas de su valor numérico, lo que permite comparar de manera sencilla las probabilidades asignadas a las distintas clases.

Asimismo, se incorpora un indicador del nivel de confianza asociado a la predicción. Este se determina a partir de la diferencia entre la probabilidad de la clase más probable y la correspondiente a la segunda clase con mayor probabilidad. De acuerdo con este margen, la aplicación clasifica la confianza de la predicción en tres niveles: alta cuando la diferencia es mayor o igual a 0,30, media cuando se encuentra entre 0,15 y 0,30, y baja cuando es menor a 0,15. Este indicador permite al usuario interpretar el resultado del modelo con un mayor o menor grado de cautela según el nivel de confianza obtenido.

Además de los resultados de clasificación, la aplicación permite visualizar el mapa de calor obtenido mediante Grad-CAM a través de un botón dedicado. Este se superpone sobre la imagen del ECG, permitiendo así identificar las regiones del trazado que presentan una mayor relevancia para la predicción de la clase seleccionada. Tanto la imagen procesada como el mapa de calor pueden ampliarse y desplazarse para facilitar la inspección de las distintas derivaciones y regiones del trazado. De esta manera, la herramienta proporciona al usuario información adicional para valorar el resultado del modelo.

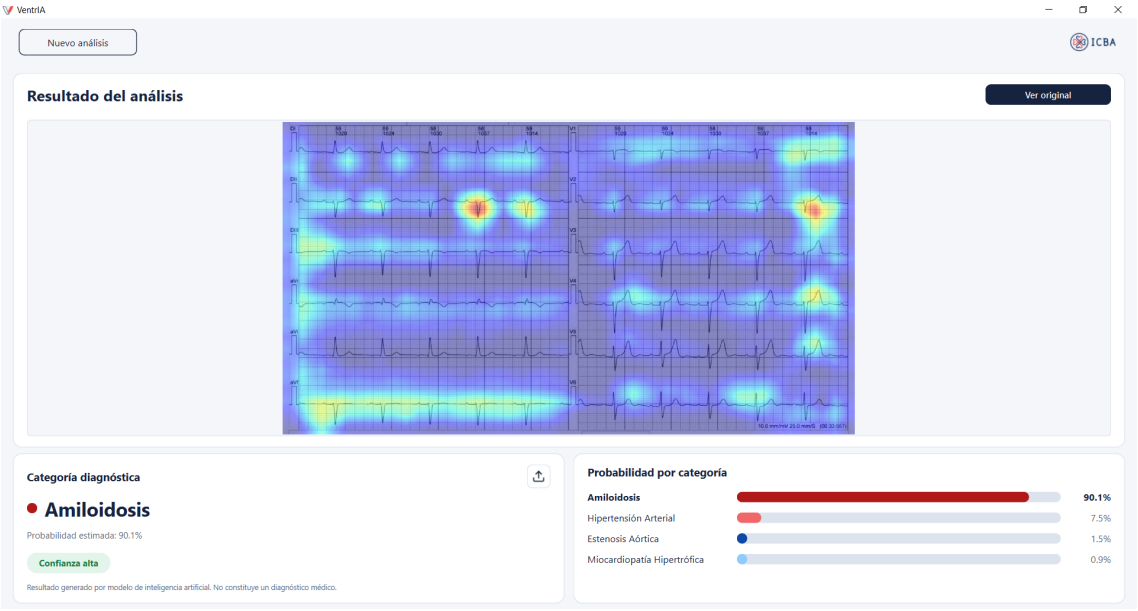

Figura 20: Pantalla de resultados de VentrIA.

Los resultados obtenidos pueden exportarse en formato PDF. El informe incluye la imagen del ECG analizado, la predicción obtenida, las probabilidades correspondientes a las cuatro patologías, el nivel de confianza y el mapa de calor. Un ejemplo completo del informe se presenta en el Anexo B.1. Finalmente, si lo desea, el usuario puede iniciar un nuevo análisis mediante el botón "Nuevo análisis", ubicado en la esquina superior izquierda de la pantalla. Esta opción reinicia el flujo de trabajo y retorna a la pantalla de carga de imagen.

4.6.3 Evaluación de experiencia de usuario

Con el objetivo de conocer la experiencia de uso y la valoración de las principales funcionalidades de VentrIA, se invitó a un grupo de profesionales médicos del ICBA a probar la herramienta y dar su devolución.

Para recopilar estas opiniones de manera estructurada y facilitar su posterior análisis, se diseñó una breve encuesta. El cuestionario se organizó en tres secciones. La primera estuvo destinada a caracterizar el perfil profesional de los participantes y su experiencia con la interpretación de ECG y pacientes con HVI. La segunda se centró en la usabilidad de la interfaz y en la interpretación de los resultados proporcionados por la herramienta, incluyendo la visualización de las probabilidades de cada categoría y de las regiones del ECG resaltadas mediante Grad-CAM. La tercera estuvo orientada a obtener una valoración general de VentrIA, considerando su utilidad percibida y disposición de los participantes a incorporarla en su práctica clínica. El cuestionario completo se presenta en el Anexo B.2.

5 Resultados

5.1 Evaluación de los modelos base sobre el dataset sintético

Como parte del proceso de entrenamiento de los modelos base, se realizaron cinco estudios Optuna independientes, uno para cada arquitectura evaluada: CNN-A, CNN-B, ResNet50 (RN50), EfficientNetB0 (EFNB0) y ConvNeXtTiny (CVNXT). Los resultados completos de cada estudio, incluyendo las configuraciones evaluadas y las métricas obtenidas, se presentan en el Anexo C.1.

Una vez finalizados los estudios, se seleccionaron por cada arquitectura las tres configuraciones con menor *val_loss* y se evaluaron sobre el conjunto de prueba del dataset sintético. El detalle del entrenamiento y la evaluación de las tres configuraciones por arquitectura se presentan en el Anexo D. En cada caso, la configuración con mayor BA fue adoptada como ganadora. Estas configuraciones se presentan en la Tabla 10. Se observa que ambas arquitecturas propias adoptaron cuatro bloques convolucionales, mientras que en las tres arquitecturas preentrenadas la configuración seleccionada correspondió al descongelamiento de dos bloques del *backbone*.

Tabla 10: Configuraciones de hiperparámetros correspondientes al mejor modelo base de cada arquitectura.

Modelo	**Número de bloques**	**Filtros iniciales**	**Dropout inicial**	**Bloques descongelados**	**Unidades capa densa**	**Tasa de aprendizaje**
CNN-A	4	64	0,28	—	—	$1{,}18 \times 10^{-4}$
CNN-B	4	32	0,28	—	—	$1{,}43 \times 10^{-4}$
RN50	—	—	—	2	128	$9{,}79 \times 10^{-5}$
EFNB0	—	—	—	2	128	$8{,}54 \times 10^{-5}$
CVNXT	—	—	—	2	256	$1{,}38 \times 10^{-5}$

Las métricas de desempeño de los cinco modelos correspondientes a las configuraciones seleccionadas se presentan en la Tabla 11, mientras que sus matrices de confusión normalizadas se muestran en la Figura 21.

Tabla 11: Métricas de desempeño de los mejores modelos base sobre el conjunto de prueba del dataset sintético.

Modelo	**BA**	**Precisión**	**F1**	**F1-NORM**	**F1-CD**	**F1-MI**	**F1-HYP**	**F1-STTC**
CNN-A	0,7517	0,7658	0,7544	0,8549	0,8096	0,6897	0,6390	0,7790
CNN-B	0,7644	0,7655	0,7647	0,8566	0,8235	0,7011	0,6474	0,7949
RN50	0,6234	0,6603	0,6383	0,7882	0,7041	0,4893	0,5072	0,7026
EFNB0	0,6210	0,6699	0,6377	0,7852	0,7023	0,4821	0,5244	0,6943
CVNXT	0,6253	0,6704	0,6435	0,8101	0,7176	0,5136	0,4684	0,7076

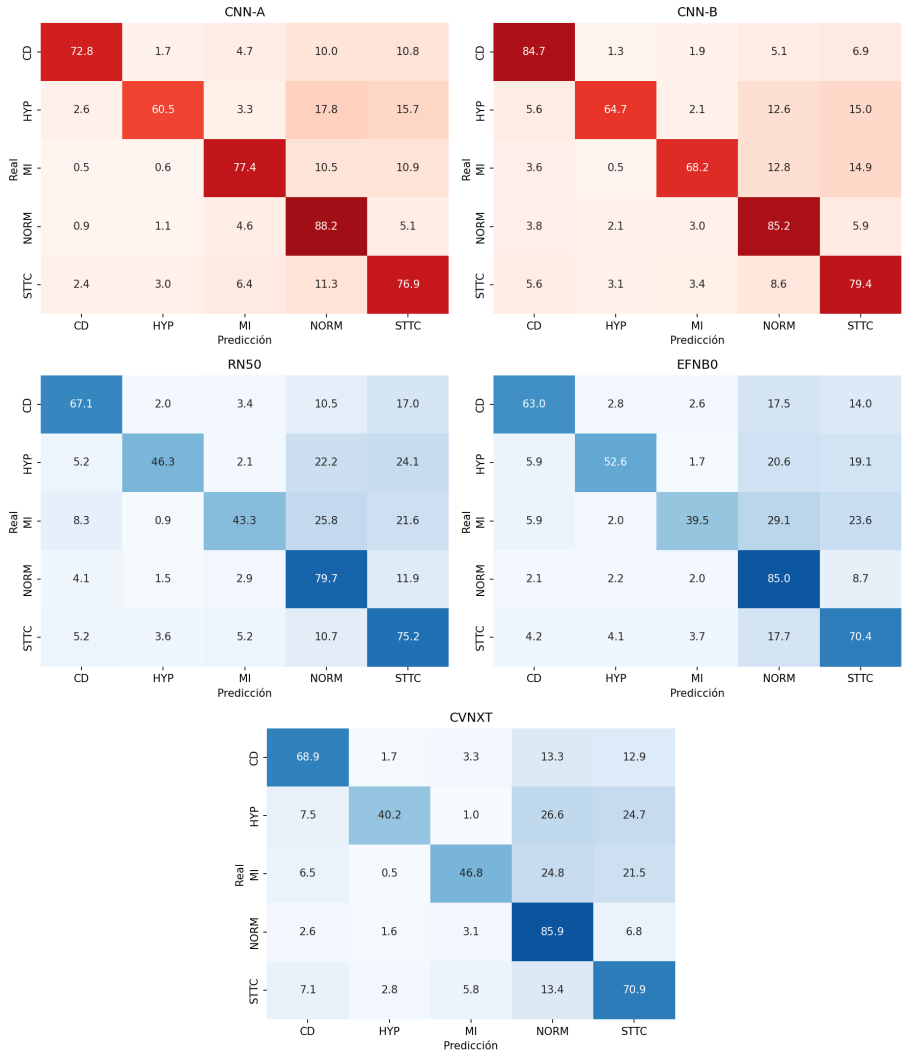

Figura 21: Matrices de confusión normalizadas de los mejores modelos base sobre el conjunto de prueba del dataset sintético.

Entre las arquitecturas propias se obtuvo un desempeño comparable, con valores de BA de 0,7517 para CNN-A y 0,7644 para CNN-B. Las arquitecturas preentrenadas también mostraron resultados similares entre sí, aunque inferiores a los de las arquitecturas propias. Dentro de este grupo, CVNXT alcanzó la mayor BA, con un valor de 0,6253, seguido por RN50 y EFNB0, con valores de 0,6234 y 0,6210, respectivamente.

De acuerdo con el criterio de selección establecido, se seleccionaron CNN-B y CVNXT como las arquitecturas base para continuar con la adaptación al problema de clasificación sobre el dataset del ICBA. A fin de distinguir las arquitecturas base de las versiones adaptadas, estas últimas se denominarán CNN-FT y CVNXT-FT, respectivamente.

5.2 Evaluación de los modelos finales sobre el dataset ICBA

Para determinar la combinación óptima de hiperparámetros en el nuevo contexto de aplicación, se realizó un nuevo estudio de Optuna por cada arquitectura evaluada. Los resultados detallados de ambas búsquedas pueden encontrarse en el Anexo C.2.

La Tabla 12 resume la configuración ganadora para cada modelo, correspondiente a aquella que obtuvo el menor valor de *val_loss*. Cabe destacar que, en ambos casos, las configuraciones calificadas en segundo y tercer lugar resultaron muy similares a la primera, diferenciándose únicamente en pequeñas variaciones en la tasa de aprendizaje. Para CNN-FT, la segunda y tercera configuración presentaron tasas de $8{,}54 \times 10^{-5}$ y $8{,}59 \times 10^{-5}$ respectivamente, mientras que para CVNXT-FT, de $1{,}72 \times 10^{-5}$ y $1{,}33 \times 10^{-5}$. Esto sugiere que la búsqueda logró converger hacia una región acotada dentro del espacio de hiperparámetros evaluado.

Tabla 12: Configuración de hiperparámetros correspondiente a los modelos finales.

Modelo	**Bloques descongelados**	**Unidades capa densa**	**Tasa de aprendizaje**
CNN-FT	2	128	$8{,}69 \times 10^{-5}$
CVNXT-FT	2	128	$1{,}68 \times 10^{-5}$

Con las configuraciones seleccionadas, CNN-FT y CVNXT-FT fueron evaluados mediante un esquema de validación cruzada de cinco *folds*. Las métricas obtenidas en cada *fold*, junto con su media y desvío estándar, se presentan en las Tablas 13 y 14. En ambos casos, las métricas corresponden a la evaluación del modelo resultante del entrenamiento en cada *fold* sobre el conjunto de prueba del dataset ICBA.

Asimismo, las curvas de entrenamiento correspondientes a cada *fold* se presentan en la Figura 22. En ellas se indica la época correspondiente al menor valor de *val_loss* alcanzado durante el entrenamiento de cada *fold*, a partir del cual se determinó la cantidad de épocas para el entrenamiento de los modelos finales, denominados CNN-FINAL y CVNXT-FINAL. En CNN-FT, el menor valor de *val_loss* se alcanzó en las épocas 22, 12, 22, 14 y 24 para los *folds* 1 a 5, respectivamente. La mediana de estos valores fue de 22 épocas, por lo que el modelo CNN-FINAL se entrenó durante 32 épocas en total, correspondientes a 10 épocas de LP y 22 épocas de FT. En el caso de CVNXT-FT, los mínimos se alcanzaron en las épocas 4, 1, 1, 4 y 5, con una mediana de 4 épocas. En consecuencia, CVNXT-FINAL se entrenó durante 14 épocas, con 10 épocas correspondientes a LP y 4 a FT.

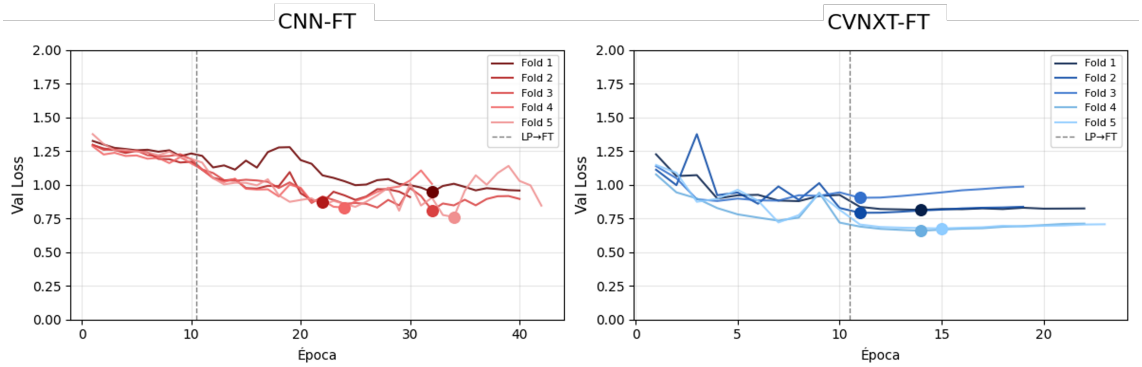

Figura 22: Curvas de entrenamiento de CNN-FT y CVNXT-FT por *fold* de validación cruzada sobre el dataset ICBA.

Los resultados obtenidos por CNN-FINAL y CVNXT-FINAL se incluyen en las Tablas 13 y 14, junto con los resultados correspondientes a cada *fold* de la validación cruzada. Las matrices de confusión normalizadas de ambos modelos finales se presentan en la Figura 23.

Tabla 13: Métricas de desempeño del modelo CNN-FT sobre el conjunto de prueba del dataset ICBA, obtenidas en cada *fold* de CV y durante el entrenamiento final con la totalidad de los datos.

Fold	**BA**	**Precisión**	**F1**	**F1-Am**	**F1-HTA**	**F1-EAo**	**F1-MCH**
Fold 1	0,6581	0,7302	0,6545	0,7857	0,7324	0,6429	0,4571
Fold 2	0,6446	0,6554	0,6385	0,7848	0,7027	0,6667	0,4000
Fold 3	0,7279	0,7372	0,7305	0,8421	0,7353	0,6914	0,6531
Fold 4	0,6226	0,6741	0,6182	0,7561	0,6250	0,6593	0,4324
Fold 5	0,7204	0,7574	0,7238	0,8148	0,7436	0,7027	0,6341
Media $\pm$ σ	$0{,}6747 \pm 0{,}0469$	$0{,}7109 \pm 0{,}0438$	$0{,}6731 \pm 0{,}0510$	$0{,}7967 \pm 0{,}0328$	$0{,}7078 \pm 0{,}0488$	$0{,}6726 \pm 0{,}0243$	$0{,}5153 \pm 0{,}1190$
CNN-FINAL	0,6673	0,7422	0,6671	0,7692	0,5862	0,6977	0,6154

Tabla 14: Métricas de desempeño del modelo CVNXT-FT sobre el conjunto de prueba del dataset ICBA, obtenidas en cada *fold* de CV y durante el entrenamiento final con la totalidad de los datos.

Fold	**BA**	**Precisión**	**F1**	**F1-Am**	**F1-HTA**	**F1-EAo**	**F1-MCH**
Fold 1	0,7379	0,7648	0,7460	0,8000	0,7105	0,7179	0,7556
Fold 2	0,7191	0,7702	0,7261	0,7901	0,7324	0,7317	0,6500
Fold 3	0,7411	0,7563	0,7458	0,7945	0,7089	0,7297	0,7500
Fold 4	0,6881	0,7034	0,6927	0,7568	0,6667	0,6667	0,6809
Fold 5	0,7188	0,7395	0,7232	0,7561	0,7500	0,7200	0,6667
Media $\pm$ σ	$0{,}7210 \pm 0{,}0211$	$0{,}7468 \pm 0{,}0269$	$0{,}7268 \pm 0{,}0218$	$0{,}7795 \pm 0{,}0213$	$0{,}7137 \pm 0{,}0313$	$0{,}7132 \pm 0{,}0267$	$0{,}7006 \pm 0{,}0489$
CVNXT-FINAL	0,7309	0,7480	0,7365	0,7778	0,7105	0,7342	0,7234

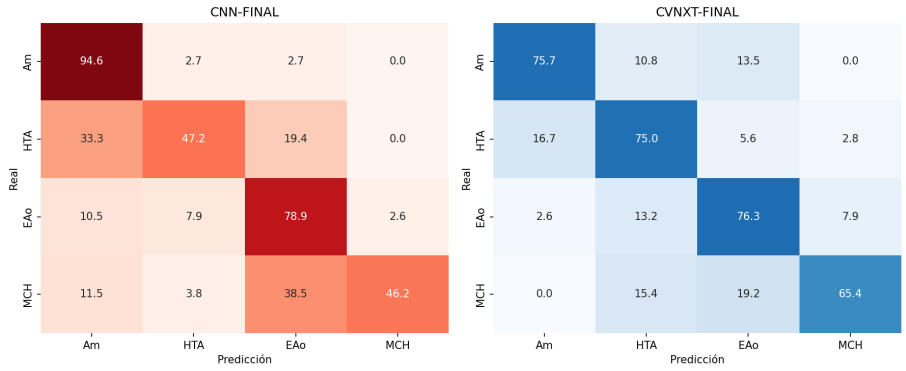

Figura 23: Matrices de confusión normalizadas de los modelos finales sobre el conjunto de prueba del dataset ICBA.

Se observa que CVNXT-FT superó a CNN-FT en la validación cruzada con una BA media de $0{,}7210 \pm 0{,}0211$ frente a $0{,}6747 \pm 0{,}0469$. Por su parte, los modelos finales de ambas arquitecturas exhibieron métricas consistentes con las estimaciones de la validación cruzada, con CVNXT-FINAL alcanzando una BA de 0,7309, superior a la de CNN-FINAL que se mantuvo en 0,6673.

5.3 Ensamble de modelos

Dado que CNN-FINAL y CVNXT-FINAL exhibieron patrones de clasificación diferenciados en sus matrices de confusión, se analizó la distribución conjunta de sus aciertos y errores sobre el conjunto de prueba, con el objetivo de evaluar su posible complementariedad. La Figura 24 presenta un resumen de estos resultados, mientras que las probabilidades asignadas por cada modelo a las cuatro clases, para cada imagen, se detallan en la Tabla E.1 del Anexo E.

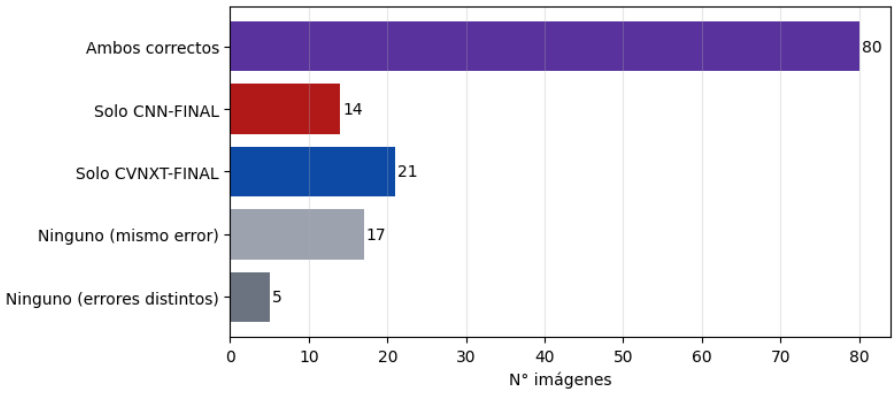

Figura 24: Distribución conjunta de aciertos y errores de CNN-FINAL y CVNXT-FINAL sobre el conjunto de prueba del dataset ICBA.

De las 137 imágenes del conjunto de prueba, 80 (58 %) fueron clasificadas correctamente por ambos modelos. De las 57 imágenes en las que al menos uno de los modelos cometió un error, 14 (10 %) fueron clasificadas correctamente únicamente por CNN-FINAL, 21 (15 %) únicamente por CVNXT-FINAL y 22 (16 %) fueron clasificadas incorrectamente por ambos. Estos resultados muestran que cada modelo logra clasificar correctamente algunas imágenes que el otro no, lo que justifica considerar un ensamble de ambos.

Se evaluó entonces un promedio ponderado de las probabilidades *softmax*, asignando un peso de 40 % a CNN-FINAL y de 60 % a CVNXT-FINAL. La distribución de pesos se definió teniendo en cuenta el mejor desempeño individual de CVNXT-FINAL. Los resultados de la evaluación del ensamble, junto con las métricas de los modelos individuales para su comparación, se presentan en la Tabla 15. La Figura 25 presenta la matriz de confusión correspondiente.

Tabla 15: Comparación de métricas de desempeño entre los modelos finales y el ensamble sobre el conjunto de prueba del dataset ICBA.

Modelo	**BA**	**Precisión**	**F1**	**F1-Am**	**F1-HTA**	**F1-EAo**	**F1-MCH**
CNN-FINAL	0,6673	0,7422	0,6671	0,7692	0,5862	0,6977	0,6154
CVNXT-FINAL	0,7309	0,7480	0,7365	0,7778	0,7105	0,7342	0,7234
Ensamble 40/60	**0,7809**	**0,8010**	**0,7869**	**0,8462**	**0,7397**	**0,7792**	**0,7826**

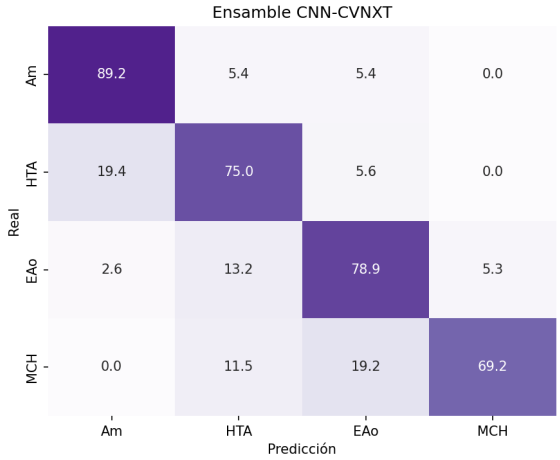

Figura 25: Matriz de confusión normalizada del ensamble de modelos finales sobre el conjunto de prueba del dataset ICBA.

El ensamble alcanzó una BA de 0,7809, superando tanto a CVNXT-FINAL (0,7309) como a CNN-FINAL (0,6673). El F1 mejoró en las cuatro clases. En cuanto a la sensibilidad, el ensamble alcanzó en cada clase valores iguales o cercanos a los del mejor modelo individual, e incluso superó a ambos en MCH (69,2 %, frente a 46,2 % y 65,4 %).

Como se observa en la Figura 26, de las 35 imágenes en las que solo uno de los modelos acertaba, el ensamble logró clasificar correctamente 28 de ellas (20 de las 21 acertadas únicamente por CVNXT-FINAL y 8 de las 14 acertadas únicamente por CNN-FINAL). A su vez, conservó la clasificación correcta de las 80 imágenes acertadas por ambos. En cambio, ninguna de las 22 imágenes clasificadas incorrectamente por ambos modelos fue recuperada. En total, el ensamble clasificó correctamente 108 de las 137 imágenes del conjunto de prueba, frente a 101 de CVNXT-FINAL y 94 de CNN-FINAL. La clasificación obtenida por el ensamble para cada imagen se presenta en la Tabla E.2 del Anexo E.

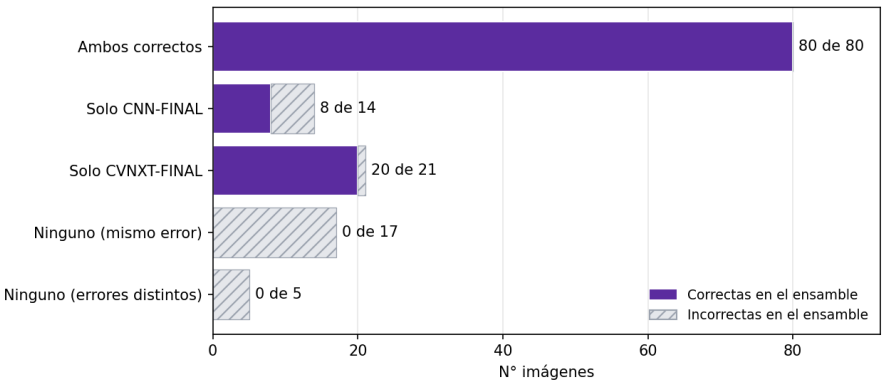

Figura 26: Predicción del ensamble según la distribución conjunta de aciertos y errores de CNN-FINAL y CVNXT-FINAL sobre el conjunto de prueba del dataset ICBA.

Dado su mejor desempeño global, el ensamble fue seleccionado como el modelo de clasificación final para su integración en la interfaz gráfica desarrollada.

5.4 Impacto del preentrenamiento con imágenes sintéticas

Para evaluar en qué medida el preentrenamiento con imágenes sintéticas afectó el desempeño de los modelos, se repitió el entrenamiento de CNN-B y CVNXT omitiendo esta etapa. Los modelos obtenidos bajo esta condición se denominaron CNN-ABL y CVNXT-ABL, respectivamente.

Para cada arquitectura se realizó un nuevo estudio de Optuna, destinado a determinar los hiperparámetros adecuados en este nuevo contexto y establecer una comparación en condiciones equivalentes. Los resultados detallados de ambos estudios se presentan en el Anexo C.3. Las configuraciones que obtuvieron el menor *val_loss* en cada estudio se muestran en la Tabla 16.

Tabla 16: Configuración de hiperparámetros correspondiente a los modelos de ablación.

Modelo	Bloques	Filtros base	Dropout inicial	Unidades capa densa	Bloques descongelados	Tasa de aprendizaje
CNN-ABL	2	32	0,3909	128	—	$9{,}02 \times 10^{-4}$
CVNXT-ABL	—	—	—	256	1	$9{,}45 \times 10^{-5}$

Los modelos de ablación fueron evaluados mediante el mismo esquema de validación cruzada de cinco *folds* utilizado para los modelos principales. La cantidad de épocas para el entrenamiento final se determinó, al igual que en los modelos con preentrenamiento, a partir de la mediana de las épocas correspondientes al menor valor de *val_loss* en cada *fold*. Las curvas de entrenamiento obtenidas se presentan en la Figura 27, donde se señalan los mínimos de *val_loss* utilizados para este cálculo. Para CNN-ABL, estos mínimos corresponden a las épocas 1, 1, 1, 1 y 34, por lo que la mediana fue de 1 época. En consecuencia, CNN-ABL-FINAL se entrenó únicamente durante una época. Para CVNXT-ABL, los mínimos de la fase FT se alcanzaron en las épocas 20, 16, 13, 16 y 27, resultando en una mediana de 16 épocas. Por lo tanto, CVNXT-ABL-FINAL se entrenó durante 26 épocas en total, correspondientes a 10 épocas de LP y 16 de FT.

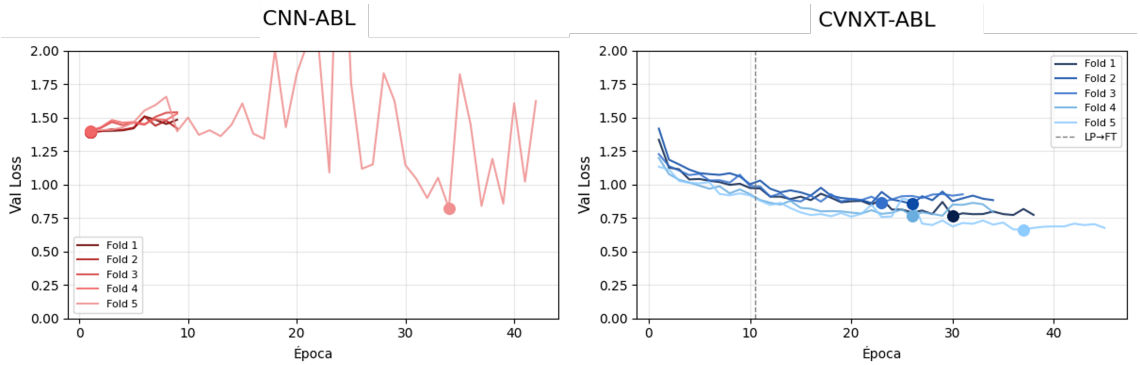

Figura 27: Curvas de entrenamiento de CNN-ABL y CVNXT-ABL por *fold* de validación cruzada sobre el dataset ICBA.

Las Tablas 17 y 18 presentan los resultados obtenidos durante la CV para cada *fold*, junto con la media y el desvío estándar, así como el desempeño de los modelos finales. A modo de referencia, se incluye también el desempeño de los modelos finales que sí recibieron preentrenamiento en el dataset sintético, a fin de facilitar la comparación. Las matrices de confusión correspondientes a los modelos finales ablacionados se presentan en la Figura 28.

Tabla 17: Métricas de desempeño del modelo CNN-ABL sobre el conjunto de prueba del dataset ICBA, obtenidas en cada *fold* de CV y durante el entrenamiento final con la totalidad de los datos.

Fold	BA	Precisión	F1	F1-Am	F1-HTA	F1-EAo	F1-MCH
Fold 1	0,2500	0,0675	0,1063	0,4253	0,0000	0,0000	0,0000
Fold 2	0,2500	0,0675	0,1063	0,4253	0,0000	0,0000	0,0000
Fold 3	0,2500	0,0675	0,1063	0,4253	0,0000	0,0000	0,0000
Fold 4	0,2500	0,0675	0,1063	0,4253	0,0000	0,0000	0,0000
Fold 5	0,5511	0,5522	0,5177	0,6222	0,4828	0,3860	0,5797
Media $\pm$ σ	$0{,}3102 \pm 0{,}1347$	$0{,}1644 \pm 0{,}2168$	$0{,}1886 \pm 0{,}1840$	$0{,}4647 \pm 0{,}0881$	$0{,}0966 \pm 0{,}2159$	$0{,}0772 \pm 0{,}1726$	$0{,}1159 \pm 0{,}2593$
CNN-ABL-FINAL	0,2500	0,0474	0,0798	0,0000	0,0000	0,0000	0,3190
CNN-FINAL (ref.)	0,6673	0,7422	0,6671	0,7692	0,5862	0,6977	0,6154

Tabla 18: Métricas de desempeño del modelo CVNXT-ABL sobre el conjunto de prueba del dataset ICBA, obtenidas en cada *fold* de CV y durante el entrenamiento final con la totalidad de los datos.

Fold	BA	Precisión	F1	F1-Am	F1-HTA	F1-EAo	F1-MCH
Fold 1	0,6996	0,7054	0,7014	0,7324	0,6761	0,6914	0,7059
Fold 2	0,7242	0,7236	0,7219	0,7324	0,7436	0,6944	0,7170
Fold 3	0,6345	0,6604	0,6408	0,7000	0,5867	0,6400	0,6364
Fold 4	0,6843	0,7179	0,6934	0,7297	0,6190	0,6857	0,7391
Fold 5	0,6724	0,6837	0,6735	0,6824	0,5970	0,6944	0,7200
Media $\pm$ σ	$0{,}6830 \pm 0{,}0333$	$0{,}6982 \pm 0{,}0261$	$0{,}6862 \pm 0{,}0307$	$0{,}7154 \pm 0{,}0230$	$0{,}6445 \pm 0{,}0653$	$0{,}6812 \pm 0{,}0233$	$0{,}7037 \pm 0{,}0395$
CVNXT-ABL-FINAL	0,6192	0,6777	0,6263	0,6769	0,6118	0,6667	0,5500
CVNXT-FINAL (ref.)	0,7309	0,7480	0,7365	0,7778	0,7105	0,7342	0,7234

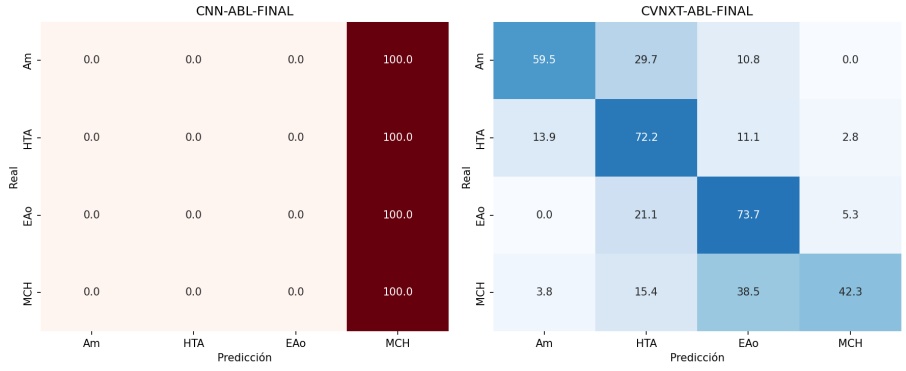

Figura 28: Matrices de confusión normalizadas de los modelos sin preentrenamiento en imágenes sintéticas sobre el conjunto de prueba del dataset ICBA.

En cuatro de los cinco *folds* de la validación cruzada, CNN-ABL clasificó todas las imágenes del conjunto de prueba como Am, mientras que CNN-ABL-FINAL las clasificó a todas como MCH. Al predecir una única clase, estos modelos obtuvieron una BA de 0,2500 y un F1 nulo para las tres clases restantes. Asimismo, para todas las imágenes, la diferencia entre las probabilidades asignadas a las dos clases más probables fue inferior a 0,05. Este resultado era esperable, ya que entrenar una CNN desde cero a partir de un conjunto de datos de este tamaño difícilmente permite aprender representaciones discriminativas. En el *fold* 5, en cambio, las probabilidades variaron entre 0,003 y 0,83, y se alcanzó una BA de 0,5511, por lo que la BA media de la CV, de 0,3102, se vio elevada principalmente por este resultado.

Por otro lado, CVNXT-ABL presentó un desempeño considerablemente superior al de CNN-ABL, con una BA media de $0{,}6830 \pm 0{,}0333$. No obstante, su desempeño fue inferior al obtenido por CVNXT-FINAL, tanto en la validación cruzada como en el entrenamiento final. En particular, CVNXT-ABL-FINAL alcanzó una BA de 0,6192, frente a 0,7309 para CVNXT-FINAL.

5.5 Mapas de calor obtenidos mediante Grad-CAM

Se generaron los mapas de activación Grad-CAM del ensamble CNN-CVNXT sobre las 137 imágenes del conjunto de prueba del dataset ICBA. Estos corresponden a la combinación de los obtenidos por CNN-FINAL y CVNXT-FINAL para la clase predicha por el ensamble, ponderados con los mismos pesos asignados a cada modelo en la combinación de sus probabilidades (40 % y 60 %, respectivamente).

Dado que los valores de cada mapa dependen de la arquitectura y de la capa utilizada, ambos fueron previamente normalizados entre 0 y 1, de modo que, en cada uno, el valor máximo corresponde a la región de mayor contribución para ese modelo. Asimismo, como ambos modelos producen mapas de distinta resolución (44×24 y 22×12 posiciones), estos fueron llevados a las dimensiones de la imagen antes de su combinación. De este modo, el mapa final refleja la contribución conjunta de ambos modelos a la predicción, expresada en una escala común. Los tonos rojos y amarillos indican las regiones que más contribuyeron a la predicción de la clase asignada, mientras que los tonos azules corresponden a las de menor contribución.

Las Figuras 29 y 30 muestran ejemplos de los mapas de calor obtenidos para imágenes correcta e incorrectamente clasificadas, respectivamente. Además, en el Anexo F se incluyen ejemplos adicionales de imágenes correctamente clasificadas de cada clase, con el fin de brindar mayor sustento a los patrones observados.

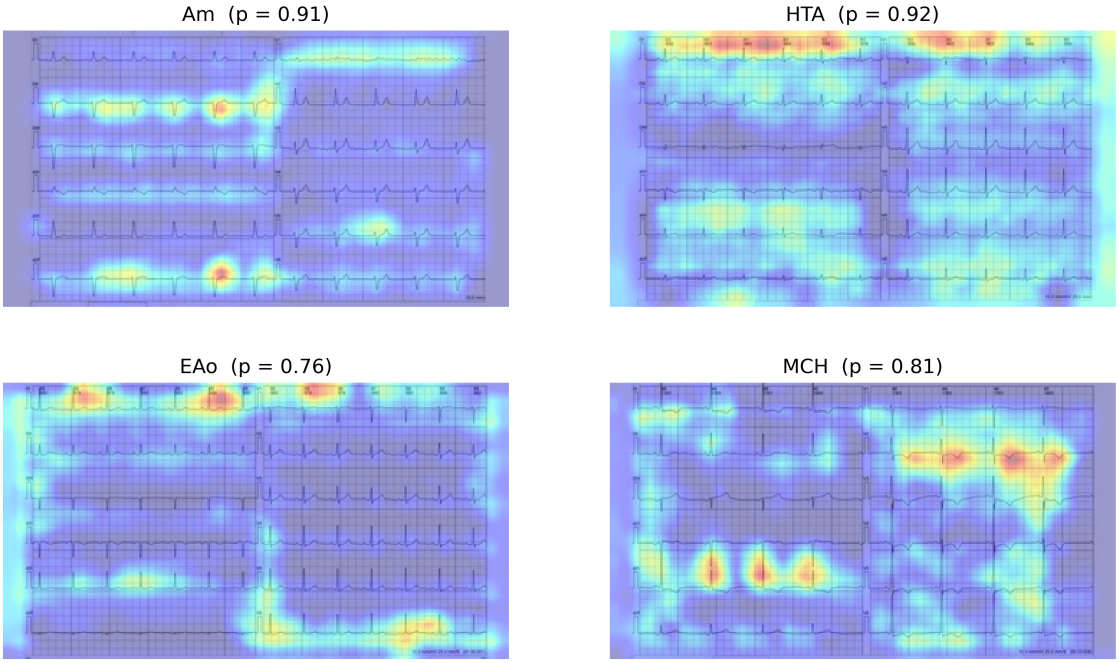

Figura 29: Mapas de activación Grad-CAM del ensamble sobre imágenes correctamente clasificadas, para cada una de las cuatro patologías consideradas.

En las imágenes correctamente clasificadas de Am y MCH, la activación se concentró en focos más localizados sobre el trazado electrocardiográfico. En las imágenes de EAo, y en algunas de HTA, se observó una activación intensa sobre la franja superior de la imagen, región que contiene la primera fila de derivaciones y, en ciertos estudios, anotaciones numéricas sobre los complejos QRS. A su vez, ambas clases presentaron una mayor activación en los márgenes en comparación con Am y MCH. Por su parte, los mapas de HTA mostraron, en general, un patrón más difuso, con activaciones distribuidas sobre una mayor proporción de la imagen, resaltando varias de las derivaciones.

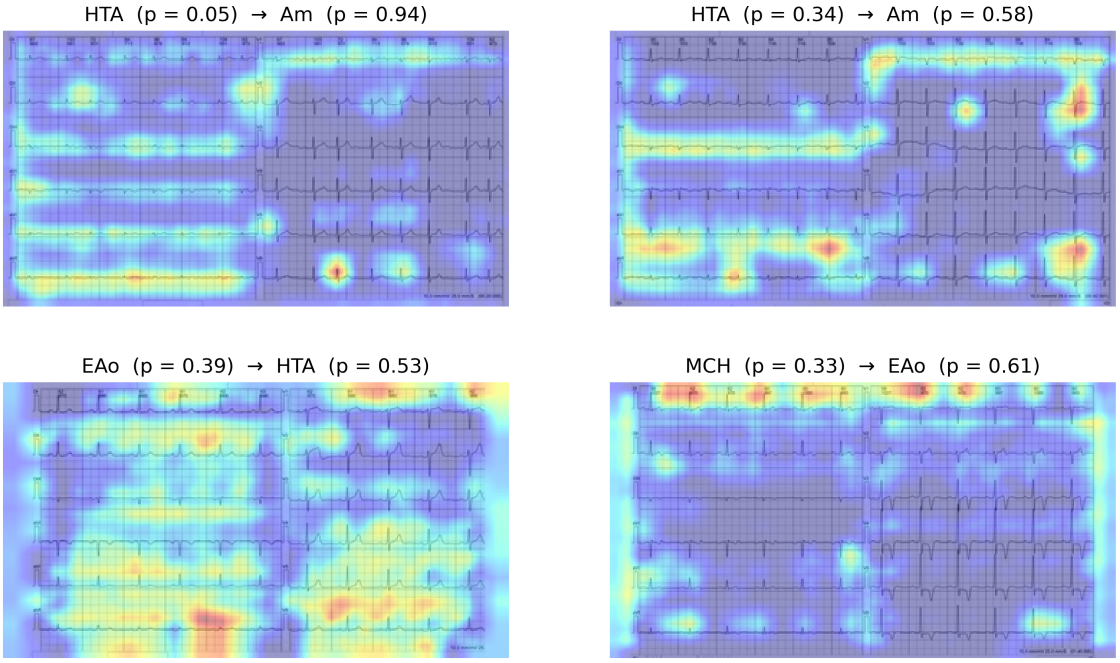

Figura 30: Mapas de activación Grad-CAM del ensamble sobre imágenes incorrectamente clasificadas, para cada una de las cuatro patologías consideradas. Sobre cada imagen se indica la clase correcta y la clase predicha, junto con la probabilidad asignada por el ensamble a cada una, con el formato: clase correcta (p_{correcta}) → clase predicha (p_{predicha}).

Por su parte, en las imágenes incorrectamente clasificadas, los mapas presentaron un patrón de activación similar al de la clase predicha, y no al de su clase real.

5.6 Evaluación de la interfaz por profesionales médicos

La aplicación VentrIA fue evaluada por seis cardiólogos del ICBA a partir de la encuesta descrita en la Sección 4.6.3. Los participantes contaban con entre 2 y más de 20 años de experiencia clínica en el área de cardiología, y todos informaron leer más de 30 ECG por semana y atender pacientes con HVI de manera frecuente o muy frecuente. La distribución de estas características entre los diferentes profesionales consultados se presenta en la Figura 31.

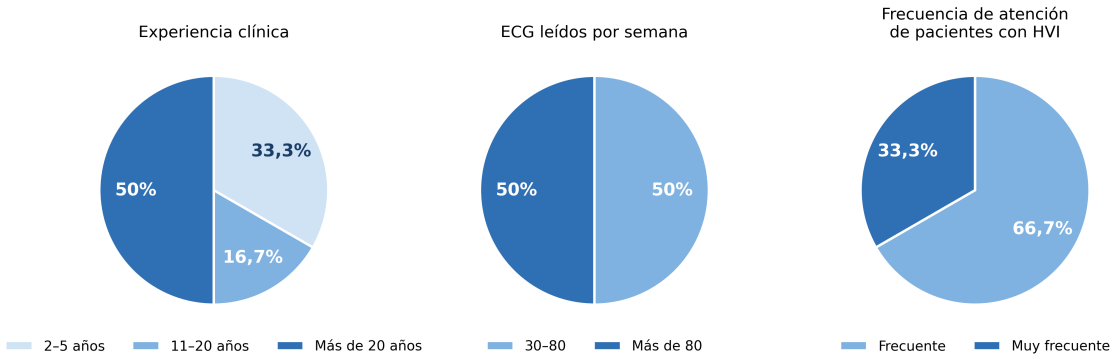

Figura 31: Distribución del perfil de los profesionales que participaron en la evaluación de VentrIA.

En relación con el problema abordado, la dificultad percibida por los participantes para determinar la etiología de la HVI a partir del ECG obtuvo una puntuación media de 3,67 sobre 5. Asimismo, todos indicaron recurrir a estudios complementarios para establecer la etiología, principalmente al ecocardiograma Doppler y, en algunos casos, a la resonancia magnética cardíaca.

En cuanto a la usabilidad y la utilidad clínica de la herramienta, la Tabla 19 presenta la puntuación media asignada a cada ítem de la encuesta. El detalle de todas las respuestas recopiladas se presenta en el Anexo B.3.

Tabla 19: Puntuación media asignada por los participantes a cada ítem de la encuesta, en escala 1–5 (1 = muy en desacuerdo, 5 = muy de acuerdo). Entre paréntesis se indica el rango de valores asignados.

Ítem	**Media (rango)**
Usabilidad	
Facilidad de navegación	4,50 (2–5)
Claridad de la información en pantalla	4,67 (3–5)
Facilidad de interpretación del resultado	4,33 (1–5)
Utilidad de las probabilidades por categoría	4,67 (3–5)
Utilidad clínica	
Relevancia clínica de las regiones resaltadas	3,83 (2–5)
Utilidad de los mapas de calor	4,33 (3–5)
Utilidad para evaluar la etiología de la HVI	4,33 (3–5)
Probabilidad de incorporarla en la práctica	4,33 (3–5)

Por último, la valoración general de VentrIA como herramienta de apoyo diagnóstico obtuvo una media de 8,67 sobre 10. Cabe destacar que, si bien la familiaridad de los participantes con herramientas basadas en inteligencia artificial fue moderada, con una puntuación media de 3,17, la probabilidad de incorporar VentrIA en su práctica clínica obtuvo una puntuación media de 4,33.

6 Discusión

6.1 Análisis de resultados

6.1.1 Comparación entre arquitecturas de los modelos base

A partir de los resultados presentados en la Sección 5.1, se observa que los modelos propios, CNN-A y CNN-B, alcanzaron un desempeño similar sobre el conjunto de prueba sintético, con valores de BA de 0,7517 y 0,7644, respectivamente. Si bien ambas arquitecturas presentaron oscilaciones marcadas en la pérdida de validación durante las primeras épocas, en CNN-B estas desaparecieron hacia la época 15, mientras que en CNN-A persistieron hasta aproximadamente la época 34 (Anexo D.1). Además, CNN-B obtuvo una menor pérdida de validación en sus tres configuraciones candidatas, con valores de 0,57–0,58 frente a 0,66–0,71 de CNN-A (Anexo C.1). Esto indica que, con una proporción de aciertos similar, CNN-B asignó mayor probabilidad a la clase correcta, es decir, que sus predicciones resultaron más confiables. Dado que la única diferencia entre ambas arquitecturas son las conexiones residuales, estos resultados sugieren que su aporte se reflejó principalmente en la estabilidad del entrenamiento más que en el desempeño final. Este comportamiento resulta esperable, ya que los beneficios de las conexiones residuales suelen ser más notorios en redes de mayor profundidad.

Por su parte, los modelos preentrenados también obtuvieron resultados muy similares entre sí, con valores de BA de 0,6253 para ConvNeXtTiny, 0,6234 para ResNet50 y 0,6210 para EfficientNetB0. Diferencias de esta magnitud, inferiores a 0,005, no permiten establecer una superioridad clara entre las arquitecturas. A pesar de eso, siguiendo con el criterio de selección establecido, se eligió ConvNeXtTiny para continuar con la etapa de ajuste fino, al ser la arquitectura que obtuvo la mayor BA. Esta elección se ve respaldada, además, por otras observaciones. En primer lugar, ConvNeXtTiny presentó la menor pérdida de validación en sus tres configuraciones candidatas, con valores cercanos a 0,77, frente a 0,82 de EfficientNetB0 y 0,83–0,86 de ResNet50 (Anexo C.1). En segundo lugar, al finalizar la etapa LP, con el *backbone* aún congelado, ConvNeXtTiny alcanzó una exactitud de validación cercana al 63 %, similar a la de ResNet50 y superior a la de EfficientNetB0, que no superó el 54 % (Anexo D.1). Es decir, las representaciones que esta arquitectura traía de su preentrenamiento en ImageNet resultaron, aun sin ajuste sobre el dataset sintético, de las más útiles para clasificar las imágenes de ECG, característica relevante en una etapa cuyo propósito es servir como punto de partida para la tarea clínica. Por último, ResNet50, en particular, mostró signos de sobreajuste. En sus tres configuraciones alcanzó su menor pérdida de validación entre la cuarta y la quinta época de la etapa FT y, a partir de ese punto, su exactitud de entrenamiento continuó aumentando hasta valores cercanos al 95 %, mientras que la pérdida de validación empeoraba. Esto indica que el modelo comenzó a ajustarse a las particularidades de las imágenes de entrenamiento en lugar de aprender patrones generalizables, lo que constituye un argumento adicional para descartar esta arquitectura frente a las otras dos alternativas.

La diferencia más marcada, sin embargo, se observó entre ambas estrategias, donde las arquitecturas propias superaron a todas las preentrenadas por más de 0,12 de BA. Esta diferencia puede atribuirse a la naturaleza de cada una. Los modelos propios ajustaron la totalidad de sus parámetros al dominio sintético, por lo que se especializaron en el mismo tipo de imágenes sobre el que fueron evaluados posteriormente. La transferencia de aprendizaje, en cambio, conserva la mayor parte de las representaciones aprendidas sobre imágenes naturales y adapta únicamente las capas finales. Las curvas de entrenamiento del Anexo D.1 permiten caracterizar mejor esta diferencia. En su mejor época, los modelos propios alcanzaron exactitudes de entrenamiento del orden del 84–86 % y de validación cercanas al 80 %, mientras que los preentrenados se ubicaron en torno al 73–76 % y 70 %, respectivamente. La brecha entre entrenamiento y validación resultó similar en ambos grupos, por lo que la ventaja de los modelos propios no radica en una mayor capacidad

de generalización, sino en haber aprendido en mayor medida las características de este tipo de imágenes.

Esta diferencia en el grado de aprendizaje se refleja también en el patrón de errores. Las matrices de confusión de la Figura 21 muestran que los modelos preentrenados tendieron a asignar las imágenes que no lograban reconocer a NORM y STTC, las dos superclases más frecuentes del dataset. Este comportamiento fue más evidente en las clases HYP y MI. En los modelos preentrenados, entre el 40 % y el 51 % de las imágenes de HYP y entre el 46 % y el 53 % de las de MI fueron asignadas a alguna de estas dos superclases, frente al 28–34 % y 21–28 %, respectivamente, en los modelos propios. Este comportamiento es coherente con lo mencionado anteriormente, ya que un modelo que aprendió en menor medida las características del dominio tiende a apoyarse en las clases observadas con mayor frecuencia durante el entrenamiento.

6.1.2 Transferencia de los modelos base al problema clínico

Al ajustar los modelos base al dataset ICBA, la relación observada en la etapa sintética se invirtió. Los resultados presentados en la Sección 5.2 muestran que CVNXT-FT superó a CNN-FT, con una BA media de $0{,}7210 \pm 0{,}0211$ frente a $0{,}6747 \pm 0{,}0469$. Además, CVNXT-FT presentó una menor variabilidad entre *folds*, lo que indica que su desempeño depende en menor medida de la composición particular de cada partición, aspecto relevante en un escenario con pocos datos.

Estos resultados no contradicen lo observado en la etapa anterior, ya que ambas evaluaciones corresponden a tareas y conjuntos de datos distintos. Un mejor desempeño en la tarea de preentrenamiento no garantiza que las representaciones aprendidas resulten más útiles para una tarea diferente, y la dinámica del entrenamiento permite observar este fenómeno. Durante la etapa LP, el *backbone* permanece congelado y solo se entrena la cabeza clasificadora, por lo que el desempeño alcanzado al finalizar esta etapa refleja qué tan útiles resultan las representaciones de cada modelo, tal como fueron aprendidas, para la nueva tarea. Como se observa en la Figura 22, al finalizar la etapa LP, la pérdida de validación de CNN-FT se mantuvo en valores cercanos a 1,2, mientras que la de CVNXT-FT descendió hasta alrededor de 0,85. Asimismo, durante la etapa FT, CVNXT-FT alcanzó su menor pérdida de validación entre la primera y la quinta época, mientras que CNN-FT requirió entre 12 y 24 épocas. Ambas observaciones indican que las representaciones de ConvNeXt-Tiny constituyeron un punto de partida más adecuado para la tarea objetivo y requirieron menos modificaciones para adaptarse a ella.

Una posible explicación de este comportamiento se relaciona con el origen de las representaciones de cada modelo. ConvNeXtTiny combina representaciones visuales generales, aprendidas sobre un conjunto amplio y diverso de imágenes naturales, con una adaptación parcial al dominio electrocardiográfico obtenida durante el preentrenamiento sintético. Esta base general resultaría más robusta frente al cambio de tarea. La arquitectura propia, en cambio, construyó la totalidad de sus representaciones en función de la tarea sintética, por lo que dispondría de menos características reutilizables al enfrentarse a un problema diferente. Así, la especialización, que constituía una ventaja al ser evaluada sobre el mismo dominio en el que fue entrenada, deja de serlo cuando cambian tanto la tarea como el conjunto de imágenes.

Por último, los modelos finales obtuvieron un desempeño prácticamente igual a la media de la validación cruzada, con una BA de 0,6673 frente a 0,6747 en CNN y de 0,7309 frente a 0,7210 en CVNXT. Por un lado, esto indica que la validación cruzada constituyó un buen estimador del desempeño final. Por otro, muestra que incorporar el quinto *fold* al entrenamiento, lo que representó aproximadamente 110 imágenes adicionales, no produjo una mejora apreciable. Esto sugiere que, para obtener una mejora significativa en el desempeño, sería necesario un aumento considerablemente mayor del volumen de datos disponible.

6.1.3 Contribución del preentrenamiento con imágenes sintéticas

Uno de los aportes más relevantes de este trabajo es el desarrollo del dataset sintético para el preentrenamiento de los modelos. Esta contribución se pone especialmente de manifiesto en los resultados del experimento de ablación presentados en la Sección 5.4.

Para la arquitectura propia, la ausencia de esta etapa no produjo una simple degradación del desempeño, sino un colapso del entrenamiento. Cuatro de los cinco *folds* de CV de CNN-ABL, así como CNN-ABL-FINAL, predijeron sistemáticamente una única clase. Sin embargo, las probabilidades asignadas a las cuatro clases se mantuvieron en todos los casos cercanas a 0,25, y la diferencia entre las dos clases más probables fue de apenas unas centésimas. Este comportamiento es consistente con una clasificación prácticamente aleatoria, en la que los modelos no aprendieron representaciones que les permitieran distinguir entre las clases a partir de los ECG, sino que produjeron salidas prácticamente independientes de la imagen de entrada.

Por lo tanto, el hecho de que todas las imágenes fueran asignadas a una misma clase no responde a un patrón aprendido, sino al sesgo introducido por la inicialización aleatoria de los pesos. Una red recién inicializada puede presentar preferencia por determinadas clases incluso antes de haber visto los datos. En este caso, la utilización de una semilla fija hizo que todos los entrenamientos partieran de los mismos pesos iniciales. A su vez, el hecho de que la menor pérdida de validación se alcanzara ya en la primera época indica que los modelos no llegaron a desarrollar un aprendizaje efectivo, por lo que permanecieron próximos a ese estado inicial. Ambos factores explican que los modelos de la CV conservaran una preferencia similar por una única clase (Am). El modelo final, entrenado con un conjunto de imágenes algo mayor, presentó una variación suficiente para favorecer otra clase (MCH), aunque mantuvo probabilidades cercanas a 0,25 para las cuatro. En consecuencia, tanto la preferencia por una única clase como la diferencia entre los modelos de CV y el modelo final responden a mínimas variaciones aleatorias asociadas a los pesos, y no a características aprendidas de los ECG. El único *fold* en el que CNN-ABL logró aprender, alcanzando una BA de 0,5511, fue el *fold* 5, es decir, la misma partición utilizada como conjunto de validación durante la búsqueda de hiperparámetros con Optuna. Esto sugiere que la configuración seleccionada quedó ajustada a esa partición particular de los datos, y que el desempeño obtenido en ella no refleja una capacidad real de aprendizaje del modelo.

En conjunto, estos resultados indican, como era esperado bajo las condiciones evaluadas, que entrenar la arquitectura propia desde cero utilizando únicamente las imágenes del dataset ICBA resulta inviable. El preentrenamiento sobre imágenes sintéticas, en cambio, proporcionó una inicialización basada en representaciones del dominio electrocardiográfico, que permitió que CNN-FT se entrenara de manera estable en todos los *folds* y lograra distinguir entre las cuatro clases, alcanzando una BA media de $0{,}6747 \pm 0{,}0469$.

En el caso de ConvNeXtTiny, la inicialización con pesos de ImageNet fue suficiente para que CVNXT-ABL se entrenara de manera estable en todos los *folds*, alcanzando una BA media de $0{,}6830 \pm 0{,}0333$. No obstante, este desempeño resultó inferior al de CVNXT-FT, que alcanzó una BA media de $0{,}7210 \pm 0{,}0211$. Por lo tanto, el preentrenamiento sobre imágenes de ECG permitió adaptar las representaciones al dominio electrocardiográfico antes del ajuste sobre el dataset del ICBA, mejorando el desempeño de un modelo que ya contaba con una inicialización robusta. Esta idea se ve reforzada por la dinámica del entrenamiento. Al finalizar la etapa LP, con el *backbone* aún congelado, la pérdida de validación de CVNXT-ABL se mantuvo en valores cercanos a 0,96, por encima de los 0,85 alcanzados por CVNXT-FT (Figuras 22 y 27). Asimismo, durante la etapa FT, CVNXT-FT alcanzó su mínimo entre la primera y la quinta época, mientras que CVNXT-ABL requirió entre 13 y 27 épocas, a pesar de utilizar una tasa de aprendizaje mayor. En conjunto, estos resultados sugieren que el preentrenamiento sintético proporcionó una inicialización más adaptada al dominio electrocardiográfico, reduciendo el ajuste requerido por los modelos para llevar a cabo para la tarea de clasificación sobre el dataset del ICBA.

6.1.4 Mejora obtenida a partir del ensamble

Más allá de su desempeño global, las matrices de confusión de la Figura 23 muestran que CNN-FINAL y CVNXT-FINAL presentaron patrones de clasificación diferenciados. CNN-FINAL alcanzó sensibilidades elevadas para Am (94,6 %) y EAo (78,9 %), pero a costa de una tendencia a sobreclasificar estas clases. El 33,3 % de las imágenes de HTA fue clasificado como Am y el 38,5 % de las de MCH como EAo, lo que redujo la sensibilidad de ambas clases a 47,2 % y 46,2 %, respectivamente. CVNXT-FINAL, en cambio, distribuyó sus predicciones de manera más equilibrada, con sensibilidades de entre 65,4 % y 76,3 % en las cuatro clases.

Como consecuencia de estos patrones diferenciados, de las 137 imágenes del conjunto de prueba, 35 fueron clasificadas correctamente solo por uno de los modelos (Figura 24). Estos casos constituyen el margen sobre el cual el ensamble puede mejorar el desempeño, ya que, al combinar las probabilidades de ambos modelos, la clase correcta puede prevalecer aun cuando uno de ellos se equivoca. Para ello, el modelo que acierta debe asignarle una probabilidad suficientemente elevada y el modelo que se equivoca no debe concentrar su predicción en la clase incorrecta con una confianza demasiado alta.

Como se observa en la Figura 26, el ensamble logró recuperar 28 de estos 35 casos sin perder ninguna de las 80 imágenes clasificadas correctamente por ambos modelos. Esta recuperación se vio favorecida por el hecho de que, en 31 de los 35 casos, el modelo que se equivocaba asignaba a la clase real la segunda mayor probabilidad (Tabla E.1). Asimismo, la recuperación fue mayor cuando el modelo que acertaba era CVNXT-FINAL (20 de 21 casos) que cuando era CNN-FINAL (8 de 14), lo que resulta coherente con el mayor peso asignado a CVNXT-FINAL en el ensamble. En consecuencia, los casos no recuperados correspondieron principalmente a imágenes en las que CNN-FINAL acertaba con una probabilidad moderada y CVNXT-FINAL se equivocaba.

Como resultado, la sensibilidad del ensamble en cada clase igualó o se aproximó a la del mejor modelo individual: conservó buena parte de la alta sensibilidad de CNN-FINAL para Am (89,2 % frente a 94,6 %), igualó la de CNN-FINAL para EAo (78,9 %), alcanzó la de CVNXT-FINAL para HTA (75,0 %) e incluso superó a ambos modelos en MCH (69,2 % frente a 46,2 % y 65,4 %). Dado que la BA corresponde al promedio de las sensibilidades por clase, este comportamiento explica directamente su aumento respecto de ambos modelos individuales. Al mismo tiempo, el F1 fue superior al de ambos modelos en las cuatro clases, lo que indica que el ensamble no solo conservó la capacidad de detección, sino que también corrigió parte de los errores de sobreclasificación. Esto resulta importante desde el punto de vista clínico, ya que un modelo con tendencia a asignar sistemáticamente determinadas etiologías podría llevar al profesional médico a indicar con frecuencia estudios complementarios innecesarios.

Por el contrario, las 22 imágenes clasificadas incorrectamente por ambos modelos no fueron recuperadas. En 17 de ellas, ambos modelos predijeron la misma clase incorrecta, por lo que el promedio de sus probabilidades no podía favorecer a la clase real. En las 5 restantes, si bien los modelos se equivocaron hacia clases distintas, ninguno asignó a la clase real una probabilidad suficiente para que esta prevaleciera al combinar sus salidas. Estos resultados sugieren que se trata de imágenes particularmente difíciles de diferenciar, más que de errores atribuibles a un modelo en específico.

En conjunto, la implementación del ensamble resultó una estrategia efectiva. Con el reducido costo adicional que implica combinar las salidas de dos modelos ya entrenados, permitió mejorar la BA en 0,05 respecto del mejor modelo individual (CVNXT-FINAL) y obtener un clasificador más equilibrado, en el que ninguna clase presentó el desempeño marcadamente inferior observado en los modelos individuales. Esto respalda su utilización como modelo final en la interfaz VentrIA.

6.1.5 Análisis de errores

El análisis de la matriz de confusión del ensamble (Figura 25) permitió identificar algunas confusiones frecuentes entre las etiologías consideradas, entre ellas la clasificación de HTA como Am (19,4 %), de MCH como EAo (19,2 %), de EAo como HTA (13,2 %) y de MCH como HTA (11,5 %). Sin embargo, dado el tamaño reducido del conjunto de prueba, compuesto por entre 26 y 38 imágenes por clase, estos valores deben interpretarse con cautela. En estas condiciones, cada imagen representa alrededor de 3 puntos porcentuales de la sensibilidad de una clase, por lo que unos pocos errores se traducen en variaciones porcentuales considerables. En consecuencia, el orden de frecuencia entre las distintas confusiones puede estar influido por la variabilidad propia de una muestra de este tamaño, y no todas estas confusiones pueden considerarse, por sí solas, patrones generalizables del comportamiento del modelo.

Desde el punto de vista clínico, la similitud entre las manifestaciones electrocardiográficas de las distintas etiologías constituye una dificultad inherente al problema abordado. En línea con esto, resulta coherente que la Am haya sido la clase mejor reconocida por el ensamble (89,2 %), dado que es la etiología cuya expresión electrocardiográfica podría diferenciarse más fácilmente del resto. Por el contrario, las tres etiologías restantes presentan manifestaciones con mayor grado de superposición entre sí, en particular la HTA y la EAo, que comparten la sobrecarga de presión sobre el ventrículo izquierdo como mecanismo de hipertrofia. Si bien estas características permiten contextualizar las dificultades de clasificación, no explican necesariamente las confusiones observadas. De hecho, la confusión más frecuente, la clasificación de HTA como Am, no resulta esperable a partir de lo mencionado anteriormente.

Otro factor que limita el desempeño alcanzable es el tamaño del conjunto de datos de entrenamiento. Los modelos finales se ajustaron a partir de 549 imágenes lo cual constituye una cantidad reducida para aprender la variabilidad con la que cada etiología puede manifestarse en el ECG. Esta limitación resulta especialmente relevante en un problema en el que las diferencias entre clases son sutiles y en el que, como se describió en la Sección 2.2.3, los hallazgos característicos de cada etiología pueden no estar presentes en todos los pacientes. En estas condiciones, es posible que determinadas presentaciones electrocardiográficas estén representadas por muy pocos ejemplos en el conjunto de entrenamiento, o que no lo estén en absoluto, lo que dificulta que el modelo aprenda a reconocerlas.

Finalmente, otro aspecto a considerar es la distribución de clases en el conjunto de entrenamiento. Si bien el dataset no presenta un desbalance general marcado, la clase MCH contó con una cantidad de imágenes notablemente menor que las demás, aproximadamente un 30 % menos que el promedio del resto de las clases (104 frente a 148 imágenes). Esta diferencia pudo limitar la diversidad de ejemplos disponibles para el aprendizaje de las características de esta clase en específico, y así haber influido en el desempeño del modelo. En particular, esto podría explicar por qué la MCH presentó la menor sensibilidad del ensamble (69,2 %) y dos de las confusiones más frecuentes correspondieron a imágenes de esta clase clasificadas como EAo o HTA.

En conjunto, ninguno de los factores analizados permite explicar por sí solo los errores observados. Sin embargo, el comportamiento de los modelos individuales aporta un indicio adicional de que ciertas características de las imágenes podrían dificultar su clasificación. En particular, 22 de los 29 errores del ensamble correspondieron a imágenes que también fueron clasificadas incorrectamente por ambos modelos individuales y, en 17 de ellas, ambos coincidieron en asignar la misma clase incorrecta. Esto sugiere que algunas imágenes podrían presentar características, ya sea de la señal o de formato, que dificultan la clasificación para ambas arquitecturas. Para profundizar en esta hipótesis, sería necesario analizar estas imágenes individualmente y compararlas con las correctamente clasificadas, a fin de identificar qué aspectos de las mismas podrían influir en las decisiones de los modelos.

6.1.6 Interpretación clínica de las regiones de activación Grad-CAM

El análisis de los mapas de activación permitió evaluar cualitativamente si el modelo se apoya en información con relevancia fisiológica o en características no clínicas de la imagen para realizar la clasificación. Para ello, se contó con la colaboración de médicos cardiólogos, quienes, a partir de la aplicación VentrIA, evaluaron la correspondencia entre las regiones resaltadas por los mapas de calor y los hallazgos presentes en el trazado.

En las imágenes de Am correctamente clasificadas, la activación se ubicó con frecuencia sobre las derivaciones inferiores (DII, DIII y aVF) que presentaban complejos predominantemente negativos y profundos, mientras que DI y aVL presentaban complejos positivos. Esta distribución podría ser compatible con un patrón de pseudo-infarto o con un trastorno de la conducción intraventricular, ambos hallazgos descritos en pacientes con amiloidosis. En otros casos, la activación se distribuyó sobre varias derivaciones de los miembros cuyos complejos QRS presentaban una amplitud muy reducida, lo que podría ser compatible con el bajo voltaje que puede presentar esta patología.

En las imágenes de MCH correctamente clasificadas, los focos de activación coincidieron en algunos casos con ondas T negativas y simétricas, tanto en las derivaciones precordiales como en las laterales, compatibles con alteraciones de la repolarización que pueden observarse en esta patología. En otros, la activación se ubicó sobre derivaciones con complejos QRS de gran amplitud. Si bien el aumento de voltaje puede formar parte de la expresión electrocardiográfica de la MCH, también se presenta en otras etiologías de HVI, por lo que esta correspondencia no constituye evidencia de un patrón específico de la enfermedad. No obstante, sugiere que el modelo se apoyó en manifestaciones de la hipertrofia presentes en el trazado.

Por su parte, en las imágenes de EAo, la correspondencia entre las regiones de mayor activación y hallazgos electrocardiográficos específicos resultó menos evidente. Los mapas mostraron una activación intensa en la franja superior y, en algunos casos, en los márgenes laterales de la imagen. Debido a la resolución espacial de los mapas, no fue posible determinar si la activación en la franja superior correspondía a las anotaciones numéricas o a los complejos QRS de las derivaciones DI y V1, ubicadas en esa región. Asimismo, la inspección de las imágenes de entrenamiento no permitió identificar una asociación clara entre esta clase y una mayor presencia de dichas anotaciones o de márgenes laterales más amplios, ya que características similares también se observaban en imágenes de otras etiologías. Por lo tanto, no se encontró evidencia suficiente para afirmar con seguridad que el modelo utilizara estos elementos como criterio para identificar la EAo.

De manera similar, en las imágenes de HTA tampoco se identificaron hallazgos electrocardiográficos específicos que permitieran interpretar las regiones de mayor activación. Los mapas presentaron, en general, una distribución más difusa, extendida sobre varias derivaciones y cubriendo una mayor proporción de la imagen. En algunos casos, al igual que en EAo, también se observó activación en la franja superior y en los márgenes laterales, aunque tampoco fue posible asociar estas regiones a una característica propia de las imágenes de esta clase que indicara un aprendizaje basado en el formato.

Un aspecto interesante señalado durante la revisión médica fue que numerosas imágenes, tanto correcta como incorrectamente clasificadas, no presentaban hallazgos evidentes para diferenciar a simple vista las etiologías, y que algunas de ellas incluso carecían de signos electrocardiográficos claros de HVI. Si bien en algunos registros se identificaron hallazgos como fibrilación auricular o voltajes elevados, estos no permitieron establecer la patología con certeza. En este sentido, varios de los médicos destacaron la complejidad de establecer un diagnóstico únicamente a partir del ECG, y mencionaron el uso habitual de la ecocardiografía como estudio complementario en su práctica clínica.

Estos comentarios ponen de manifiesto la dificultad inherente al problema abordado. El ECG registra la actividad eléctrica del corazón, por lo que refleja de manera indirecta los cambios estructurales, y sus alteraciones pueden ser escasas o ausentes según la magnitud de la hipertrofia

y el estadio de la enfermedad, información que no se encontraba disponible para las imágenes del dataset. Esto condiciona, en cierta medida, la utilidad de los mapas de activación, ya que su valor clínico depende en parte de que el trazado presente hallazgos reconocibles. Cuando estos son poco evidentes, la interpretación de las regiones resaltadas resulta más difícil.

En conjunto, los mapas de calor generados con Grad-CAM permitieron identificar, en algunas imágenes, correspondencias plausibles entre las regiones de activación y hallazgos electrocardiográficos compatibles con determinadas etiologías, especialmente en Am y MCH. Sin embargo, en otras la interpretación clínica de las regiones resaltadas resultó menos clara, incluso en casos correctamente clasificados.

6.1.7 Usabilidad y utilidad clínica de la interfaz

Los resultados de la encuesta presentados en la Sección 5.6 indican una recepción favorable de VentrIA por parte de los cardiólogos que la evaluaron. Los ítems vinculados a la usabilidad obtuvieron puntuaciones medias cercanas al máximo, en particular la claridad de la información presentada en pantalla (4,67) y la facilidad de navegación (4,50), lo que sugiere que la interfaz resultó sencilla de utilizar e interpretar. Asimismo, los participantes la consideraron útil como herramienta de apoyo para la evaluación de la etiología de la HVI (4,33). En concordancia con estas valoraciones, VentrIA obtuvo un puntaje general de 8,67 sobre 10, y los participantes señalaron una alta probabilidad de incorporarla a su práctica clínica (4,33).

En contraste, la relevancia clínica de las regiones resaltadas por los mapas de calor fue el ítem con menor puntuación media (3,83). Este resultado es coherente con lo discutido en la sección anterior, ya que los mapas mostraron una correspondencia clara con hallazgos electrocardiográficos solo en una parte de las imágenes. No obstante, los participantes valoraron positivamente la posibilidad de conocer qué regiones del ECG consideró el modelo para realizar su predicción (4,33), lo que sugiere que, aun cuando las regiones resaltadas no siempre resulten clínicamente interpretables, esta información contribuye a valorar críticamente el resultado obtenido.

Entre las sugerencias de mejora, los profesionales consultados destacaron la posibilidad de incorporar otras fuentes de información, como imágenes de ecocardiograma o datos clínicos del paciente. Esta sugerencia se fundamenta en que, en la práctica clínica, el diagnóstico etiológico de la HVI rara vez se establece a partir de un ECG aislado. La incorporación de información complementaria podría permitir contextualizar los hallazgos electrocardiográficos y contribuir a una evaluación etiológica más completa.

6.2 Limitaciones y alcance de los modelos

Los resultados obtenidos en este trabajo deben interpretarse considerando una serie de limitaciones asociadas tanto a los datos disponibles como al alcance del proyecto. En particular, algunas decisiones metodológicas debieron adecuarse a los recursos computacionales y al tiempo disponibles, lo que acotó la exploración de ciertas alternativas. Estas limitaciones no invalidan los resultados obtenidos, pero deben considerarse al momento de interpretarlos para evaluar el desempeño de los modelos y la herramienta desarrollada.

6.2.1 Limitaciones asociadas a los datos

El conjunto de datos utilizado constituye una de las principales limitaciones de este trabajo. Por un lado, el conjunto de entrenamiento del dataset ICBA es reducido en comparación con lo habitual en el desarrollo de modelos de aprendizaje profundo. Esta restricción motivó la construcción del dataset sintético, que, si bien demostró contribuir al desempeño final de los modelos, no compensa por completo la escasez de ejemplos de las cuatro etiologías objetivo. Esto limita la capacidad de

los modelos para aprender los patrones asociados a cada una de ellas, en particular en las clases menos representadas, como la MCH.

Por otro lado, como se mencionó anteriormente, el tamaño reducido del conjunto de prueba limita la precisión de la evaluación. Al disponer de pocas imágenes por clase, las métricas obtenidas, especialmente a nivel de cada clase, son sensibles a la clasificación de unos pocos casos. Incluso una variación en la composición del conjunto de prueba podría conducir a resultados considerablemente distintos. En consecuencia, si bien los resultados permiten caracterizar el desempeño de los modelos sobre los datos evaluados, una evaluación sobre un conjunto de mayor tamaño permitiría obtener estimaciones más precisas y determinar con mayor confianza en qué medida estos resultados se mantienen ante nuevos registros.

Asimismo, el formato de las imágenes en el dataset ICBA no se distribuye de manera balanceada entre las clases. El conjunto de prueba presenta una distribución similar a la del conjunto de entrenamiento en cuanto a la relación entre formato y clase. Disponer de imágenes de todas las etiologías en los distintos formatos permitiría comparar el desempeño del modelo dentro de cada uno de ellos y obtener evidencia más concreta sobre la influencia de estas características en la clasificación. Idealmente, un conjunto de datos en el que todas las etiologías estuvieran representadas de manera equilibrada en cada formato reduciría la asociación entre ambas variables, favoreciendo así que el modelo base sus predicciones en el contenido del trazado electrocardiográfico.

6.2.2 Limitaciones del diseño experimental

El diseño experimental también presenta algunas limitaciones que deben considerarse al interpretar los resultados. La búsqueda de hiperparámetros mediante Optuna se realizó utilizando una semilla fija tanto para el muestreador TPE como para los distintos componentes estocásticos del entrenamiento. En consecuencia, la configuración seleccionada como óptima en cada búsqueda corresponde a la que obtuvo el menor *val_loss* bajo esa realización particular del proceso de entrenamiento y no necesariamente a una configuración que resulte óptima de manera consistente frente a diferentes inicializaciones. Esta consideración adquiere especial relevancia en el contexto del dataset ICBA, donde el reducido número de ejemplos puede aumentar la sensibilidad de los resultados a la inicialización de los pesos. Una alternativa para reducir esta dependencia consiste en repetir cada *trial* utilizando múltiples semillas y considerar el desempeño promedio de cada configuración. Sin embargo, esta estrategia fue descartada de la metodología debido al incremento sustancial del costo computacional y tiempo de entrenamiento que implicaría.

Por otra parte, la selección de los modelos base se realizó a partir de su desempeño sobre el conjunto de prueba del dataset sintético. Esta decisión permitió reducir la cantidad de arquitecturas que debían trasladarse a la etapa de ajuste fino sobre el dataset ICBA, evitando realizar una búsqueda de hiperparámetros y una validación cruzada completa para todas las arquitecturas candidatas. Sin embargo, el desempeño sobre el dataset sintético no necesariamente anticipa el comportamiento de una arquitectura sobre el problema clínico. De hecho, los resultados obtenidos mostraron que las representaciones de los modelos preentrenados se adaptaron mejor a la nueva tarea, aun cuando su desempeño en la etapa de preentrenamiento había sido inferior al de los modelos propios. En consecuencia, las arquitecturas descartadas en la etapa sintética no fueron evaluadas posteriormente sobre el dataset ICBA, por lo que no puede descartarse que alguna de ellas hubiera alcanzado un desempeño competitivo en el problema clínico.

En conjunto, estas decisiones permitieron mantener un protocolo experimental viable en términos computacionales y concentrar los recursos disponibles en las configuraciones seleccionadas. Si bien limitan la exploración de alternativas, no invalidan los resultados obtenidos, aunque sí acotan el grado en que puede afirmarse que las configuraciones seleccionadas constituyen las óptimas para el problema abordado.

6.2.3 Alcance de la herramienta

Dado que los modelos fueron desarrollados a partir de un conjunto de datos específico, su alcance se encuentra condicionado por las características de los registros utilizados durante el entrenamiento y la evaluación. En primer lugar, el dataset proviene de una única institución, el ICBA, por lo que los modelos pueden haber aprendido características propias tanto del formato de presentación de los informes como de las señales obtenidas con sus equipos de adquisición. A esto se le suma que se utilizaron, exclusivamente, las imágenes del conjunto de datos que presentaban una disposición de las derivaciones en 6×2 horizontal, y que incluso el dataset sintético fue diseñado para reproducir esta presentación. Asimismo, dado que la mayoría de los pacientes atendidos en esta institución provienen del área metropolitana de Buenos Aires, tampoco fue posible evaluar el desempeño de los modelos en poblaciones con características demográficas diferentes. En consecuencia, los resultados obtenidos no pueden extrapolarse directamente a electrocardiogramas provenientes de otras instituciones, poblaciones, equipos o formatos sin una validación externa.

En segundo lugar, la herramienta desarrollada no contempla todas las posibles causas de HVI. Existen otras etiologías y condiciones capaces de producir este fenotipo que, dada su menor prevalencia, no fueron incluidas en el problema de clasificación. Frente a un ECG correspondiente a uno de estos escenarios, el modelo necesariamente le asignaría una de las cuatro clases disponibles, incluso si ninguna fuera adecuada. Por lo tanto, resulta importante considerar esta limitación al interpretar las predicciones, teniendo presente que la etiología real del paciente podría no encontrarse entre las cuatro clases contempladas por el modelo.

Por último, otra limitación asociada a la formulación de la tarea es que el modelo no permite identificar más de una etiología de HVI en un mismo ECG. Al tratarse de modelos de clasificación multiclase, cada estudio queda asociado a una única de las cuatro etiologías consideradas, en concordancia con el etiquetado disponible en el dataset del ICBA. Sin embargo, algunas de estas condiciones podrían llegar a coexistir en un mismo paciente y contribuir conjuntamente al remodelado ventricular, situación que la herramienta actual no permite representar. En estos casos, la predicción del modelo reflejaría, a lo sumo, solo una de las etiologías presentes.

6.3 Justificación del enfoque basado en imágenes

Como se describió en la Sección 3, diversos trabajos han logrado reconstruir la señal a partir de imágenes de ECG con elevada precisión. Por este motivo, inicialmente se consideró la alternativa de extraer previamente la señal y abordar el problema de clasificación a partir de ella. Este enfoque presenta ventajas potenciales, ya que la señal digital prescinde de elementos de la imagen ajenos al trazado, como la grilla, las anotaciones o los márgenes, que pueden actuar como fuentes de sesgo durante el entrenamiento.

Sin embargo, esta alternativa presentaba dificultades en el contexto de este trabajo. En primer lugar, en las imágenes del ICBA la grilla presenta un color y un grosor similares a los del trazado, lo que dificulta su separación y podría afectar la calidad de la señal extraída, sobre todo en las regiones donde ambos elementos se superponen. En segundo lugar, no se contaba con acceso a las señales digitales originales de los estudios, lo que impedía tanto entrenar un digitalizador propio como validar herramientas *open source* sobre la base de datos utilizada. Incluso los métodos basados en técnicas de procesamiento de imágenes, que no requieren entrenamiento, necesitan de la señal original para evaluar la calidad de la reconstrucción. Sin esta referencia, cualquier error de digitalización se habría propagado al clasificador, y ante un desempeño insatisfactorio no habría sido posible determinar si este se debía a limitaciones del clasificador o a errores en la señal reconstruida.

En consecuencia, se optó por utilizar directamente la imagen como entrada a los modelos, priorizando un enfoque cuyo desempeño pudiera evaluarse de forma integral.

6.4 Comparación con trabajos previos de la literatura

La comparación directa de los resultados obtenidos con los reportados en la literatura se ve limitada por diferencias sustanciales en la formulación del problema. Los trabajos basados en imágenes de ECG descritos en la Sección 3 abordaron la detección individual de cada patología frente a pacientes que no la presentan, es decir, una tarea binaria en la que la clase negativa incluye sujetos sin HVI. En este trabajo, en cambio, todas las clases corresponden a etiologías asociadas a la HVI y el objetivo consiste en diferenciarlas entre sí, lo que plantea una dificultad adicional debido a la superposición de sus manifestaciones electrocardiográficas.

El antecedente más cercano es LVH-Net [85], que aborda la tarea de clasificación etiológica, aunque a partir de la señal digital de ECG, complementada con variables clínicas como la edad y el sexo. Además, contempla algunas categorías adicionales y fue desarrollado con un volumen de datos considerablemente superior al disponible en este trabajo. En LVH-Net, la Am fue la etiología mejor identificada (0,95), seguida por la MCH (0,92) y la EAo (0,90), mientras que la HVI hipertensiva presentó el desempeño más bajo (0,76). Sin embargo, los valores de AUROC reportados para cada etiología se calcularon frente a la clase normal, es decir que reflejan la capacidad del modelo para distinguir a los pacientes con una determinada etiología de aquellos sin HVI, no para diferenciar las etiologías entre sí. Esta última tarea, correspondiente a la abordada en este trabajo, resulta considerablemente más exigente, pues para distinguir una patología de un trazado normal, el modelo puede apoyarse en cualquier alteración presente en el ECG, mientras que para diferenciar entre etiologías debe identificar diferencias más sutiles. Por este motivo, los resultados de LVH-Net no son directamente comparables con los de este trabajo, incluso si se calculara la misma métrica. A esto, se suman las diferencias en la modalidad de entrada, la composición de las clases y el volumen de datos utilizado entre ambos modelos, factores que también dificultan una comparación clara.

Aun así, como observación se puede mencionar una coincidencia en el orden de desempeño entre clases. En LVH-Net la Am fue la etiología mejor identificada y la HVI hipertensiva la de menor desempeño, al igual que en el ensamble desarrollado, donde estas clases obtuvieron el mayor y el menor F1, respectivamente. Esta coincidencia podría estar relacionada con qué tan distintivas resultan las manifestaciones electrocardiográficas de cada una de estas patologías para distinguirse del resto. No obstante, todas las diferencias mencionadas entre ambos estudios no permiten establecer si esta coincidencia responde a este fenómeno.

Hasta donde alcanza la revisión bibliográfica realizada, no se identificaron trabajos que abordaran la clasificación multiclase simultánea de estas cuatro etiologías utilizando únicamente imágenes de ECG. En este sentido, el principal aporte de este trabajo consiste en explorar esta tarea directamente sobre imágenes, sin requerir el acceso a la señal digital ni la incorporación de variables clínicas adicionales. Si bien los resultados obtenidos están sujetos a las limitaciones discutidas anteriormente, muestran la viabilidad de este enfoque, incluso con la cantidad reducida de imágenes empleadas. Asimismo, aunque no es posible asegurar su generalización a imágenes de otros formatos o instituciones, el sistema fue desarrollado sobre el formato de los estudios utilizado en el ICBA, por lo que igualmente podría resultar de utilidad como herramienta de apoyo dentro de esta institución.

6.5 Posibles mejoras y perspectivas futuras

A partir de los resultados y limitaciones identificadas en este trabajo, se plantean distintas líneas de mejora y extensión.

En primer lugar, dado que el tamaño reducido del dataset ICBA constituye una de las principales restricciones del sistema actual, sería de interés ampliar la cantidad de datos disponibles, ya sea mediante la incorporación de nuevos estudios de la misma institución o de estudios provenientes

de diferentes centros. Esto permitiría evaluar hasta qué punto una mayor cantidad y diversidad de datos puede mejorar el desempeño de los modelos y favorecer su generalización a distintas condiciones de adquisición. En paralelo, el dataset sintético también podría ampliarse para incorporar imágenes con los formatos presentes en los nuevos datos y mantener así su utilidad como etapa de preentrenamiento.

En segundo lugar, la incorporación de ECG normales permitiría ampliar el espectro de análisis de la herramienta más allá de la diferenciación entre las cuatro etiologías consideradas. Actualmente, el modelo debe asignar necesariamente una de estas clases a cualquier ECG analizado, por lo que no contempla explícitamente la posibilidad de que un registro no presente alteraciones compatibles con HVI. Contar con una cantidad suficiente de estudios normales permitiría desarrollar un esquema de *screening* de HVI previo a la clasificación etiológica, lo cual podría resultar de interés dada la baja sensibilidad de los criterios electrocardiográficos utilizados actualmente para su detección. Para ello, podría evaluarse un modelo de cinco clases que incorpore la categoría normal o, alternativamente, un esquema de clasificación en dos etapas. En este último caso, sería necesario desarrollar un primer modelo binario capaz de identificar ECG con características compatibles con HVI y, únicamente en estos casos, procesarlos con el modelo desarrollado en este trabajo para estimar su posible etiología. Este enfoque permitiría extender el uso de la herramienta hacia una instancia más temprana de la evaluación y podría contribuir a levantar la sospecha de HVI antes de la realización de estudios de imagen como el ecocardiograma.

En tercer lugar, una perspectiva futura más ambiciosa consistiría en integrar VentrIA con los sistemas informáticos del ICBA, particularmente con la historia clínica electrónica, una posibilidad sugerida por el sector de innovación de la institución y por los médicos que participaron en la evaluación de la herramienta. Actualmente, su uso requiere descargar el estudio y cargar manualmente la imagen en la aplicación, mientras que en la práctica los profesionales consultan los ECG directamente desde la historia clínica. Una integración con este entorno permitiría analizar automáticamente los estudios ya disponibles, facilitando la incorporación de la herramienta al flujo de trabajo habitual. Además, el procesamiento de los estudios dentro de la propia infraestructura de la institución evitaría la necesidad de transferir las imágenes a sistemas externos, favoreciendo la protección de la confidencialidad de los datos clínicos.

Asimismo, más allá de simplificar el acceso al ECG, esta integración permitiría incorporar información adicional del paciente disponible en la historia clínica, como sus antecedentes clínicos o los resultados de otros estudios, entre ellos el ecocardiograma. El acceso conjunto a estas fuentes abriría la posibilidad de desarrollar modelos que integren información de distinta naturaleza, con el potencial de mejorar el desempeño y de aportar elementos que no están contenidos únicamente en el ECG. En este contexto, podría evaluarse también la transición del problema de clasificación multiclase hacia una formulación *multilabel*, que contemple la coexistencia de distintas etiologías en un mismo paciente. Esta formulación resultaría más viable al combinar el ECG con otras fuentes de información que al intentar identificar etiologías coexistentes únicamente a partir de los patrones electrocardiográficos.

De esta manera, VentrIA podría evolucionar desde una herramienta de clasificación de una imagen aislada hacia un sistema de apoyo integrado para la evaluación de la HVI y sus posibles etiologías. No obstante, cualquiera de estas extensiones debería acompañarse de una validación del desempeño de los modelos sobre conjuntos de datos más amplios y diversos, así como de una evaluación de la interfaz con un mayor número de profesionales, como paso necesario antes de considerar su incorporación al proceso diagnóstico. Asimismo, sería de interés analizar, en condiciones reales de práctica clínica, si su uso modifica la interpretación de los profesionales o contribuye a una orientación diagnóstica más temprana.

7 Conclusiones

En este trabajo se desarrolló una herramienta de apoyo diagnóstico basada en redes neuronales convolucionales, capaz de clasificar cuatro patologías asociadas a la HVI (Am, HTA, EAo y MCH) a partir de imágenes de ECG de 12 derivaciones. La propuesta busca aprovechar la información contenida en un estudio accesible y ampliamente utilizado en la práctica cardiológica para contribuir a la evaluación etiológica de la HVI, ofreciendo a los profesionales médicos una opinión adicional que complemente su interpretación del trazado.

Los objetivos planteados al inicio del proyecto fueron cumplidos. El ensamble de los modelos CNN-FINAL y CVNXT-FINAL alcanzó una BA de 78,09 % sobre el conjunto de prueba del dataset ICBA, superando el umbral del 70 % establecido, incluso utilizando una métrica más exigente que la exactitud global. Los experimentos realizados mostraron que el preentrenamiento sobre el dataset sintético fue un componente clave para lograr estos resultados. Sin esta etapa, la red de diseño propio no logró aprender a discriminar entre las clases, mientras que en ConvNeXtTiny, la arquitectura preentrenada en ImageNet, el desempeño disminuyó. Asimismo, la combinación de ambas arquitecturas mediante un ensamble mejoró el desempeño de los modelos individuales, aprovechando la complementariedad de sus predicciones.

En cuanto a la interpretabilidad, los mapas de Grad-CAM mostraron que, en algunos casos, el modelo concentró sus activaciones en regiones del trazado compatibles con manifestaciones electrocardiográficas descritas para estas patologías, mientras que en otros las regiones destacadas fueron menos específicas. No obstante, los profesionales que evaluaron la herramienta consideraron útil conocer las regiones de la imagen en las que se basó el modelo, ya que, aun en los casos en los que no resultan clínicamente interpretables, les permite contar con una referencia adicional para valorar más críticamente la predicción. En términos generales, la aplicación tuvo una recepción positiva por parte de los médicos, quienes manifestaron su interés en incorporarla en su práctica clínica. Si bien estas valoraciones constituyen una primera aproximación favorable a la experiencia de uso, será necesario profundizar su evaluación para determinar su utilidad en condiciones reales de práctica clínica.

Hasta donde alcanza la revisión bibliográfica realizada, no se identificaron trabajos previos que abordaran esta tarea multiclase de manera conjunta utilizando únicamente imágenes de ECG. En este sentido, VentrIA constituye una primera aproximación a este enfoque del problema y sienta las bases para profundizar en el desarrollo y la evaluación de modelos capaces de aprovechar la información contenida en estos registros. A pesar de sus limitaciones, principalmente las asociadas al tamaño y a las características del conjunto de datos disponible, este trabajo muestra la viabilidad de abordar la clasificación de estas cuatro etiologías directamente a partir de imágenes de ECG, y contribuye a revalorizar este estudio como fuente de información útil en este contexto.

Más allá de los resultados obtenidos, este trabajo pone de manifiesto que el ECG, un estudio simple y presente en la rutina clínica, todavía tiene información por ofrecer cuando se lo analiza con nuevas tecnologías. El valor de herramientas como VentrIA no reside en reemplazar a los estudios de mayor complejidad ni al criterio médico, sino en extraer más información de un estudio ya disponible, acompañando al profesional en su interpretación y contribuyendo a una atención más rápida y de mayor calidad en beneficio del paciente.

8 Bibliografía

[1] Organización Mundial de la Salud (OMS), "Enfermedades cardiovasculares (ECV)," Nota descriptiva, Junio 2024. [Online]. Available: https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)

[2] L. Calò, O. Lanza, C. Crescenzi, C. Parisi, G. Panattoni, A. Martino, M. Rebecchi, P. Tarzia, P. Ciampi, F. Romeo, S. Canestrelli, E. Silvetti, and E. De Ruvo, "The value of the 12-lead electrocardiogram in the prediction of sudden cardiac death," *European Heart Journal Supplements*, vol. 25, no. Supplement_C, pp. C218–C226, 2023.

[3] E. Silvetti, O. Lanza, F. Romeo, A. Martino, E. Fedele, C. Lanzillo, C. Crescenzi, F. Fanisio, and L. Calò, "The pivotal role of ECG in cardiomyopathies," *Frontiers in Cardiovascular Medicine*, vol. 10, p. 1178163, 2023.

[4] S. Banthiya, A. Agrawal, D. Rai, M. Chowdhury, S. Pan, and S. S. Naidu, "Diagnostic Approach to Left Ventricular Hypertrophy: A Review," *US Cardiology Review*, 2026.

[5] G. D. Aquaro, E. Corsi, G. Todiere, C. Grigoratos, A. Barison, V. Barra, G. Di Bella, M. Emdin, F. Ricci, and A. Pingitore, "Magnetic resonance for differential diagnosis of left ventricular hypertrophy: Diagnostic and prognostic implications," *Journal of Clinical Medicine*, vol. 11, no. 3, p. 651, 2022.

[6] M. K. Burrage and V. M. Ferreira, "Cardiovascular Magnetic Resonance for the Differentiation of Left Ventricular Hypertrophy," *Current Heart Failure Reports*, 2020.

[7] J. Vogel, S. Jura, S. Settelmeier *et al.*, "Delays in diagnosis and treatment of ATTR cardiac amyloidosis: A real-world data analysis," *ESC Heart Failure*, vol. 12, no. 4, pp. 2969–2975, 2025.

[8] S. S. Naidu *et al.*, "Frequency and clinicoeconomic impact of delays to definitive diagnosis of obstructive hypertrophic cardiomyopathy in the United States," *Journal of Medical Economics*, vol. 26, no. 1, pp. 682–690, 2023.

[9] K. C. Siontis, P. A. Noseworthy, Z. I. Attia, and P. A. Friedman, "Artificial intelligence-enhanced electrocardiography in cardiovascular disease management," *Nature Reviews Cardiology*, vol. 18, no. 7, pp. 465–478, 2021.

[10] Y. Ansari, O. Mourad, K. Qaraqe, and E. Serpedin, "Deep learning for ECG arrhythmia detection and classification: an overview of progress for period 2017–2023," *Frontiers in Physiology*, vol. 14, p. 1246746, 2023.

[11] L. D. Escobar Quintero, R. D. Daza Herrera, R. Viloria Amaya, and L. Torres Obregon, "Anteproyecto – desarrollo del prototipo de un sistema de monitoreo cardíaco ambulatorio implementando iot," https://www.researchgate.net/publication/346973803_ANTEPROYECTO-DESARROLLO_DEL_PROTOTIPO_DE_UN_SISTEMA_DE_MONITOREO_CARDIACO_AMBULATORIO_IMPLEMENTANDO_IoT, 2020, preprint. DOI: 10.13140/RG.2.2.27887.05289.

[12] Kenhub, "Sistema de conducción del corazón," https://www.kenhub.com/es/library/anatomia-es/sistema-de-conduccion-del-corazon, 2024, consultado en 2025.

[13] A. C. Guyton and J. E. Hall, *Tratado de Fisiología Médica*, 14th ed. Elsevier, 2021.

[14] AMBOSS, "Ecg," https://www.amboss.com/us/knowledge/ecg, 2025, accedido el 30 de noviembre de 2025.

[15] R. J. Huszar, *Interpretación del ECG*, 4th ed. Elsevier España, 2014.

[16] National Center for Biotechnology Information, "Electrocardiography," https://www.ncbi.nlm.nih.gov/books/NBK2214/, 2015, en: NCBI Bookshelf. Accedido: junio 2025.

[17] Medigraphic, "El electrocardiograma y sus aplicaciones clínicas," https://www.medigraphic.com/pdfs/archi/ac-2003/ac031f.pdf, 2003, accedido: junio 2025.

[18] MSD Manuals, "Electrocardiografía," https://www.msdmanuals.com/es/professional/trastornos-cardiovasculares/pruebas-y-procedimientos-cardiovasculares/electrocardiograf%C3%ADa, 2025, accedido: junio 2025.

[19] E. Fischmann, J. Cosma, and H. V. Pipberger, "Beat to beat and observer variation of the electrocardiogram," *American Heart Journal*, vol. 75, no. 4, pp. 465–473, 1968.

[20] D. Massel, "Observer variability in ecg interpretation for thrombolysis eligibility: experience and context matter," *Journal of Thrombosis and Thrombolysis*, vol. 15, no. 3, pp. 131–140, 2003.

[21] H. Dhutia, A. Malhotra *et al.*, "Inter-rater reliability and downstream financial implications of electrocardiography screening in young athletes," *Circulation: Cardiovascular Quality and Outcomes*, vol. 10, no. 8, p. e003306, 2017.

[22] D. Ricciardi, G. Vetta, A. Nenna, F. Picarelli *et al.*, "Current diagnostic ecg criteria for left ventricular hypertrophy: is it time to change paradigm in the analysis of data?" *Journal of Cardiovascular Medicine*, vol. 21, no. 2, pp. 128–133, 2020.

[23] K. M. Herum, I. G. Lunde, A. D. McCulloch, and G. Christensen, "The Soft- and Hard-Heartedness of Cardiac Fibroblasts: Mechanotransduction Signaling Pathways in Fibrosis of the Heart," *Journal of Clinical Medicine*, vol. 6, no. 5, p. 53, 2017.

[24] M. Nakamura and J. Sadoshima, "Mechanisms of physiological and pathological cardiac hypertrophy," *Nature Reviews Cardiology*, vol. 15, no. 7, pp. 387–407, 2018.

[25] P. Shams, S. H. Pujari, and K. Marwaha, "Left Ventricular Hypertrophy," https://www.ncbi.nlm.nih.gov/books/NBK557534/, 2026, en: StatPearls [Internet]. Accedido: agosto 2026.

[26] A. Peikert, M. Fontana, S. D. Solomon, and T. Thum, "Left ventricular hypertrophy and myocardial fibrosis in heart failure with preserved ejection fraction: mechanisms and treatment," *European Heart Journal*, vol. 47, no. 1, pp. 37–53, 2026.

[27] Z. Husti, A. Varró, and I. Baczkó, "Arrhythmogenic Remodeling in the Failing Heart," *Cells*, vol. 10, no. 11, p. 3203, 2021.

[28] M. H. Stewart, C. J. Lavie, S. Shah *et al.*, "Prognostic Implications of Left Ventricular Hypertrophy," *Progress in Cardiovascular Diseases*, 2018.

[29] D. A. Bluemke, R. A. Kronmal, J. A. C. Lima *et al.*, "The Relationship of Left Ventricular Mass and Geometry to Incident Cardiovascular Events: The MESA Study," *Journal of the American College of Cardiology*, 2008.

[30] B. Yetis Sayin and A. Oto, "Left Ventricular Hypertrophy: Etiology-Based Therapeutic Options," *Cardiology and Therapy*, 2022.

[31] World Health Organization, "Hypertension," https://www.who.int/news-room/fact-sheets/detail/hypertension, 2025, fact Sheet. Accedido: agosto 2026.

[32] C. Cuspidi, C. Sala, F. Negri, G. Mancia, A. Morganti, and Italian Society of Hypertension, "Prevalence of left-ventricular hypertrophy in hypertension: an updated review of echocardiographic studies," *Journal of Human Hypertension*, vol. 26, no. 6, pp. 343–349, 2012.

[33] S. Kawasoe and M. Ohishi, "Regression of left ventricular hypertrophy," *Hypertension Research*, vol. 47, no. 5, pp. 1225–1226, 2024.

[34] S. N. Ahmed, R. Jhaj, B. Sadasivam, and R. Joshi, "Regression of the Left Ventricular Hypertrophy in Patients with Essential Hypertension on Standard Drug Therapy," *Discoveries (Craiova)*, vol. 8, no. 3, p. e115, 2020.

[35] American Heart Association, "Problem: Aortic Valve Stenosis," https://www.heart.org/en/health-topics/heart-valve-problems-and-disease/heart-valve-problems-and-causes/problem-aortic-valve-stenosis, accedido: agosto 2026.

[36] R. Ancona and S. Comenale Pinto, "Epidemiology of aortic valve stenosis (AS) and of aortic valve incompetence (AI): is the prevalence of AS/AI similar in different parts of the world?" https://www.escardio.org/communities/councils/cardiology-practice/scientific-documents-and-publications/ejournal/volume-18/epidemiology-of-aortic-valve-stenosis-as-and-of-aortic-valve-incompetence-ai/, 2020, eSC E-Journal of Cardiology Practice, Vol. 18. Accedido: agosto 2026.

[37] R. L. Osnabrugge, D. Mylotte, S. J. Head, N. M. Van Mieghem, V. T. Nkomo, C. M. LeReun, A. J. Bogers, N. Piazza, and A. P. Kappetein, "Aortic stenosis in the elderly: Disease prevalence and number of candidates for transcatheter aortic valve replacement: A meta-analysis and modeling study," *Journal of the American College of Cardiology*, vol. 62, no. 11, pp. 1002–1012, 2013.

[38] E. J. Stein, W. F. Fearon, S. Elmariah *et al.*, "Left Ventricular Hypertrophy and Biomarkers of Cardiac Damage and Stress in Aortic Stenosis," *Journal of the American Heart Association*, vol. 11, no. 7, p. e023466, 2022.

[39] R. Reis Santos, J. Abecasis, S. Maltês *et al.*, "Cardiac magnetic resonance patterns of left ventricular remodeling in patients with severe aortic stenosis referred to surgical aortic valve replacement," *Scientific Reports*, vol. 14, p. 7085, 2024.

[40] F. Praz, M. A. Borger, J. Lanz, M. Marin-Cuartas *et al.*, "2025 ESC/EACTS guidelines for the management of valvular heart disease," *European Heart Journal*, vol. 46, no. 44, pp. 4635–4736, 2025.

[41] J. Bennett, G. D. Thornton, C. Nitsche *et al.*, "Left Ventricular Hypertrophy in Aortic Stenosis: Early Cell and Matrix Regression 2 Months Post-Aortic Valve Replacement," *Circulation: Cardiovascular Imaging*, vol. 17, no. 12, p. e017425, 2024.

[42] C. Semsarian, J. Ingles, M. S. Maron *et al.*, "New perspectives on the prevalence of hypertrophic cardiomyopathy," *Journal of the American College of Cardiology*, vol. 65, no. 12, pp. 1249–1254, 2015.

[43] D. Massera, M. V. Sherrid, M. S. Maron *et al.*, "How common is hypertrophic cardiomyopathy... really?: Disease prevalence revisited 27 years after CARDIA," *International Journal of Cardiology*, vol. 382, pp. 64–67, 2023.

[44] C. E. Seidman and J. G. Seidman, "Identifying sarcomere gene mutations in hypertrophic cardiomyopathy: a personal history," *Circulation Research*, vol. 108, no. 6, pp. 743–750, 2011.

[45] C. M. Wolf, "Hypertrophic cardiomyopathy: genetics and clinical perspectives," *Cardiovascular Diagnosis and Therapy*, vol. 9, no. S2, 2019.

[46] S. R. Ommen, C. Y. Ho, I. M. Asif *et al.*, "2024 AHA/ACC/AMSSM/HRS/PACES/SCMR Guideline for the Management of Hypertrophic Cardiomyopathy," *Circulation*, vol. 149, no. 23, pp. e1239–e1311, 2024.

[47] G. Papingiotis, L. Basmpana, and D. Farmakis, "Cardiac amyloidosis: epidemiology, diagnosis and therapy," https://www.escardio.org/communities/councils/cardiology-practice/scientific-documents-and-publications/ejournal/volume-19/cardiac-amyloidosis-epidemiology-diagnosis-and-therapy/, 2021, eSC E-Journal of Cardiology Practice, Vol. 19. Accedido: agosto 2026.

[48] M. Rossi *et al.*, "Re-Definition of the Epidemiology of Cardiac Amyloidosis," *Biomedicines*, vol. 10, no. 7, p. 1566, 2022.

[49] P. Collins, N. Melinis, W. Y. Chung, F. Hefni, R. Hegde, O. Ozbey, B. Cheng, and T. Y. Loo, "Misdiagnosis rates in ATTR-CM patients and associated symptoms," *European Heart Journal*, vol. 46, no. Supplement_1, p. ehaf784.2706, 2025.

[50] C. Mancusi, G. de Simone, J. Brguljan Hitij, I. Sudano, F. Mahfoud, G. Parati, T. Kahan, E. Barbato, L. A. Pierard, M. Garbi, F. A. Flachskampf, and E. Gerdts, "Management of patients with combined arterial hypertension and aortic valve stenosis: a consensus document from the ESC, EACVI, and EAPCI," *European Heart Journal – Cardiovascular Pharmacotherapy*, vol. 7, no. 3, pp. 242–250, 2021.

[51] V. Katsi, K. Papadomarkaki, K. Manousiadis, E. Triantafyllou, C. Fragoulis, and K. Tsioufis, "Coexistence of hypertrophic cardiomyopathy and arterial hypertension: Current insights and future directions," *Diseases*, vol. 14, no. 1, p. 1, 2025.

[52] S. Arshad, Y. H. Goldberg, H. Bhopalwala *et al.*, "High prevalence of cardiac amyloidosis in clinically significant aortic stenosis: A meta-analysis," *Cardiology Research*, vol. 13, no. 6, pp. 357–371, 2022.

[53] C. Nitsche, P. R. Scully, K. P. Patel *et al.*, "Prevalence and outcomes of concomitant aortic stenosis and cardiac amyloidosis," *Journal of the American College of Cardiology*, vol. 77, no. 2, pp. 128–139, 2021.

[54] ECG Waves. (2026) Ecg in left ventricular hypertrophy (lvh): criteria and implications. [Online]. Available: https://ecgwaves.com/topic/ecg-left-ventricular-hypertrophy-lvh-clinical-characteristics/

[55] O. S. Ogah, O. O. Oladapo, A. A. Adebiyi, B. L. Salako, A. O. Falase, A. K. Adebayo, A. Aje, and D. B. Ojji, "Electrocardiographic left ventricular hypertrophy with strain pattern: prevalence, mechanisms and prognostic implications," *Cardiovascular Journal of Africa*, vol. 19, no. 1, pp. 39–45, 2008.

[56] Life in the Fast Lane. (2024) Left ventricular hypertrophy (lvh) – ecg library. [Online]. Available: https://litfl.com/left-ventricular-hypertrophy-lvh-ecg-library/

[57] M. Namdar, J. Steffel, S. Jetzer, C. Schmied, D. Hürlimann, G. G. Camici *et al.*, "Value of electrocardiogram in the differentiation of hypertensive heart disease, hypertrophic cardiomyopathy, aortic stenosis, amyloidosis, and Fabry disease," *The American Journal of Cardiology*, vol. 109, no. 4, pp. 587–593, 2012.

[58] B. Surawicz and T. K. Knilans, *Chou's Electrocardiography in Clinical Practice: Adult and Pediatric*, 6th ed. Philadelphia, PA: Saunders Elsevier, 2008.

[59] M. Mahmod, K. Chan, J. F. Fernandes, R. Ariga, B. Raman, E. Zacur, H.-f. R. Law, M. Rigolli, J. M. Francis, S. Dass *et al.*, "Differentiating left ventricular remodeling in aortic stenosis from systemic hypertension," *Circulation: Cardiovascular Imaging*, vol. 17, no. 8, p. e016489, 2024.

[60] J. P. Costabel, R. Espinosa, A. Spaccavento, F. N. Ballari, M. Cortés, D. G. Conde, and P. F. Elissamburu, "Comparative analysis of electrocardiographic patterns of ventricular hypertrophy in cardiac amyloidosis and other cardiomyopathies," *Current Problems in Cardiology*, vol. 50, no. 7, p. 103074, 2025.

[61] N. Martini, G. Sinigiani, L. De Michieli, R. Mussinelli, M. Perazzolo Marra, S. Iliceto, A. Zorzi, S. Perlini, D. Corrado, and A. Cipriani, "Electrocardiographic features and rhythm disorders in cardiac amyloidosis," *Trends in Cardiovascular Medicine*, vol. 34, pp. 257–264, 2024.

[62] A. Vereckei, G. Katona, G. Szénási, L. D. Vidács, D. Földeák, H. Takács, V. Nagy, and R. Sepp, "Novel electrocardiographic criteria may render possible the more accurate recognition of cardiac amyloidosis," *ESC Heart Failure*, vol. 11, no. 2, pp. 1030–1038, 2024.

[63] A. Venkateshvaran, H. Mert Karaoglu, and B. Pilebro, "Prediagnostic electrocardiographic abnormalities in transthyretin amyloid cardiomyopathy: a longitudinal observational study," *Journal of Clinical Medicine*, vol. 15, no. 6, p. 2201, 2026.

[64] R. M. Lang, L. P. Badano, V. Mor-Avi *et al.*, "Recommendations for cardiac chamber quantification by echocardiography in adults: An update from the American Society of Echocardiography and the European Association of Cardiovascular Imaging," *Journal of the American Society of Echocardiography*, vol. 28, no. 1, pp. 1–39, 2015.

[65] E. Monda, G. Palmiero, M. Lioncino, M. Rubino, A. Cirillo, A. Fusco, M. Caiazza, F. Verrillo, G. Diana, A. Mauriello, M. Iavarone, M. A. Losi, M. L. De Rimini, S. Dellegrottaglie, A. D'Andrea, E. Bossone, and G. Pacileo, "Multimodality imaging in cardiomyopathies with hypertrophic phenotypes," *Journal of Clinical Medicine*, vol. 11, no. 3, p. 868, 2022.

[66] F. Weidemann, M. Niemann, S. Stork, W. Voelker, M. Beer, T. Seyfarth, G. Ertl, and J. Strotmann, "The different faces of echocardiographic left ventricular hypertrophy: Clues to the etiology," *Journal of the American Society of Echocardiography*, vol. 23, no. 8, pp. 793–801, 2010.

[67] P. Garcia-Pavia, C. Rapezzi, Y. Adler *et al.*, "Diagnosis and treatment of cardiac amyloidosis: a position statement of the ESC Working Group on Myocardial and Pericardial Diseases," *European Heart Journal*, vol. 42, no. 16, pp. 1554–1568, 2021.

[68] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

[69] M. H. Reza, M. N. Biswas, S. S. G. Rabbani, S. H. Sadi, M. F. Ahamed, F. B. Sha, R. Sarmun, and M. E. H. Chowdhury, "A comprehensive review of convolutional neural networks: foundations, enhancements and applications," *Neural Computing and Applications*, vol. 38, p. 56, 2026.

[70] DevelopersBreach, "Convolution neural network: Deep learning," https://developersbreach.com/convolution-neural-network-deep-learning/, accedido: julio de 2026.

[71] R. Kaur, R. Kumar, and M. Gupta, "Review on transfer learning for convolutional neural network," in *2021 3rd International Conference on Advances in Computing, Communication Control and Networking (ICAC3N)*, 2021, pp. 1–6.

[72] F. Zhuang, Z. Qi, K. Duan, D. Xi, Y. Zhu, H. Zhu, H. Xiong, and Q. He, "A comprehensive survey on transfer learning," *Proceedings of the IEEE*, vol. 109, no. 1, pp. 43–76, 2021.

[73] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in Neural Information Processing Systems*, vol. 27, 2014, pp. 3320–3328.

[74] I. Kandel and M. Castelli, "How deeply to fine-tune a convolutional neural network: A case study using a histopathology dataset," *Applied Sciences*, vol. 10, no. 10, p. 3359, 2020.

[75] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, "ImageNet large scale visual recognition challenge," *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, 2015.

[76] N. Tajbakhsh, J. Y. Shin, S. R. Gurudu, R. T. Hurst, C. B. Kendall, M. B. Gotway, and J. Liang, "Convolutional neural networks for medical image analysis: Full training or fine tuning?" *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, pp. 1299–1312, 2016.

[77] A. F. Markus, J. A. Kors, and P. R. Rijnbeek, "The role of explainability in creating trustworthy artificial intelligence for health care: a comprehensive survey of the terminology, design choices, and evaluation strategies," *Journal of Biomedical Informatics*, vol. 113, p. 103655, 2021.

[78] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 618–626.

[79] AiMed Insights, "Explainable AI: Grad-CAM step-by-step," https://aimedinsights.substack.com/p/explainable-ai-grad-cam-step-by-step, 2024, accedido: agosto de 2026.

[80] Y. Liu, C. Liu, J. Zheng, C. Xu, and D. Wang, "Improving explainability and integrability of medical AI to promote health care professional acceptance and use: Mixed systematic review," *Journal of Medical Internet Research*, vol. 27, p. e73374, 2025.

[81] E. J. Topol, "High-performance medicine: the convergence of human and artificial intelligence," *Nature Medicine*, vol. 25, no. 1, pp. 44–56, 2019.

[82] D. C. Lepcha, B. Goyal, A. Dogra, A. Alkhayyat, P. K. Sahu, A. Ali, and V. Kukreja, "Deep learning in medical image analysis: A comprehensive review of algorithms, trends, applications, and challenges," *Computer Modeling in Engineering & Sciences*, vol. 145, no. 2, pp. 1487–1573, 2025.

[83] X. Zhao, G. Huang, L. Wu *et al.*, "Deep learning assessment of left ventricular hypertrophy based on electrocardiogram," *Frontiers in Cardiovascular Medicine*, vol. 9, p. 952089, 2022.

[84] J.-m. Kwon, K.-H. Jeon, H. M. Kim *et al.*, "Comparing the performance of artificial intelligence and conventional diagnosis criteria for detecting left ventricular hypertrophy using electrocardiography," *EP Europace*, vol. 22, no. 3, pp. 412–419, 2020.

[85] J. S. Haimovich, N. Diamant, S. Khurshid, P. Di Achille, C. Reeder, S. Friedman, P. Singh, W. Spurlock, P. T. Ellinor, A. Philippakis, P. Batra, J. E. Ho, and S. A. Lubitz, "Artificial intelligence–enabled classification of hypertrophic heart diseases using electrocardiograms," *Cardiovascular Digital Health Journal*, vol. 4, no. 2, pp. 48–59, 2023.

[86] Y. Li, Q. Qu, M. Wang, L. Yu, J. Wang, L. Shen, and K. He, "Deep learning for digitizing highly noisy paper-based ecg records," *Computers in Biology and Medicine*, vol. 127, p. 104077, 2020.

[87] H. Wu, K. H. K. Patel, X. Li, B. Zhang, C. Galazis, N. Bajaj, A. Sau, X. Shi, L. Sun, Y. Tao, H. Al-Qaysi, L. Tarusan, N. Yasmin, N. Grewal, G. Kapoor, J. W. Waks, D. B. Kramer, N. S. Peters, and F. S. Ng, "A fully-automated paper ecg digitisation algorithm using deep learning," *Scientific Reports*, vol. 12, p. 20963, 2022.

[88] J. D. Fortune, N. E. Coppa, K. T. Haq, H. Patel, and L. G. Tereshchenko, "Digitizing ecg image: A new method and open-source software code," *Computer Methods and Programs in Biomedicine*, vol. 221, p. 106890, 2022.

[89] F. Krones, B. Walker, T. Lyons, and A. Mahdi, "Combining hough transform and deep learning approaches to reconstruct ecg signals from printouts," in *Computing in Cardiology*, vol. 51, 2024.

[90] E. Stenhede, A. M. Bjørnstad, and A. Ranjbar, "Digitizing paper ecgs at scale: an open-source algorithm for clinical research," *npj Digital Medicine*, vol. 9, p. 145, 2026.

[91] R. Ao and G. He, "Image based deep learning in 12-lead ECG diagnosis," *Frontiers in Artificial Intelligence*, vol. 5, p. 1087370, 2023.

[92] E. Hata, C. Seo, M. Nakayama, K. Iwasaki, T. Ohkawauchi, and J. Ohya, "Classification of aortic stenosis using ECG by deep learning and its analysis using Grad-CAM," in *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, 2020, pp. 1548–1551.

[93] G. J. Gnanadurai, A. Raaza, R. Velayutham, S. K. Palani, and E. A. Bramwell, "Detection of cardiac amyloidosis on electrocardiogram images using machine learning and deep learning techniques," *Computational Intelligence*, vol. 39, pp. 554–576, 2023.

[94] J. Qin, Y. Wei, Z. Wang, J. Jin, W. Zhao, and L. Pei, "HDNet: A deep learning model for diagnosing hypertension using electrocardiogram images," in *2025 IEEE Smart World Congress (SWC)*, 2025.

[95] V. Sangha, L. S. Dhingra, A. Aminorroaya, P. M. Croon, N. V. Sikand, S. Sen, M. W. Martinez, M. S. Maron, H. M. Krumholz, F. W. Asselbergs, E. K. Oikonomou, and R. Khera, "Identification of hypertrophic cardiomyopathy on electrocardiographic images with deep learning," *Nature Cardiovascular Research*, vol. 4, pp. 991–1000, 2025.

[96] S. Ghosh, N. Das, and M. Nasipuri, "Reshaping inputs for convolutional neural network: Some common and uncommon methods," *Pattern Recognition*, vol. 93, pp. 79–94, 2019.

[97] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[98] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *3rd International Conference on Learning Representations (ICLR)*, 2015.

[99] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.

[100] P. Wagner, N. Strodthoff, R.-D. Bousseljot, D. Kreiseler, F. I. Lunze, W. Samek, and T. Schaeffter, "PTB-XL, a large publicly available electrocardiography dataset," *Scientific Data*, vol. 7, no. 1, p. 154, 2020.

[101] F. Liu, C. Liu, L. Zhao, X. Zhang, X. Wu, X. Xu, Y. Liu, C. Ma, S. Wei, Z. He, J. Li, and A. Entisar, "An open access database for evaluating the algorithms of electrocardiogram rhythm and morphology abnormality detection," *Journal of Medical Imaging and Health Informatics*, vol. 8, no. 7, pp. 1368–1373, 2018.

[102] J. Zheng, J. Zhang, S. Danioko, H. Yao, H. Guo, and C. Rakovski, "A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients," *Scientific Data*, vol. 7, no. 1, p. 48, 2020.

[103] M. A. Reyna, N. Sadr, E. A. Perez Alday, A. Gu, A. J. Shah, C. Robichaux, A. B. Rad, A. Elola, S. Seyedi, S. Ansari, H. Ghanbari, Q. Li, A. Sharma, and G. D. Clifford, "Will two do? varying dimensions in electrocardiography: The PhysioNet/Computing in Cardiology challenge 2021," *Computing in Cardiology*, vol. 48, 2021.

[104] SNOMED International, "What is SNOMED CT?" https://www.snomed.org/what-is-snomed-ct, 2024.

[105] ——, "SNOMED CT Browser," https://browser.ihtsdotools.org/, 2024, accedido: junio 2025.

[106] M. Lin, Q. Chen, and S. Yan, "Network in network," in *2nd International Conference on Learning Representations (ICLR)*, 2014.

[107] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 11 976–11 986.

[108] W. Xu, Y.-L. Fu, and D. Zhu, "ResNet and its application to medical image processing: Research progress and challenges," *Computer Methods and Programs in Biomedicine*, vol. 240, p. 107660, 2023.

[109] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019, pp. 2623–2631.

[110] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, "Fine-tuning can distort pretrained features and underperform out-of-distribution," in *10th International Conference on Learning Representations (ICLR)*, 2022.

[111] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *International Conference on Learning Representations (ICLR)*, 2015.

[112] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019.

[113] S. Raschka, "Model evaluation, model selection, and algorithm selection in machine learning," *arXiv preprint arXiv:1811.12808*, 2018. [Online]. Available: https://arxiv.org/abs/1811.12808

[114] D. Loeffen, A. Rijpma, R. Bartels, and R. Vinke, "On the assessment of deep-learning based super-resolution in small datasets of human brain MRI scans," *medRxiv*, 2026. [Online]. Available: https://www.medrxiv.org/content/10.64898/2026.02.16.26346392v1

A Esquema de etiquetado del dataset sintético

Tabla A.1: Jerarquía de superclases y subclases diagnósticas del dataset PTB-XL, adoptada como esquema de referencia para el remapeo de etiquetas de los datasets de preentrenamiento.

Superclase	Subclase	Diagnóstico	Abreviación
NORM	NORM	normal ECG	NORM
CD	CLBBB	complete left bundle branch block	CLBBB
	CRBBB	complete right bundle branch block	CRBBB
	ILBBB	incomplete left bundle branch block	ILBBB
	IRBBB	incomplete right bundle branch block	IRBBB
	IVCD	non-specific intraventricular conduction disturbance	IVCD
	LAFB/LPFB	left anterior fascicular block	LAFB
		left posterior fascicular block	LPFB
	WPW	Wolff-Parkinson-White syndrome	WPW
		first degree AV block	1AVB
	_AVB	second degree AV block	2AVB
		third degree AV block	3AVB
HYP	LAO/LAE	left atrial overload/enlargement	LAO/LAE
	LVH	left ventricular hypertrophy	LVH
	RAO/RAE	right atrial overload/enlargement	RAO/RAE
	RVH	right ventricular hypertrophy	RVH
	SEHYP	septal hypertrophy	SEHYP
MI	AMI	anteroseptal myocardial infarction	ASMI
		anterior myocardial infarction	AMI
		anterolateral myocardial infarction	ALMI
		subendocardial injury in anteroseptal leads	INJAS
		subendocardial injury in anterolateral leads	INJAL
		subendocardial injury in lateral leads	INJLA
	IMI	inferior myocardial infarction	IMI
		inferolateral myocardial infarction	ILMI
		inferoposterolateral myocardial infarction	IPLMI
		inferoposterior myocardial infarction	IPMI
		subendocardial injury in inferior leads	INJIN
		subendocardial injury in inferolateral leads	INJIL
	LMI	lateral myocardial infarction	LMI
	PMI	posterior myocardial infarction	PMI
STTC	ISCA	ischemic in anterolateral leads	ISCAL
		ischemic in anteroseptal leads	ISCAS
		ischemic in lateral leads	ISCLA
		ischemic in anterior leads	ISCAN
	ISCI	ischemic in inferior leads	ISCIN
		ischemic in inferolateral leads	ISCIL
	ISC_	non-specific ischemic	ISC_
	NST_	non-specific ST changes	NST_
		non-diagnostic T abnormalities	NDT
		digitalis-effect	DIG
	STTC	long QT interval	LNGQT
		ST-T changes compatible with ventricular aneurysm	ANEUR
		electrolytic disturbance or drug	EL

Tabla A.2: Asignación de superclases diagnósticas a los códigos SNOMED-CT presentes en los datasets de señales públicos. Los códigos marcados con (-) no se asociaron a ninguna superclase.

SNOMED	**Descripción**	**Superclase**
426177001	sinus bradycardia	-
426783006	sinus rhythm	NORM
428750005	nonspecific ST-T abnormality	STTC
164934002	T wave abnormal	STTC
164889003	atrial fibrillation	-
427084000	sinus tachycardia	-
59118001	right bundle branch block	CD
270492004	1st degree AV block	CD
284470004	premature atrial contraction	-
164930006	ST interval abnormal	STTC
111975006	prolonged QT interval	STTC
164873001	left ventricular hypertrophy (ecg)	HYP
429622005	ST depression	STTC
39732003	left axis deviation	-
55827005	left ventricular hypertrophy (disorder)	HYP
164867002	old myocardial infarction	MI
59931005	T wave inversion	STTC
425623009	lateral ischemia	STTC
67741000119109	left atrial enlargement	HYP
164884008	ventricular ectopics	-
164909002	left bundle branch block	CD
164917005	Q wave abnormal	-
164890007	atrial flutter	-
17338001	ventricular premature beats	-
251146004	low QRS voltages	-
426761007	supraventricular tachycardia	-
164931005	ST elevation	STTC
713426002	incomplete right bundle branch block	CD
427393009	sinus arrhythmia	-
425419005	inferior ischemia	STTC
698252002	nonspecific intraventricular conduction disorder	CD
164865005	myocardial infarction	MI
164861001	myocardial ischemia	STTC
47665007	right axis deviation	-
426434006	anterior ischemia	STTC
426627000	bradycardia	-
233917008	AV block	CD
427172004	premature ventricular contractions	-
445118002	left anterior fascicular block	CD
713422000	atrial tachycardia	-
251199005	counterclockwise rotation	-
428417006	early repolarization	-
413844008	chronic myocardial ischemia	STTC
713427006	complete right bundle branch block	CD
251120003	incomplete left bundle branch block	CD
6374002	bundle branch block	CD
89792004	right ventricular hypertrophy	HYP
164912004	P wave change	-
251198002	clockwise rotation	-
266249003	ventricular hypertrophy	HYP
253352002	left atrial abnormality	-
54329005	anterior myocardial infarction	MI
195126007	atrial hypertrophy	HYP
63593006	supraventricular premature beats	-
195042002	2nd degree AV block	CD
251268003	atrial pacing pattern	-

SNOMED	Descripción	Superclase
251266004	ventricular pacing pattern	-
195080001	atrial fibrillation and flutter	-
446813000	left atrial hypertrophy	HYP
27885002	complete heart block	CD
445211001	left posterior fascicular block	CD
426995002	junctional escape	-
164937009	U wave abnormal	-
446358003	right atrial hypertrophy	HYP
195060002	ventricular pre-excitation	-
426664006	accelerated junctional rhythm	-
251166008	AV nodal reentrant tachycardia	-
253339007	right atrial abnormality	-
251180001	ventricular trigeminy	-
164896001	ventricular fibrillation	-
164947007	prolonged PR interval	-
251139008	suspect lead reversal	-
164921003	R wave abnormal	-
11157007	ventricular bigeminy	-
75532003	ventricular escape beat	-
195101003	wandering atrial pacemaker	-
65778007	sinoatrial block	-
67751000119106	right atrial high voltage	-
233897008	AV reentrant tachycardia	-
17366009	wandering atrial rhythm	-
55930002	ST changes	STTC
54016002	Mobitz I AV block	CD
74390002	Wolff-Parkinson-White pattern	CD
426648003	junctional tachycardia	-
29320008	AV junctional rhythm	-
49578007	shortened PR interval	-
251173003	atrial bigeminy	-
164942001	fragmented QRS	-
251164006	junctional premature complex	-
10370003	pacing rhythm	-
13640000	fusion beats	-
251170000	blocked PAC	-
413444003	acute myocardial ischemia	STTC
81898007	ventricular escape rhythm	-
370365005	left ventricular strain	-
74615001	brady-tachy syndrome	-
704997005	inferior ST depression	-
164895002	ventricular tachycardia	-
82226007	diffuse intraventricular block	-
111288001	ventricular flutter	-
251259000	high T voltage	-
77867006	decreased QT interval	-
426749004	chronic atrial fibrillation	-

B Material complementario de VentrIA

B.1 Informe de resultados

Figura B.1.1: Ejemplo del informe PDF generado por VentrIA con los resultados del análisis del modelo.

B.2 Cuestionario de evaluación

Evaluación de Experiencia de Usuario — VentrIA

Gracias por participar en la evaluación de VentrIA, una herramienta de apoyo a la decisión clínica orientada a la evaluación de la etiología de la hipertrofia ventricular izquierda (HVI) a partir de estudios de ECG de 12 derivaciones. Esta encuesta busca conocer su experiencia con la interfaz y su percepción sobre la utilidad de la herramienta.

Tiempo estimado: ∼5 minutos.

Sección 1: Perfil clínico y contexto

1. Rol / especialidad *
   - ◯ Cardiólogo/a
   - ◯ Médico/a clínico/a
   - ◯ Técnico/a en prácticas cardiológicas
   - ◯ Otro

2. Años de experiencia clínica *
   - ◯ < 2 años
   - ◯ 2–5 años
   - ◯ 6–10 años
   - ◯ 11–20 años
   - ◯ > 20 años

3. ¿Cuántos ECG lee aproximadamente en una semana? *
   - ◯ < 10
   - ◯ 10–30
   - ◯ 30–80
   - ◯ > 80

4. ¿Con qué frecuencia atiende pacientes que presentan hipertrofia ventricular izquierda (HVI)? *
   - ◯ Muy frecuentemente
   - ◯ Frecuentemente
   - ◯ Ocasionalmente
   - ◯ Raramente
   - ◯ Nunca

5. ¿Qué tan desafiante considera determinar la etiología de HVI a partir del ECG? *

	1	2	3	4	5	
Nada desafiante	◯	◯	◯	◯	◯	Muy desafiante

6. En su práctica habitual, ¿cómo suele abordar el proceso diagnóstico cuando identifica signos de HVI en un ECG? ¿Suele apoyarse en otros estudios complementarios para establecer la etiología? En caso afirmativo, ¿cuáles?

   _____

   _____

   _____

7. Ordene las siguientes etiologías según la frecuencia con la que las encuentra en su práctica clínica, colocando en primer lugar la más frecuente y en cuarto lugar la menos frecuente. *

	1	2	3	4
Amiloidosis	◯	◯	◯	◯
Hipertensión arterial	◯	◯	◯	◯
Estenosis aórtica	◯	◯	◯	◯
Miocardiopatía hipertrófica	◯	◯	◯	◯

Sección 2: Usabilidad e interpretación de resultados

8. Me resultó fácil navegar por la interfaz de VentrIA. *

	1	2	3	4	5	
Muy en desacuerdo	○	○	○	○	○	Muy de acuerdo

9. La información presentada en pantalla es clara y comprensible. *

	1	2	3	4	5	
Muy en desacuerdo	○	○	○	○	○	Muy de acuerdo

10. El resultado de la clasificación es fácil de interpretar. *

	1	2	3	4	5	
Muy en desacuerdo	○	○	○	○	○	Muy de acuerdo

11. Ver las probabilidades asignadas a cada categoría me permite valorar con mayor criterio el resultado de la clasificación. *

	1	2	3	4	5	
Muy en desacuerdo	○	○	○	○	○	Muy de acuerdo

12. Las regiones del ECG resaltadas por el mapa de calor me parecen clínicamente relevantes para la predicción mostrada. *

	1	2	3	4	5	
Muy en desacuerdo	○	○	○	○	○	Muy de acuerdo

13. Si lo considera relevante, ¿qué regiones o características del ECG fueron destacadas por el mapa de calor y qué significado clínico les atribuye?

_____

_____

_____

14. Conocer qué regiones del ECG considera el modelo para realizar su predicción me ayuda a valorar el resultado obtenido. *

	1	2	3	4	5	
Muy en desacuerdo	○	○	○	○	○	Muy de acuerdo

Sección 3: Valoración general de VentrIA

15. ¿Qué tan familiarizado/a está con el uso de herramientas basadas en inteligencia artificial? *

	1	2	3	4	5	
Nada	○	○	○	○	○	Mucho

16. ¿En qué medida considera que VentrIA podría ser una herramienta de apoyo útil en la evaluación de la etiología de la HVI? *

	1	2	3	4	5	
Muy poco útil	○	○	○	○	○	Muy útil

17. ¿Qué tan probable es que incorpore VentrIA en su práctica clínica? *

	1	2	3	4	5	
Muy poco probable	○	○	○	○	○	Muy probable

18. En términos generales, ¿cómo calificaría a VentrIA como herramienta de apoyo diagnóstico? *

1	2	3	4	5	6	7	8	9	10
○	○	○	○	○	○	○	○	○	○

19. ¿Qué aspectos de la interfaz o del funcionamiento de VentrIA considera que podrían mejorarse?

_____

_____

_____

B.3 Respuestas del cuestionario

Tabla B.3.1: Perfil de los profesionales médicos que participaron en la encuesta. La familiaridad con herramientas de inteligencia artificial se valoró en escala 1–5.

	P1	**P2**	**P3**	**P4**	**P5**	**P6**
Experiencia clínica (años)	>20	11–20	>20	>20	2–5	2–5
ECG leídos por semana	>80	30–80	>80	30–80	30–80	>80
Atención de pacientes con HVI	Muy frec.	Frec.	Muy frec.	Frec.	Frec.	Frec.
Familiaridad con herramientas de IA	4	4	2	2	3	4

Tabla B.3.2: Percepción de los participantes sobre la problemática abordada.

	P1	**P2**	**P3**	**P4**	**P5**	**P6**
Dificultad para determinar la etiología	5	4	3	5	2	3
Orden de frecuencia de las etiologías						
HTA	1	1	1	1	1	1
EAo	3	2	2	2	2	2
MCH	2	3	3	3	3	3
Am	4	4	4	4	4	4

Tabla B.3.3: Puntuaciones asignadas por cada participante a los ítems de usabilidad y utilidad clínica de la encuesta, en escala 1–5 (1 = muy en desacuerdo, 5 = muy de acuerdo).

Ítem	**P1**	**P2**	**P3**	**P4**	**P5**	**P6**	**Media**
Usabilidad							
Facilidad de navegación	5	5	2	5	5	5	4,50
Claridad de la información en pantalla	5	5	3	5	5	5	4,67
Facilidad de interpretación del resultado	5	5	1	5	5	5	4,33
Utilidad de las probabilidades por categoría	5	5	3	5	5	5	4,67
Utilidad clínica							
Relevancia clínica de las regiones resaltadas	5	5	2	4	4	3	3,83
Utilidad de conocer las regiones consideradas	5	5	3	3	5	5	4,33
Utilidad para evaluar la etiología de la HVI	4	5	3	4	5	5	4,33
Probabilidad de incorporarla en la práctica	5	5	3	4	4	5	4,33
Valoración general (1–10)	10	10	5	8	9	10	8,67

C Estudios de Optuna

Se presentan a continuación los resultados completos de la optimización de hiperparámetros realizados con Optuna en cada etapa del entrenamiento. Para cada *trial* se indica el estado (Completo o Podado), la configuración de hiperparámetros evaluada y el valor final de la función objetivo (*val_loss*). El *ranking* se obtiene ordenando los *trials* completos de menor a mayor *val_loss*. Los *trials* podados no reciben *ranking*.

C.1 Preentrenamiento en imágenes sintéticas

Tabla C.1.1: Resultados del estudio de Optuna para CNN-A entrenada en el dataset sintético.

Trial	**Estado**	**Número de bloques**	**Filtros iniciales**	**Dropout inicial**	**Tasa de aprendizaje**	**val_loss**	**Ranking**
1	Completo	4	32	0,2967	$1{,}43 \times 10^{-4}$	0,6419	6
2	Completo	4	32	0,2796	$1{,}43 \times 10^{-4}$	0,6046	2
3	Completo	4	64	0,2803	$5{,}11 \times 10^{-4}$	0,6313	5
4	Completo	4	32	0,1637	$1{,}52 \times 10^{-4}$	0,6974	19
5	Completo	4	64	0,2296	$1{,}96 \times 10^{-4}$	0,6771	16
6	Completo	5	64	0,2099	$2{,}86 \times 10^{-4}$	0,7366	22
7	Completo	5	64	0,2777	$1{,}11 \times 10^{-4}$	0,6060	3
8	Completo	5	32	0,3847	$9{,}24 \times 10^{-4}$	0,7314	21
9	Completo	5	32	0,3053	$2{,}76 \times 10^{-4}$	0,6514	8
10	Completo	4	32	0,3728	$1{,}81 \times 10^{-4}$	0,6435	7
11	Podado	4	32	0,1023	$4{,}69 \times 10^{-4}$	—	—
12	Completo	5	64	0,3230	$1{,}03 \times 10^{-4}$	0,6076	4
13	Completo	5	64	0,3361	$1{,}02 \times 10^{-4}$	0,6535	9
14	Completo	5	64	0,1933	$1{,}23 \times 10^{-4}$	0,6673	14
15	Podado	4	32	0,2613	$2{,}29 \times 10^{-4}$	—	—
16	Podado	5	64	0,2464	$3{,}84 \times 10^{-4}$	—	—
17	Completo	5	32	0,1624	$1{,}40 \times 10^{-4}$	0,6736	15
18	Completo	4	64	0,3430	$1{,}91 \times 10^{-4}$	0,6607	10
19	Completo	5	32	0,3088	$7{,}42 \times 10^{-4}$	0,8585	23
20	Completo	4	64	0,2833	$1{,}18 \times 10^{-4}$	0,5991	1
21	Completo	4	32	0,3577	$2{,}27 \times 10^{-4}$	0,6938	18
22	Completo	4	64	0,2828	$1{,}22 \times 10^{-4}$	0,6650	12
23	Podado	4	64	0,2495	$1{,}01 \times 10^{-4}$	—	—
24	Podado	4	64	0,3004	$1{,}59 \times 10^{-4}$	—	—
25	Podado	4	64	0,2184	$1{,}25 \times 10^{-4}$	—	—
26	Completo	4	64	0,3998	$1{,}24 \times 10^{-4}$	0,6890	17
27	Completo	5	64	0,2618	$1{,}67 \times 10^{-4}$	0,7305	20
28	Podado	4	64	0,2846	$2{,}28 \times 10^{-4}$	—	—
29	Completo	5	32	0,1874	$3{,}55 \times 10^{-4}$	0,6616	11
30	Completo	4	32	0,2345	$1{,}39 \times 10^{-4}$	0,6671	13

Tabla C.1.2: Resultados del estudio de Optuna para CNN-B entrenada en el dataset sintético.

Trial	Estado	Número de bloques	Filtros iniciales	Dropout inicial	Tasa de aprendizaje	val_loss	Ranking
1	Completo	4	32	0,2796	$1{,}43 \times 10^{-4}$	0,5768	2
2	Completo	4	64	0,2803	$5{,}11 \times 10^{-4}$	0,7137	17
3	Completo	4	32	0,1637	$1{,}52 \times 10^{-4}$	0,7313	19
4	Completo	4	64	0,2296	$1{,}96 \times 10^{-4}$	0,6919	15
5	Completo	5	64	0,2099	$2{,}86 \times 10^{-4}$	0,6818	13
6	Completo	5	64	0,2777	$1{,}11 \times 10^{-4}$	0,8430	22
7	Completo	5	32	0,3847	$9{,}24 \times 10^{-4}$	0,6846	14
8	Completo	5	32	0,3053	$2{,}76 \times 10^{-4}$	0,6532	11
9	Completo	4	32	0,3728	$1{,}81 \times 10^{-4}$	0,6304	10
10	Podado	5	64	0,2640	$1{,}53 \times 10^{-4}$	—	—
11	Completo	4	32	0,1023	$1{,}04 \times 10^{-4}$	0,5941	5
12	Completo	4	32	0,1047	$1{,}03 \times 10^{-4}$	0,6964	16
13	Podado	4	32	0,1047	$1{,}02 \times 10^{-4}$	—	—
14	Podado	4	32	0,3370	$4{,}50 \times 10^{-4}$	—	—
15	Completo	4	32	0,1783	$1{,}39 \times 10^{-4}$	0,5987	7
16	Completo	4	32	0,1550	$2{,}22 \times 10^{-4}$	0,6041	8
17	Podado	4	32	0,3230	$4{,}21 \times 10^{-4}$	—	—
18	Completo	4	32	0,2171	$1{,}31 \times 10^{-4}$	0,5899	4
19	Completo	4	32	0,2356	$2{,}41 \times 10^{-4}$	0,7173	18
20	Completo	4	32	0,2105	$3{,}56 \times 10^{-4}$	0,6548	12
21	Podado	5	32	0,3532	$6{,}16 \times 10^{-4}$	—	—
22	Podado	4	32	0,1455	$1{,}29 \times 10^{-4}$	—	—
23	Completo	4	32	0,2969	$1{,}71 \times 10^{-4}$	0,8136	21
24	Completo	4	32	0,1937	$1{,}22 \times 10^{-4}$	0,6296	9
25	Completo	4	32	0,2447	$1{,}37 \times 10^{-4}$	0,5944	6
26	Podado	4	32	0,1241	$2{,}12 \times 10^{-4}$	—	—
27	Completo	4	64	0,1351	$1{,}65 \times 10^{-4}$	0,7472	20
28	Completo	4	32	0,2615	$1{,}20 \times 10^{-4}$	0,5827	3
29	Completo	4	32	0,2662	$1{,}20 \times 10^{-4}$	0,5725	1
30	Podado	4	64	0,2653	$7{,}24 \times 10^{-4}$	—	—

Tabla C.1.3: Resultados del estudio de Optuna para ResNet50 preentrenada en ImageNet y ajustada al dataset sintético.

Trial	Estado	Bloques descongelados	Unidades capa densa	Tasa de aprendizaje	val_loss	Ranking
1	Completo	1	256	$2{,}05 \times 10^{-6}$	0,9085	15
2	Completo	1	128	$2{,}61 \times 10^{-5}$	0,9004	12
3	Completo	1	256	$2{,}31 \times 10^{-6}$	0,9085	14
4	Completo	1	256	$3{,}82 \times 10^{-6}$	0,9048	13
5	Completo	2	128	$8{,}17 \times 10^{-6}$	0,9437	18
6	Completo	2	128	$1{,}24 \times 10^{-6}$	0,9643	20
7	Completo	2	128	$8{,}54 \times 10^{-5}$	0,8665	5
8	Completo	2	128	$7{,}59 \times 10^{-6}$	0,9535	19
9	Completo	2	128	$8{,}69 \times 10^{-5}$	0,8272	1
10	Completo	2	128	$6{,}54 \times 10^{-5}$	0,8594	2
11	Completo	2	256	$3{,}09 \times 10^{-5}$	0,8902	10
12	Completo	2	128	$7{,}79 \times 10^{-5}$	0,8626	4
13	Completo	2	128	$3{,}66 \times 10^{-5}$	0,8861	9
14	Completo	2	128	$5{,}05 \times 10^{-5}$	0,8780	7
15	Completo	2	128	$1{,}66 \times 10^{-5}$	0,9285	17
16	Completo	2	128	$5{,}97 \times 10^{-5}$	0,8810	8
17	Completo	2	128	$1{,}76 \times 10^{-5}$	0,9155	16
18	Completo	2	128	$9{,}79 \times 10^{-5}$	0,8604	3
19	Completo	2	256	$1{,}52 \times 10^{-5}$	0,8997	11
20	Completo	2	128	$4{,}43 \times 10^{-5}$	0,8698	6

Tabla C.1.4: Resultados del estudio de Optuna para EfficientNetB0 preentrenada en ImageNet y ajustada al dataset sintético.

Trial	Estado	Bloques descongelados	Unidades capa densa	Tasa de aprendizaje	val_loss	Ranking
1	Completo	1	256	$2{,}05 \times 10^{-6}$	0,9601	16
2	Completo	1	128	$2{,}61 \times 10^{-5}$	0,8379	8
3	Completo	1	256	$2{,}31 \times 10^{-6}$	0,9473	15
4	Completo	1	256	$3{,}82 \times 10^{-6}$	0,9213	14
5	Completo	2	128	$8{,}17 \times 10^{-6}$	0,8447	12
6	Completo	2	128	$1{,}24 \times 10^{-6}$	0,9917	17
7	Completo	2	128	$8{,}54 \times 10^{-5}$	0,8228	1
8	Completo	2	128	$7{,}59 \times 10^{-6}$	0,8480	13
9	Podado	1	256	$2{,}05 \times 10^{-6}$	—	—
10	Completo	1	128	$2{,}61 \times 10^{-5}$	0,8379	9
11	Completo	2	128	$8{,}69 \times 10^{-5}$	0,8266	5
12	Completo	2	128	$7{,}39 \times 10^{-5}$	0,8234	2
13	Completo	2	128	$9{,}23 \times 10^{-5}$	0,8403	10
14	Completo	2	128	$3{,}56 \times 10^{-5}$	0,8349	6
15	Completo	2	128	$4{,}41 \times 10^{-5}$	0,8250	4
16	Podado	2	128	$1{,}58 \times 10^{-5}$	—	—
17	Completo	2	128	$5{,}79 \times 10^{-5}$	0,8236	3
18	Podado	2	128	$1{,}43 \times 10^{-5}$	—	—
19	Completo	2	256	$6{,}29 \times 10^{-5}$	0,8444	11
20	Completo	2	128	$9{,}91 \times 10^{-5}$	0,8351	7

Tabla C.1.5: Resultados del estudio de Optuna para ConvNeXtTiny preentrenada en ImageNet y ajustada al dataset sintético.

Trial	Estado	Bloques descongelados	Unidades capa densa	Tasa de aprendizaje	val_loss	Ranking
1	Completo	1	256	$2{,}05 \times 10^{-6}$	0,8162	18
2	Completo	1	128	$2{,}61 \times 10^{-5}$	0,7745	9
3	Completo	1	256	$2{,}31 \times 10^{-6}$	0,8098	17
4	Completo	1	256	$3{,}82 \times 10^{-6}$	0,7885	16
5	Completo	2	128	$8{,}17 \times 10^{-6}$	0,7766	11
6	Completo	2	128	$8{,}54 \times 10^{-5}$	0,7735	8
7	Completo	2	128	$1{,}24 \times 10^{-6}$	0,8180	19
8	Completo	2	128	$7{,}59 \times 10^{-6}$	0,7788	13
9	Completo	2	128	$8{,}69 \times 10^{-5}$	0,7821	14
10	Completo	2	128	$6{,}54 \times 10^{-5}$	0,7830	15
11	Completo	2	256	$3{,}09 \times 10^{-5}$	0,7729	7
12	Completo	2	256	$3{,}08 \times 10^{-5}$	0,7694	5
13	Completo	2	256	$2{,}68 \times 10^{-5}$	0,7780	12
14	Completo	2	256	$2{,}63 \times 10^{-5}$	0,7753	10
15	Completo	2	256	$1{,}55 \times 10^{-5}$	0,7691	4
16	Completo	2	256	$1{,}46 \times 10^{-5}$	0,7696	6
17	Completo	2	256	$1{,}38 \times 10^{-5}$	0,7684	2
18	Completo	2	256	$1{,}31 \times 10^{-5}$	0,7671	1
19	Podado	1	256	$4{,}84 \times 10^{-6}$	—	—
20	Completo	2	256	$1{,}35 \times 10^{-5}$	0,7689	3

C.2 Ajuste fino sobre el dataset ICBA

Tabla C.2.1: Resultados del estudio de Optuna para CNN-B ajustada al dataset ICBA.

Trial	Estado	Unidades capa densa	Bloques descongelados	Tasa de aprendizaje	val_loss	Ranking
1	Completo	256	1	$2{,}05 \times 10^{-6}$	1,1378	16
2	Completo	128	1	$2{,}61 \times 10^{-5}$	1,0082	12
3	Completo	256	1	$2{,}31 \times 10^{-6}$	1,1369	15
4	Completo	256	1	$3{,}82 \times 10^{-6}$	1,0947	13
5	Completo	128	2	$8{,}17 \times 10^{-6}$	0,8909	10
6	Completo	128	2	$1{,}24 \times 10^{-6}$	1,0984	14
7	Completo	128	2	$8{,}54 \times 10^{-5}$	0,7640	2
8	Completo	128	2	$7{,}59 \times 10^{-6}$	0,8986	11
9	Completo	128	2	$8{,}69 \times 10^{-5}$	0,7596	1
10	Completo	128	2	$6{,}54 \times 10^{-5}$	0,7806	4
11	Completo	256	2	$3{,}09 \times 10^{-5}$	0,8385	7
12	Completo	128	2	$8{,}59 \times 10^{-5}$	0,7777	3
13	Completo	128	2	$3{,}19 \times 10^{-5}$	0,8584	9
14	Completo	128	2	$9{,}95 \times 10^{-5}$	0,8447	8
15	Completo	128	2	$4{,}71 \times 10^{-5}$	0,8150	6
16	Podado	128	2	$2{,}02 \times 10^{-5}$	—	—
17	Podado	128	2	$1{,}42 \times 10^{-5}$	—	—
18	Completo	128	2	$5{,}59 \times 10^{-5}$	0,7883	5
19	Podado	256	1	$4{,}26 \times 10^{-5}$	—	—
20	Podado	128	2	$1{,}39 \times 10^{-5}$	—	—

Tabla C.2.2: Resultados del estudio de Optuna para ConvNeXtTiny ajustada al dataset ICBA.

Trial	Estado	Unidades capa densa	Bloques descongelados	Tasa de aprendizaje	val_loss	Ranking
1	Completo	256	1	$2{,}05 \times 10^{-6}$	0,7888	17
2	Completo	128	1	$2{,}61 \times 10^{-5}$	0,6902	13
3	Completo	256	1	$2{,}31 \times 10^{-6}$	0,7885	16
4	Completo	256	1	$3{,}82 \times 10^{-6}$	0,7864	15
5	Completo	128	2	$8{,}17 \times 10^{-6}$	0,6776	10
6	Completo	128	2	$1{,}24 \times 10^{-6}$	0,6773	7
7	Completo	128	2	$8{,}54 \times 10^{-5}$	0,7148	14
8	Completo	128	2	$7{,}59 \times 10^{-6}$	0,6775	8
9	Podado	128	2	$1{,}04 \times 10^{-6}$	—	—
10	Completo	128	2	$2{,}47 \times 10^{-5}$	0,6778	11
11	Podado	256	2	$1{,}20 \times 10^{-6}$	—	—
12	Completo	128	2	$7{,}14 \times 10^{-6}$	0,6776	9
13	Completo	128	2	$1{,}72 \times 10^{-5}$	0,6753	2
14	Completo	128	2	$1{,}97 \times 10^{-5}$	0,6772	5
15	Completo	128	2	$2{,}10 \times 10^{-5}$	0,6773	6
16	Completo	128	2	$5{,}29 \times 10^{-5}$	0,6833	12
17	Completo	128	2	$1{,}68 \times 10^{-5}$	0,6752	1
18	Completo	128	2	$1{,}28 \times 10^{-5}$	0,6762	4
19	Podado	256	1	$4{,}02 \times 10^{-5}$	—	—
20	Completo	128	2	$1{,}33 \times 10^{-5}$	0,6758	3

C.3 Experimento de ablación

Tabla C.3.1: Resultados del estudio de Optuna para CNN-B entrenada directamente sobre el dataset ICBA, sin preentrenamiento en imágenes sintéticas.

Trial	Estado	Número de bloques	Filtros base	Dropout inicial	Tasa de aprendizaje	val_loss	Ranking
1	Completo	2	32	0,2796	$1{,}43 \times 10^{-4}$	1,3996	17
2	Completo	1	64	0,2803	$5{,}11 \times 10^{-4}$	1,3880	9
3	Completo	1	32	0,1637	$1{,}52 \times 10^{-4}$	1,3832	5
4	Completo	1	64	0,2296	$1{,}96 \times 10^{-4}$	1,3855	6
5	Completo	2	64	0,2099	$2{,}86 \times 10^{-4}$	1,4085	22
6	Completo	3	64	0,2777	$1{,}11 \times 10^{-4}$	1,3884	10
7	Completo	2	32	0,3847	$9{,}24 \times 10^{-4}$	1,0568	2
8	Completo	3	32	0,3053	$2{,}76 \times 10^{-4}$	1,3926	11
9	Completo	2	32	0,3909	$9{,}02 \times 10^{-4}$	0,8235	1
10	Completo	3	32	0,3919	$9{,}48 \times 10^{-4}$	1,4391	24
11	Completo	2	32	0,1085	$5{,}29 \times 10^{-4}$	1,4002	18
12	Completo	2	32	0,3982	$9{,}23 \times 10^{-4}$	1,3993	14
13	Completo	2	32	0,3467	$6{,}06 \times 10^{-4}$	1,4005	19
14	Completo	2	32	0,3365	$6{,}99 \times 10^{-4}$	1,3993	15
15	Completo	2	32	0,3540	$4{,}25 \times 10^{-4}$	1,4021	21
16	Completo	1	32	0,3682	$7{,}63 \times 10^{-4}$	1,3864	7
17	Completo	3	32	0,3100	$3{,}91 \times 10^{-4}$	1,3970	12
18	Completo	2	32	0,3984	$9{,}91 \times 10^{-4}$	1,2633	3
19	Completo	3	64	0,1758	$7{,}52 \times 10^{-4}$	1,4265	23
20	Completo	1	32	0,3214	$3{,}66 \times 10^{-4}$	1,3831	4
21	Completo	2	32	0,3675	$2{,}22 \times 10^{-4}$	1,3996	16
22	Completo	2	32	0,3971	$9{,}75 \times 10^{-4}$	1,3981	13
23	Podado	2	32	0,3752	$7{,}78 \times 10^{-4}$	—	—
24	Podado	2	32	0,3394	$6{,}11 \times 10^{-4}$	—	—
25	Podado	2	32	0,3742	$8{,}41 \times 10^{-4}$	—	—
26	Completo	2	32	0,3992	$6{,}39 \times 10^{-4}$	1,4018	20
27	Completo	1	64	0,3305	$4{,}99 \times 10^{-4}$	1,3876	8
28	Completo	3	32	0,3591	$9{,}58 \times 10^{-4}$	1,4516	25
29	Podado	2	32	0,2953	$8{,}17 \times 10^{-4}$	—	—
30	Podado	2	32	0,2552	$6{,}71 \times 10^{-4}$	—	—

Tabla C.3.2: Resultados del estudio de Optuna para ConvNeXtTiny preentrenada en ImageNet y ajustada directamente sobre el dataset ICBA, sin preentrenamiento en imágenes sintéticas.

Trial	**Estado**	**Unidades capa densa**	**Bloques descongelados**	**Tasa de aprendizaje**	**val_loss**	**Ranking**
1	Completo	256	1	$2{,}05 \times 10^{-6}$	0,8198	18
2	Completo	128	1	$2{,}61 \times 10^{-5}$	0,7148	12
3	Completo	256	1	$2{,}31 \times 10^{-6}$	0,8148	17
4	Completo	256	1	$3{,}82 \times 10^{-6}$	0,7869	16
5	Completo	128	2	$8{,}17 \times 10^{-6}$	0,7100	10
6	Completo	128	2	$1{,}24 \times 10^{-6}$	0,8461	19
7	Completo	128	2	$8{,}54 \times 10^{-5}$	0,7193	14
8	Completo	128	2	$7{,}59 \times 10^{-6}$	0,7163	13
9	Completo	128	2	$2{,}47 \times 10^{-5}$	0,7034	8
10	Completo	128	2	$2{,}93 \times 10^{-5}$	0,6930	3
11	Completo	256	2	$8{,}23 \times 10^{-5}$	0,7210	15
12	Completo	128	2	$2{,}47 \times 10^{-5}$	0,7034	9
13	Completo	128	2	$2{,}65 \times 10^{-5}$	0,7003	6
14	Completo	128	2	$4{,}60 \times 10^{-5}$	0,7013	7
15	Completo	128	2	$1{,}48 \times 10^{-5}$	0,7124	11
16	Completo	128	2	$4{,}35 \times 10^{-5}$	0,6988	5
17	Completo	128	2	$4{,}45 \times 10^{-5}$	0,6941	4
18	Podado	128	2	$1{,}29 \times 10^{-5}$	—	—
19	Completo	256	1	$5{,}13 \times 10^{-5}$	0,6789	2
20	Completo	256	1	$9{,}45 \times 10^{-5}$	0,6626	1

D Resultados adicionales del preentrenamiento en imágenes sintéticas

D.1 Curvas de entrenamiento

Se presentan a continuación las curvas de entrenamiento de las tres configuraciones candidatas evaluadas para cada arquitectura durante la fase de preentrenamiento sobre el dataset sintético. Para cada una se muestra la evolución de la función de pérdida y de la *accuracy* sobre los conjuntos de entrenamiento y validación. La configuración seleccionada como la de mejor desempeño en cada arquitectura se indica con (*).

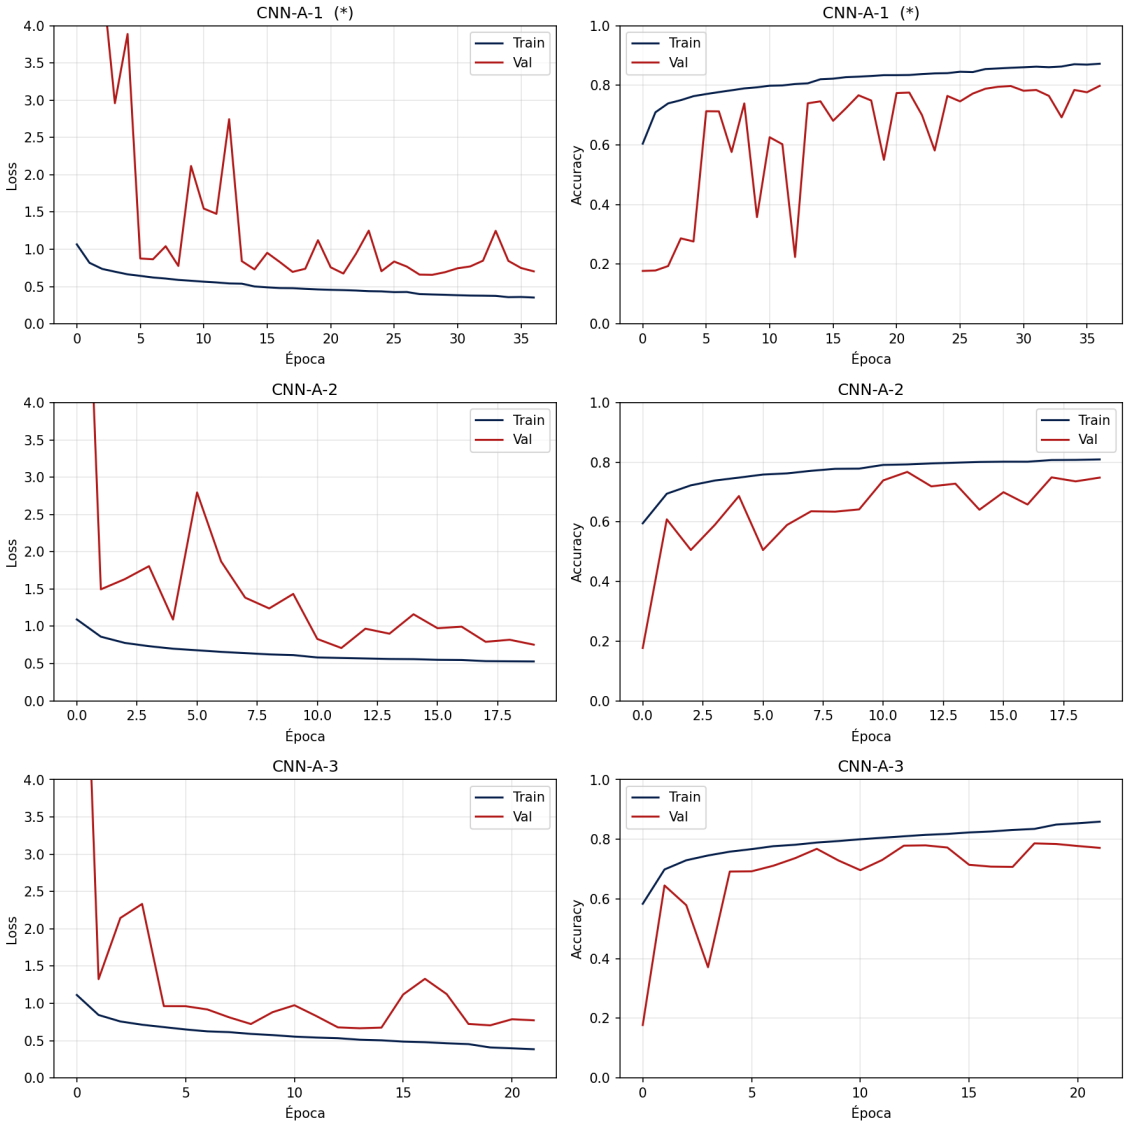

Figura D.1.1: Curvas de entrenamiento de las tres configuraciones candidatas de CNN-A sobre el dataset sintético.

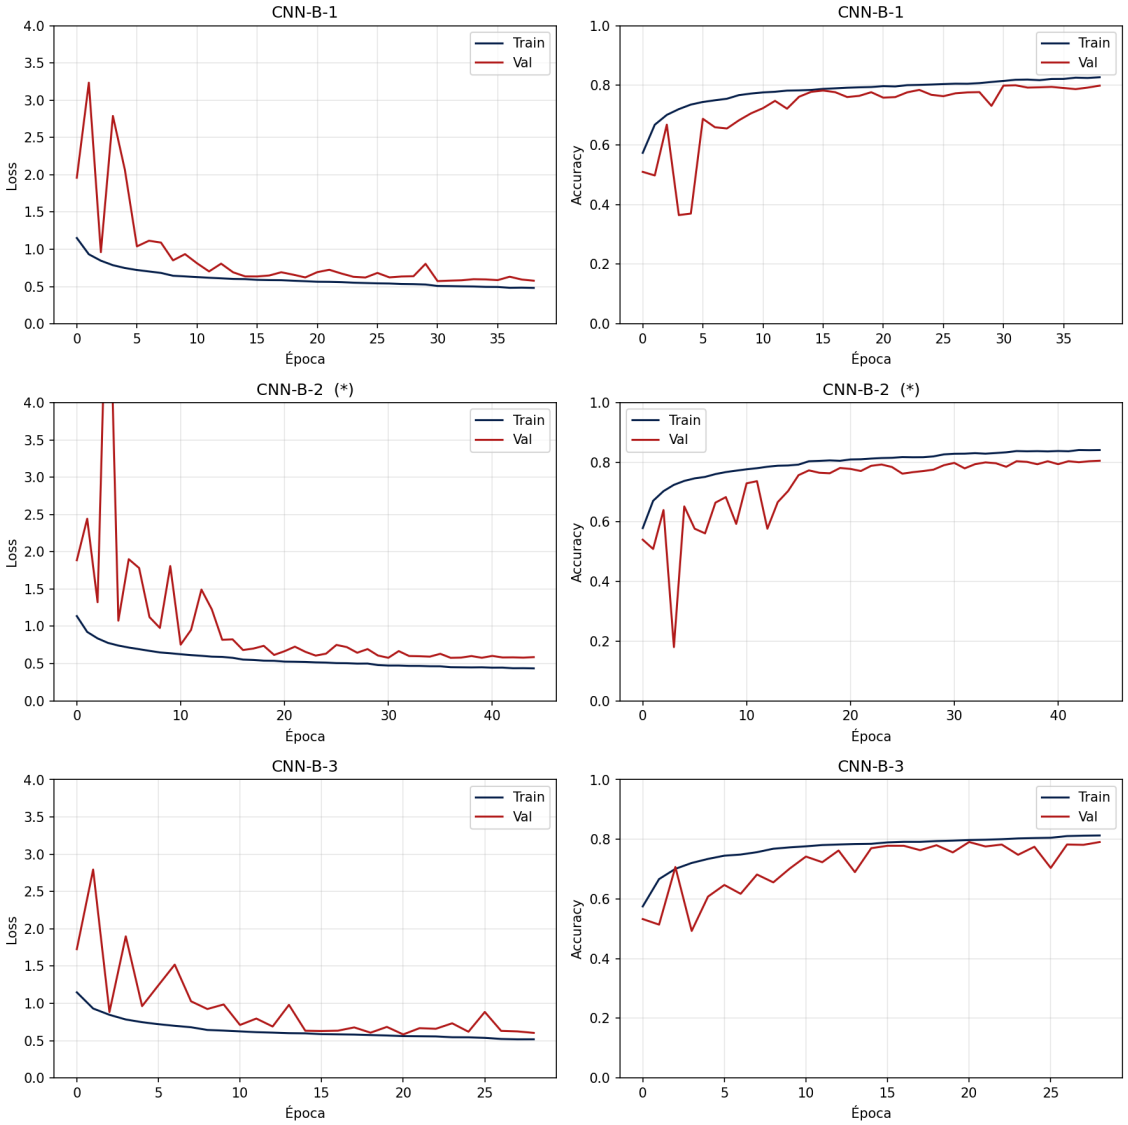

Figura D.1.2: Curvas de entrenamiento de las tres configuraciones candidatas de CNN-B sobre el dataset sintético.

A diferencia de los modelos propios, los modelos preentrenados en ImageNet fueron entrenados mediante el protocolo LP-FT. En sus curvas, una línea vertical gris delimita ambas fases. La región izquierda corresponde a la etapa de *Linear Probing*, durante la cual el *backbone* permanece congelado y solo se entrena la cabeza clasificadora, mientras que la región derecha corresponde a la etapa de *Fine-Tuning*, en la que se descongelan los últimos bloques del *backbone* para su ajuste conjunto.

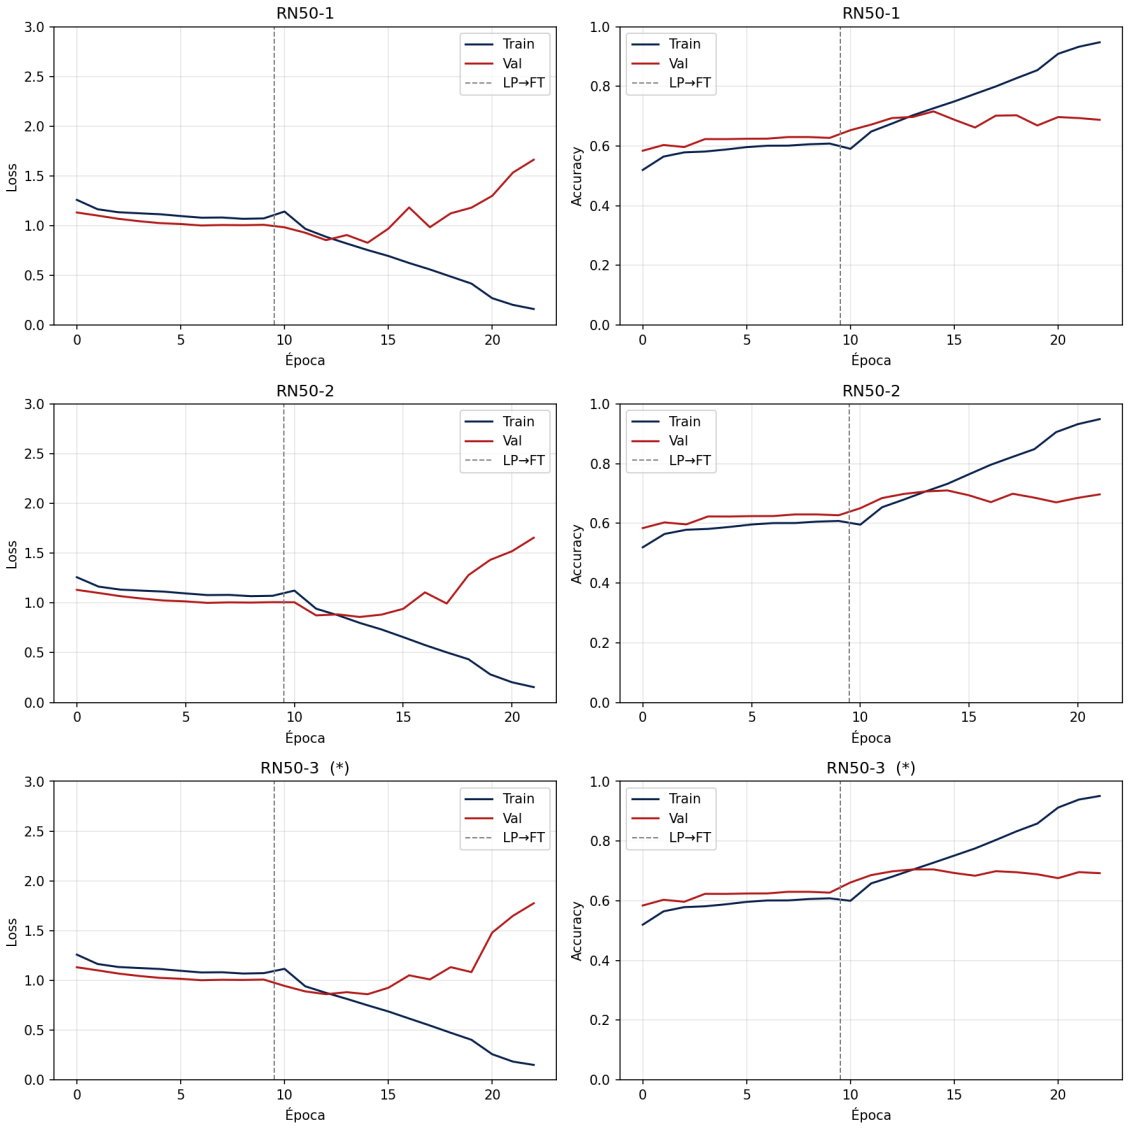

Figura D.1.3: Curvas de entrenamiento de las tres configuraciones candidatas de ResNet50 sobre el dataset sintético.

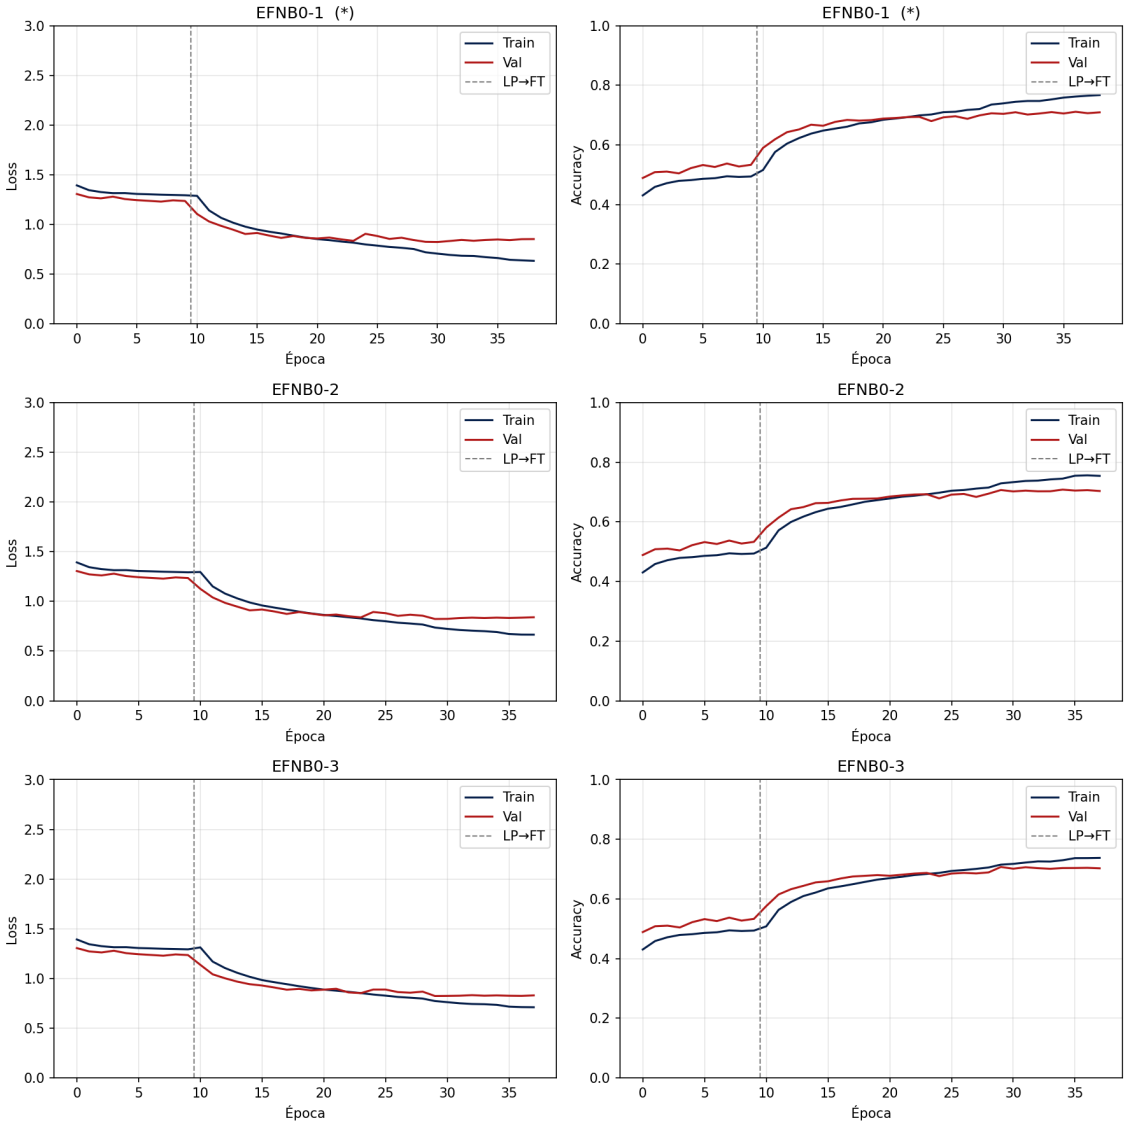

Figura D.1.4: Curvas de entrenamiento de las tres configuraciones candidatas de EfficientNetB0 sobre el dataset sintético.

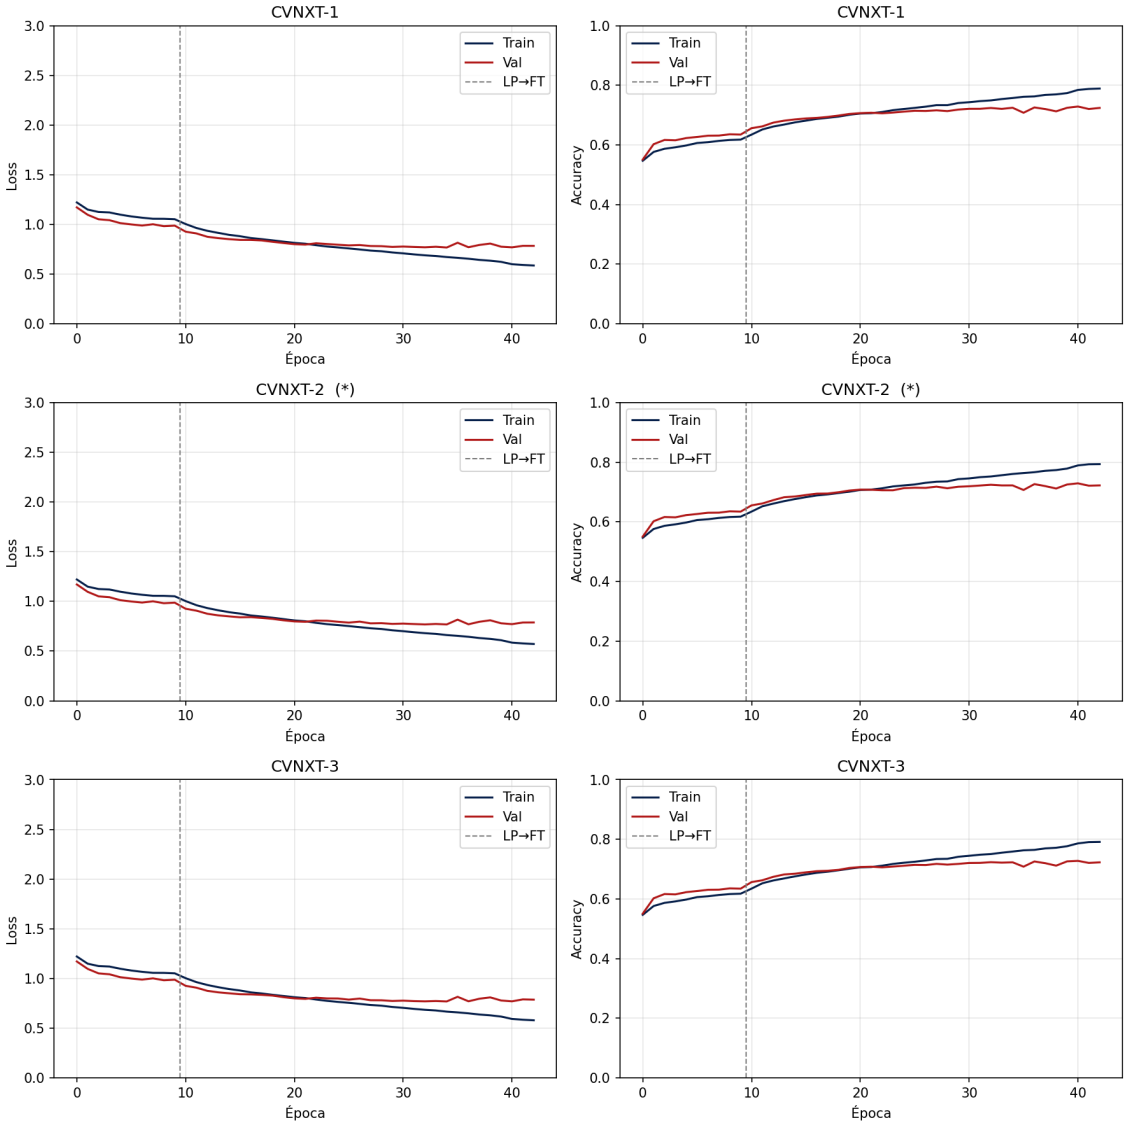

Figura D.1.5: Curvas de entrenamiento de las tres configuraciones candidatas de ConvNeXtTiny sobre el dataset sintético.

D.2 Métricas de desempeño

Se presentan a continuación las métricas de desempeño de las tres configuraciones candidatas evaluadas para cada arquitectura durante la fase de preentrenamiento sobre el conjunto de prueba del dataset sintético. La configuración seleccionada como la de mejor desempeño en cada arquitectura, cuyos resultados se presentan en el cuerpo del informe, se indica con (*).

Tabla D.2.1: Métricas sobre el conjunto de prueba del dataset sintético para las tres configuraciones candidatas de cada arquitectura.

Modelo	**BA**	**Acc**	**Precisión**	**F1**	**F1-NORM**	**F1-CD**	**F1-MI**	**F1-HYP**	**F1-STTC**
CNN-A-1 (*)	**0,7517**	0,7968	0,7658	0,7544	0,8549	0,8096	0,6897	0,6390	0,7790
CNN-A-2	0,6782	0,7611	0,7516	0,6949	0,8277	0,7933	0,6703	0,4805	0,7026
CNN-A-3	0,6928	0,7818	0,7598	0,7184	0,8438	0,8013	0,6314	0,5453	0,7704
CNN-B-1	0,7304	0,8018	0,7807	0,7519	0,8576	0,8199	0,6915	0,6089	0,7815
CNN-B-2 (*)	**0,7644**	0,8066	0,7655	0,7647	0,8566	0,8235	0,7011	0,6474	0,7949
CNN-B-3	0,7239	0,7872	0,7527	0,7344	0,8489	0,8095	0,6789	0,5735	0,7612
RN50-1	0,5927	0,7117	0,6916	0,6220	0,7963	0,6978	0,4258	0,4854	0,7049
RN50-2	0,5748	0,7034	0,6879	0,6069	0,7928	0,6943	0,4375	0,4205	0,6895
RN50-3 (*)	**0,6234**	0,7077	0,6603	0,6383	0,7882	0,7041	0,4893	0,5072	0,7026
EFNB0-1 (*)	**0,6210**	0,7070	0,6699	0,6377	0,7852	0,7023	0,4821	0,5244	0,6943
EFNB0-2	0,6098	0,7057	0,6760	0,6338	0,7847	0,6929	0,4905	0,5067	0,6944
EFNB0-3	0,5987	0,7000	0,6724	0,6255	0,7808	0,6851	0,4761	0,4970	0,6883
CVNXT-1	0,6224	0,7220	0,6738	0,6426	0,8090	0,7167	0,5086	0,4718	0,7070
CVNXT-2 (*)	**0,6253**	0,7224	0,6704	0,6435	0,8101	0,7176	0,5136	0,4684	0,7076
CVNXT-3	0,6233	0,7215	0,6714	0,6424	0,8088	0,7156	0,5101	0,4696	0,7077

D.3 Matrices de confusión

Se presentan a continuación las matrices de confusión normalizadas de las tres configuraciones candidatas evaluadas para cada arquitectura sobre el conjunto de prueba del dataset sintético. Las etiquetas corresponden a las superclases del dataset PTB-XL: NORM (normal), CD (trastornos de conducción), MI (infarto de miocardio), HYP (hipertrofia) y STTC (cambios en el segmento ST y la onda T). La configuración seleccionada como la de mejor desempeño en cada arquitectura, cuyos resultados se presentan en el cuerpo del informe, se indica con (*).

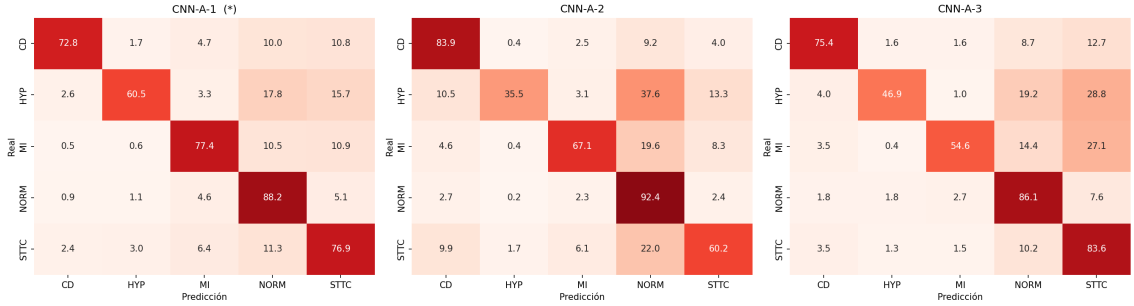

Figura D.3.1: Matrices de confusión normalizadas de las tres configuraciones candidatas de CNN-A sobre el conjunto de prueba del dataset sintético.

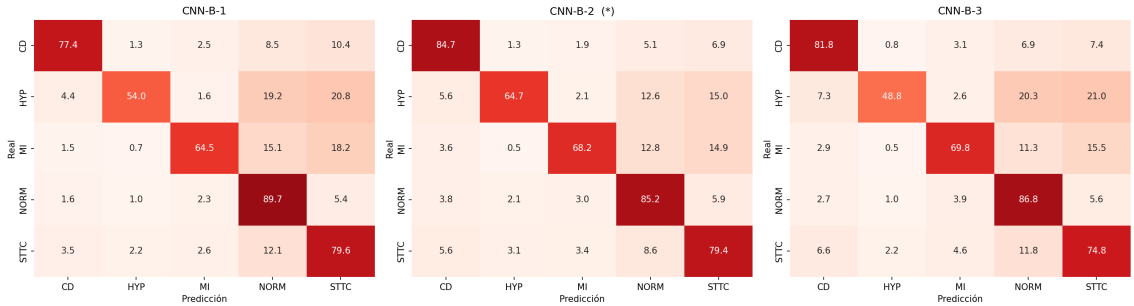

Figura D.3.2: Matrices de confusión normalizadas de las tres configuraciones candidatas de CNN-B sobre el conjunto de prueba del dataset sintético.

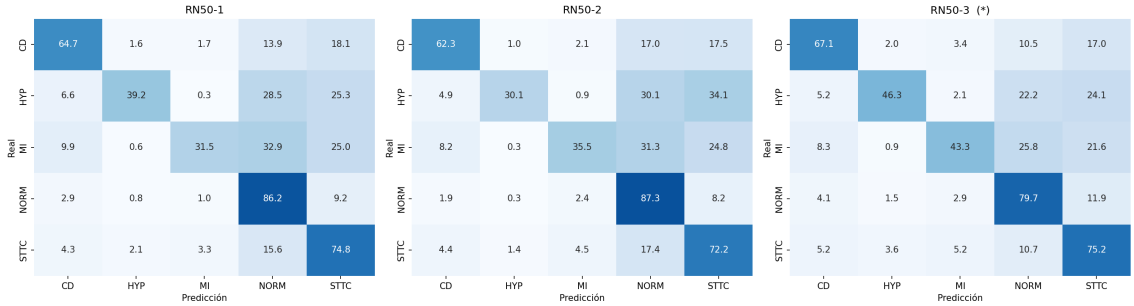

Figura D.3.3: Matrices de confusión normalizadas de las tres configuraciones candidatas de ResNet50 sobre el conjunto de prueba del dataset sintético.

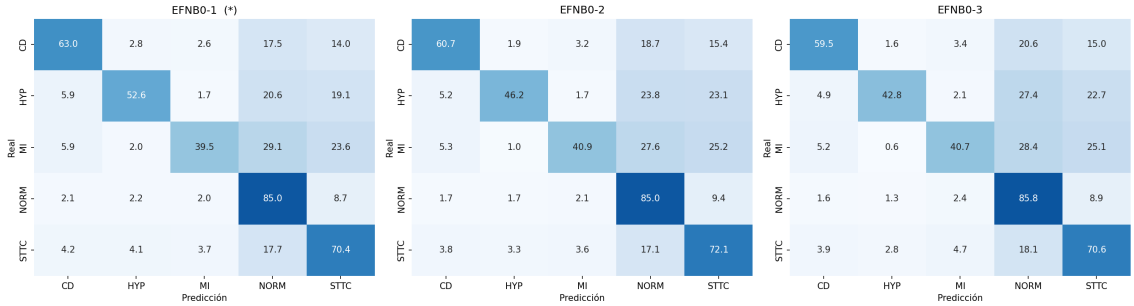

Figura D.3.4: Matrices de confusión normalizadas de las tres configuraciones candidatas de EfficientNetB0 sobre el conjunto de prueba del dataset sintético.

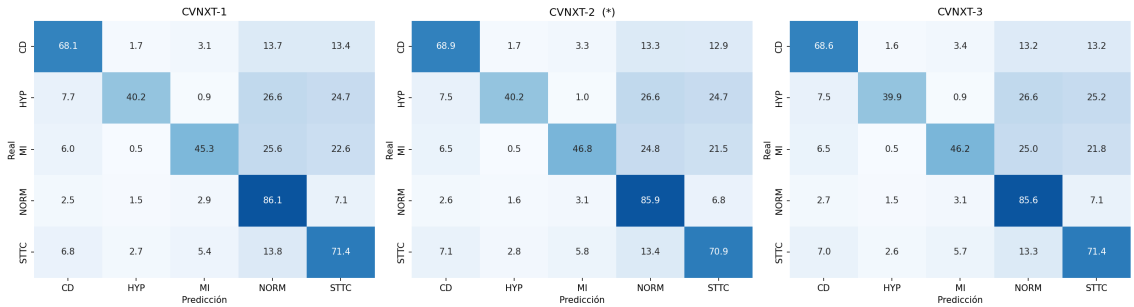

Figura D.3.5: Matrices de confusión normalizadas de las tres configuraciones candidatas de ConvNeXtTiny sobre el conjunto de prueba del dataset sintético.

E Detalle de las predicciones de los modelos finales

Tabla E.1: Probabilidades asignadas a cada clase por CNN-FINAL y CVNXT-FINAL sobre las imágenes del conjunto de prueba del dataset ICBA. En negrita se indica la probabilidad de la clase predicha, con fondo verde si la predicción es correcta y rojo si es incorrecta. En este último caso, se sombrea en gris la probabilidad asignada a la clase real.

		CNN-FINAL				**CVNXT-FINAL**			
Imagen	**Clase real**	Am	HTA	EAo	MCH	Am	HTA	EAo	MCH
Imágenes clasificadas correctamente por ambos modelos (80)									
Am_9	Am	**0,94**	0,01	0,03	0,02	**0,88**	0,12	0,00	0,00
Am_21	Am	**1,00**	0,00	0,00	0,00	**0,99**	0,01	0,00	0,00
Am_22	Am	**0,49**	0,01	0,22	0,29	**0,95**	0,03	0,01	0,01
Am_23	Am	**0,98**	0,00	0,01	0,01	**1,00**	0,00	0,00	0,00
Am_25	Am	**0,98**	0,00	0,01	0,01	**0,98**	0,02	0,00	0,00
Am_35	Am	**0,99**	0,00	0,00	0,00	**1,00**	0,00	0,00	0,00
Am_36	Am	**0,99**	0,00	0,00	0,01	**0,98**	0,02	0,00	0,00
Am_44	Am	**0,49**	0,01	0,22	0,29	**0,96**	0,02	0,01	0,01
Am_53	Am	**0,90**	0,06	0,03	0,01	**0,82**	0,17	0,01	0,00
Am_58	Am	**0,98**	0,00	0,01	0,01	**0,92**	0,07	0,01	0,00
Am_64	Am	**0,99**	0,01	0,00	0,00	**0,97**	0,03	0,00	0,00
Am_66	Am	**0,99**	0,01	0,00	0,00	**0,97**	0,03	0,00	0,00
Am_72	Am	**0,99**	0,00	0,00	0,01	**0,97**	0,02	0,01	0,00
Am_89	Am	**0,99**	0,01	0,00	0,00	**0,97**	0,03	0,00	0,00
Am_96	Am	**0,85**	0,12	0,02	0,01	**0,95**	0,04	0,00	0,00
Am_100	Am	**0,94**	0,04	0,01	0,01	**0,89**	0,11	0,00	0,00
Am_110	Am	**0,85**	0,02	0,05	0,08	**1,00**	0,00	0,00	0,00
Am_111	Am	**0,96**	0,03	0,01	0,01	**0,93**	0,06	0,01	0,00
Am_112	Am	**0,96**	0,01	0,02	0,02	**0,98**	0,02	0,00	0,00
Am_116	Am	**0,99**	0,01	0,00	0,00	**1,00**	0,00	0,00	0,00
Am_121	Am	**0,99**	0,00	0,00	0,00	**0,91**	0,09	0,00	0,00
Am_126	Am	**0,88**	0,05	0,05	0,02	**0,74**	0,22	0,03	0,01
Am_128	Am	**0,99**	0,00	0,00	0,00	**0,98**	0,02	0,00	0,00
Am_131	Am	**1,00**	0,00	0,00	0,00	**1,00**	0,00	0,00	0,00
Am_132	Am	**0,99**	0,01	0,00	0,00	**1,00**	0,00	0,00	0,00
Am_137	Am	**0,99**	0,00	0,00	0,00	**0,91**	0,09	0,00	0,00
Am_147	Am	**0,94**	0,05	0,01	0,00	**0,99**	0,01	0,00	0,00
Am_153	Am	**0,97**	0,01	0,01	0,01	**0,93**	0,07	0,00	0,00
HTA_9	HTA	0,18	**0,56**	0,19	0,07	0,04	**0,95**	0,01	0,00
HTA_18	HTA	0,05	**0,56**	0,27	0,12	0,12	**0,86**	0,01	0,01
HTA_23	HTA	0,11	**0,70**	0,16	0,02	0,23	**0,76**	0,01	0,00
HTA_64	HTA	0,06	**0,58**	0,33	0,03	0,03	**0,96**	0,01	0,00
HTA_73	HTA	0,04	**0,83**	0,11	0,01	0,02	**0,98**	0,00	0,00
HTA_77	HTA	0,16	**0,69**	0,14	0,01	0,08	**0,89**	0,03	0,00
HTA_111	HTA	0,01	**0,65**	0,32	0,03	0,04	**0,88**	0,08	0,00
HTA_117	HTA	0,12	**0,76**	0,10	0,02	0,22	**0,73**	0,04	0,01
HTA_119	HTA	0,35	**0,52**	0,11	0,02	0,14	**0,83**	0,03	0,01
HTA_124	HTA	0,15	**0,56**	0,22	0,06	0,32	**0,64**	0,03	0,01
HTA_125	HTA	0,22	**0,62**	0,13	0,03	0,08	**0,82**	0,09	0,01
HTA_134	HTA	0,06	**0,68**	0,21	0,05	0,31	**0,66**	0,03	0,00
HTA_159	HTA	0,08	**0,46**	0,42	0,04	0,03	**0,66**	0,30	0,01
HTA_168	HTA	0,02	**0,68**	0,26	0,03	0,05	**0,80**	0,14	0,02
HTA_171	HTA	0,12	**0,69**	0,16	0,03	0,07	**0,86**	0,07	0,00
EAo_3	EAo	0,06	0,05	**0,61**	0,28	0,00	0,00	**0,58**	0,42
EAo_10	EAo	0,03	0,05	**0,65**	0,27	0,00	0,00	**0,50**	0,49
EAo_27	EAo	0,06	0,07	**0,73**	0,14	0,01	0,06	**0,79**	0,14
EAo_29	EAo	0,09	0,09	**0,68**	0,13	0,00	0,02	**0,73**	0,25

		CNN-FINAL				CVNXT-FINAL			
Imagen	**Clase real**	Am	HTA	EAo	MCH	Am	HTA	EAo	MCH
EAo_35	EAo	0,01	0,01	**0,71**	0,28	0,00	0,00	**0,58**	0,42
EAo_40	EAo	0,09	0,06	**0,69**	0,16	0,00	0,00	**0,71**	0,29
EAo_41	EAo	0,02	0,04	**0,85**	0,10	0,00	0,00	**0,79**	0,21
EAo_44	EAo	0,05	0,05	**0,64**	0,26	0,01	0,01	**0,85**	0,13
EAo_50	EAo	0,02	0,04	**0,62**	0,32	0,00	0,01	**0,54**	0,45
EAo_52	EAo	0,07	0,06	**0,73**	0,13	0,01	0,04	**0,79**	0,16
EAo_54	EAo	0,02	0,02	**0,68**	0,27	0,00	0,01	**0,83**	0,16
EAo_58	EAo	0,02	0,03	**0,78**	0,17	0,00	0,00	**0,81**	0,18
EAo_60	EAo	0,02	0,05	**0,55**	0,37	0,01	0,04	**0,72**	0,24
EAo_62	EAo	0,01	0,07	**0,74**	0,18	0,00	0,00	**0,73**	0,26
EAo_67	EAo	0,01	0,00	**0,83**	0,16	0,00	0,00	**0,80**	0,19
EAo_74	EAo	0,06	0,05	**0,64**	0,25	0,00	0,00	**0,60**	0,40
EAo_89	EAo	0,23	0,02	**0,43**	0,32	0,00	0,01	**0,56**	0,43
EAo_97	EAo	0,01	0,01	**0,62**	0,36	0,00	0,00	**0,79**	0,21
EAo_99	EAo	0,01	0,07	**0,75**	0,17	0,00	0,00	**0,74**	0,26
EAo_113	EAo	0,07	0,21	**0,63**	0,10	0,24	0,30	**0,40**	0,06
EAo_114	EAo	0,12	0,18	**0,58**	0,13	0,05	0,26	**0,65**	0,05
EAo_126	EAo	0,07	0,14	**0,66**	0,12	0,01	0,13	**0,81**	0,05
EAo_131	EAo	0,09	0,05	**0,64**	0,22	0,01	0,01	**0,84**	0,15
EAo_159	EAo	0,06	0,09	**0,70**	0,15	0,03	0,06	**0,72**	0,19
EAo_165	EAo	0,20	0,24	**0,41**	0,15	0,09	0,28	**0,58**	0,05
EAo_189	EAo	0,19	0,06	**0,50**	0,26	0,09	0,25	**0,59**	0,07
MCH_12	MCH	0,04	0,01	0,45	**0,49**	0,00	0,00	0,32	**0,68**
MCH_20	MCH	0,13	0,00	0,30	**0,57**	0,00	0,00	0,49	**0,51**
MCH_25	MCH	0,03	0,00	0,33	**0,64**	0,00	0,00	0,08	**0,92**
MCH_27	MCH	0,00	0,00	0,30	**0,69**	0,00	0,00	0,09	**0,91**
MCH_31	MCH	0,31	0,00	0,12	**0,57**	0,00	0,00	0,21	**0,78**
MCH_47	MCH	0,02	0,01	0,45	**0,52**	0,00	0,00	0,22	**0,78**
MCH_65	MCH	0,14	0,02	0,35	**0,49**	0,00	0,00	0,18	**0,81**
MCH_66	MCH	0,02	0,00	0,07	**0,91**	0,00	0,00	0,25	**0,75**
MCH_77	MCH	0,20	0,00	0,17	**0,63**	0,00	0,01	0,15	**0,84**
MCH_100	MCH	0,06	0,00	0,06	**0,88**	0,00	0,00	0,08	**0,92**
MCH_109	MCH	0,04	0,02	0,31	**0,64**	0,02	0,01	0,47	**0,50**
Imágenes clasificadas correctamente solo por CNN-FINAL (14)									
Am_51	Am	**0,86**	0,10	0,03	0,01	0,20	0,29	**0,44**	0,06
Am_94	Am	**0,97**	0,01	0,01	0,01	0,30	**0,65**	0,04	0,01
Am_101	Am	**0,86**	0,10	0,03	0,01	0,21	0,28	**0,45**	0,06
Am_103	Am	**0,56**	0,21	0,19	0,04	0,13	**0,84**	0,03	0,00
Am_159	Am	**0,88**	0,03	0,06	0,03	0,01	0,04	**0,91**	0,03
Am_161	Am	**0,94**	0,01	0,03	0,02	0,24	0,19	**0,48**	0,09
Am_170	Am	**0,35**	0,05	0,27	0,33	0,38	**0,55**	0,07	0,01
HTA_5	HTA	0,03	**0,91**	0,05	0,01	0,08	0,19	0,15	**0,58**
HTA_25	HTA	0,32	**0,48**	0,19	0,01	**0,75**	0,25	0,00	0,00
EAo_22	EAo	0,14	0,20	**0,35**	0,30	0,00	0,00	0,36	**0,64**
EAo_75	EAo	0,01	0,01	**0,56**	0,42	0,00	0,00	0,47	**0,53**
EAo_87	EAo	0,00	0,04	**0,52**	0,45	0,00	0,00	0,47	**0,53**
EAo_174	EAo	0,20	0,27	**0,46**	0,06	0,20	**0,44**	0,31	0,05
MCH_40	MCH	0,03	0,00	0,21	**0,76**	0,00	0,01	**0,58**	0,41
Imágenes clasificadas correctamente solo por CVNXT-FINAL (21)									
HTA_13	HTA	**0,69**	0,16	0,10	0,05	0,44	**0,56**	0,00	0,00
HTA_17	HTA	**0,49**	0,45	0,04	0,02	0,10	**0,90**	0,00	0,00
HTA_19	HTA	0,17	0,19	**0,52**	0,12	0,18	**0,71**	0,07	0,04
HTA_21	HTA	0,19	0,24	**0,51**	0,06	0,23	**0,75**	0,02	0,00
HTA_26	HTA	**0,74**	0,11	0,09	0,06	0,19	**0,81**	0,00	0,00
HTA_27	HTA	**0,44**	0,42	0,11	0,03	0,05	**0,94**	0,01	0,00
HTA_28	HTA	0,26	0,07	**0,49**	0,19	0,23	**0,76**	0,01	0,00
HTA_31	HTA	**0,84**	0,13	0,03	0,01	0,14	**0,84**	0,02	0,01

		CNN-FINAL				CVNXT-FINAL			
Imagen	**Clase real**	Am	HTA	EAo	MCH	Am	HTA	EAo	MCH
HTA_83	HTA	**0,47**	0,29	0,19	0,05	0,10	**0,89**	0,01	0,00
HTA_89	HTA	**0,72**	0,22	0,05	0,01	0,23	**0,76**	0,00	0,00
HTA_136	HTA	0,05	0,44	**0,44**	0,07	0,05	**0,69**	0,24	0,01
HTA_139	HTA	0,15	0,31	**0,39**	0,15	0,27	**0,40**	0,31	0,03
EAo_15	EAo	0,06	0,01	0,41	**0,52**	0,00	0,01	**0,64**	0,35
EAo_138	EAo	**0,81**	0,04	0,11	0,04	0,11	0,25	**0,62**	0,02
EAo_154	EAo	**0,37**	0,18	0,37	0,08	0,20	0,37	**0,41**	0,02
MCH_5	MCH	0,01	0,01	**0,50**	0,48	0,00	0,00	0,36	**0,63**
MCH_16	MCH	0,02	0,01	**0,57**	0,40	0,00	0,00	0,24	**0,76**
MCH_55	MCH	0,01	0,02	**0,51**	0,45	0,00	0,00	0,37	**0,63**
MCH_68	MCH	0,00	0,00	**0,62**	0,37	0,00	0,00	0,39	**0,61**
MCH_86	MCH	0,03	0,00	**0,51**	0,46	0,00	0,00	0,46	**0,54**
MCH_103	MCH	0,22	0,07	**0,44**	0,27	0,07	0,04	0,31	**0,58**
Imágenes clasificadas incorrectamente por ambos modelos (22)									
Am_157	Am	0,32	**0,33**	0,27	0,08	0,10	**0,66**	0,22	0,02
Am_165	Am	0,27	0,01	**0,41**	0,31	0,04	0,03	**0,80**	0,13
HTA_3	HTA	**0,85**	0,00	0,06	0,09	**0,98**	0,02	0,00	0,00
HTA_20	HTA	**0,91**	0,08	0,01	0,00	**0,96**	0,04	0,00	0,00
HTA_35	HTA	**0,97**	0,02	0,00	0,00	**0,93**	0,07	0,00	0,00
HTA_92	HTA	**0,60**	0,30	0,08	0,02	**0,80**	0,19	0,01	0,00
HTA_95	HTA	**0,83**	0,05	0,08	0,04	**0,89**	0,11	0,00	0,00
HTA_147	HTA	0,13	0,12	**0,59**	0,16	0,06	0,06	**0,66**	0,23
HTA_169	HTA	0,06	0,25	**0,49**	0,20	0,15	0,28	**0,51**	0,06
EAo_112	EAo	0,32	**0,39**	0,25	0,04	0,03	**0,64**	0,32	0,02
EAo_144	EAo	0,09	**0,56**	0,30	0,05	0,02	**0,51**	0,45	0,02
EAo_150	EAo	**0,90**	0,04	0,04	0,02	**0,48**	0,30	0,19	0,03
EAo_155	EAo	0,12	**0,63**	0,22	0,03	0,29	**0,70**	0,01	0,00
EAo_171	EAo	**0,45**	0,19	0,28	0,08	0,17	**0,52**	0,29	0,01
MCH_29	MCH	0,04	0,03	**0,54**	0,39	0,04	0,07	**0,59**	0,30
MCH_79	MCH	**0,41**	0,03	0,23	0,33	0,01	0,03	**0,79**	0,17
MCH_89	MCH	0,13	0,01	**0,43**	0,43	0,00	0,01	**0,72**	0,27
MCH_105	MCH	0,08	0,36	**0,49**	0,08	0,03	**0,86**	0,08	0,03
MCH_113	MCH	0,32	**0,33**	0,25	0,10	0,09	**0,91**	0,01	0,00
MCH_121	MCH	0,36	0,08	**0,41**	0,15	0,04	0,06	**0,71**	0,19
MCH_123	MCH	**0,58**	0,25	0,14	0,03	0,07	**0,53**	0,28	0,12
MCH_128	MCH	**0,43**	0,11	0,32	0,14	0,15	**0,38**	0,35	0,12

Tabla E.2: Predicciones de CNN-FINAL, CVNXT-FINAL y del ensamble sobre las imágenes del conjunto de prueba del dataset ICBA. La clase predicha se indica en **verde** si es correcta y en **rojo** si es incorrecta, junto con la probabilidad asignada entre paréntesis.

Imagen	Clase real	CNN-FINAL	CVNXT-FINAL	Ensamble
Imágenes clasificadas correctamente por ambos modelos (80)				
Am_9	Am	**Am** (0,94)	**Am** (0,88)	**Am** (0,90)
Am_21	Am	**Am** (1,00)	**Am** (0,99)	**Am** (0,99)
Am_22	Am	**Am** (0,49)	**Am** (0,95)	**Am** (0,77)
Am_23	Am	**Am** (0,98)	**Am** (1,00)	**Am** (0,99)
Am_25	Am	**Am** (0,98)	**Am** (0,98)	**Am** (0,98)
Am_35	Am	**Am** (0,99)	**Am** (1,00)	**Am** (1,00)
Am_36	Am	**Am** (0,99)	**Am** (0,98)	**Am** (0,98)
Am_44	Am	**Am** (0,49)	**Am** (0,96)	**Am** (0,77)
Am_53	Am	**Am** (0,90)	**Am** (0,82)	**Am** (0,85)
Am_58	Am	**Am** (0,98)	**Am** (0,92)	**Am** (0,94)
Am_64	Am	**Am** (0,99)	**Am** (0,97)	**Am** (0,98)
Am_66	Am	**Am** (0,99)	**Am** (0,97)	**Am** (0,98)
Am_72	Am	**Am** (0,99)	**Am** (0,97)	**Am** (0,98)
Am_89	Am	**Am** (0,99)	**Am** (0,97)	**Am** (0,98)
Am_96	Am	**Am** (0,85)	**Am** (0,95)	**Am** (0,91)
Am_100	Am	**Am** (0,94)	**Am** (0,89)	**Am** (0,91)
Am_110	Am	**Am** (0,85)	**Am** (1,00)	**Am** (0,94)
Am_111	Am	**Am** (0,96)	**Am** (0,93)	**Am** (0,94)
Am_112	Am	**Am** (0,96)	**Am** (0,98)	**Am** (0,97)
Am_116	Am	**Am** (0,99)	**Am** (1,00)	**Am** (1,00)
Am_121	Am	**Am** (0,99)	**Am** (0,91)	**Am** (0,94)
Am_126	Am	**Am** (0,88)	**Am** (0,74)	**Am** (0,79)
Am_128	Am	**Am** (0,99)	**Am** (0,98)	**Am** (0,98)
Am_131	Am	**Am** (1,00)	**Am** (1,00)	**Am** (1,00)
Am_132	Am	**Am** (0,99)	**Am** (1,00)	**Am** (1,00)
Am_137	Am	**Am** (0,99)	**Am** (0,91)	**Am** (0,94)
Am_147	Am	**Am** (0,94)	**Am** (0,99)	**Am** (0,97)
Am_153	Am	**Am** (0,97)	**Am** (0,93)	**Am** (0,95)
HTA_9	HTA	**HTA** (0,56)	**HTA** (0,95)	**HTA** (0,79)
HTA_18	HTA	**HTA** (0,56)	**HTA** (0,86)	**HTA** (0,74)
HTA_23	HTA	**HTA** (0,70)	**HTA** (0,76)	**HTA** (0,73)
HTA_64	HTA	**HTA** (0,58)	**HTA** (0,96)	**HTA** (0,81)
HTA_73	HTA	**HTA** (0,83)	**HTA** (0,98)	**HTA** (0,92)
HTA_77	HTA	**HTA** (0,69)	**HTA** (0,89)	**HTA** (0,81)
HTA_111	HTA	**HTA** (0,65)	**HTA** (0,88)	**HTA** (0,78)
HTA_117	HTA	**HTA** (0,76)	**HTA** (0,73)	**HTA** (0,74)
HTA_119	HTA	**HTA** (0,52)	**HTA** (0,83)	**HTA** (0,71)
HTA_124	HTA	**HTA** (0,56)	**HTA** (0,64)	**HTA** (0,61)
HTA_125	HTA	**HTA** (0,62)	**HTA** (0,82)	**HTA** (0,74)
HTA_134	HTA	**HTA** (0,68)	**HTA** (0,66)	**HTA** (0,67)
HTA_159	HTA	**HTA** (0,46)	**HTA** (0,66)	**HTA** (0,58)
HTA_168	HTA	**HTA** (0,68)	**HTA** (0,80)	**HTA** (0,75)
HTA_171	HTA	**HTA** (0,69)	**HTA** (0,86)	**HTA** (0,79)
EAo_3	EAo	**EAo** (0,61)	**EAo** (0,58)	**EAo** (0,59)
EAo_10	EAo	**EAo** (0,65)	**EAo** (0,50)	**EAo** (0,56)
EAo_27	EAo	**EAo** (0,73)	**EAo** (0,79)	**EAo** (0,76)
EAo_29	EAo	**EAo** (0,68)	**EAo** (0,73)	**EAo** (0,71)
EAo_35	EAo	**EAo** (0,71)	**EAo** (0,58)	**EAo** (0,63)
EAo_40	EAo	**EAo** (0,69)	**EAo** (0,71)	**EAo** (0,70)
EAo_41	EAo	**EAo** (0,85)	**EAo** (0,79)	**EAo** (0,81)
EAo_44	EAo	**EAo** (0,64)	**EAo** (0,85)	**EAo** (0,76)
EAo_50	EAo	**EAo** (0,62)	**EAo** (0,54)	**EAo** (0,57)
EAo_52	EAo	**EAo** (0,73)	**EAo** (0,79)	**EAo** (0,77)
EAo_54	EAo	**EAo** (0,68)	**EAo** (0,83)	**EAo** (0,77)

Imagen	Clase real	CNN-FINAL	CVNXT-FINAL	Ensamble
EAo_58	EAo	**EAo** (0,78)	**EAo** (0,81)	**EAo** (0,80)
EAo_60	EAo	**EAo** (0,55)	**EAo** (0,72)	**EAo** (0,65)
EAo_62	EAo	**EAo** (0,74)	**EAo** (0,73)	**EAo** (0,73)
EAo_67	EAo	**EAo** (0,83)	**EAo** (0,80)	**EAo** (0,81)
EAo_74	EAo	**EAo** (0,64)	**EAo** (0,60)	**EAo** (0,61)
EAo_89	EAo	**EAo** (0,43)	**EAo** (0,56)	**EAo** (0,51)
EAo_97	EAo	**EAo** (0,62)	**EAo** (0,79)	**EAo** (0,72)
EAo_99	EAo	**EAo** (0,75)	**EAo** (0,74)	**EAo** (0,74)
EAo_113	EAo	**EAo** (0,63)	**EAo** (0,40)	**EAo** (0,49)
EAo_114	EAo	**EAo** (0,58)	**EAo** (0,65)	**EAo** (0,62)
EAo_126	EAo	**EAo** (0,66)	**EAo** (0,81)	**EAo** (0,75)
EAo_131	EAo	**EAo** (0,64)	**EAo** (0,84)	**EAo** (0,76)
EAo_159	EAo	**EAo** (0,70)	**EAo** (0,72)	**EAo** (0,72)
EAo_165	EAo	**EAo** (0,41)	**EAo** (0,58)	**EAo** (0,51)
EAo_189	EAo	**EAo** (0,50)	**EAo** (0,59)	**EAo** (0,55)
MCH_12	MCH	**MCH** (0,49)	**MCH** (0,68)	**MCH** (0,60)
MCH_20	MCH	**MCH** (0,57)	**MCH** (0,51)	**MCH** (0,53)
MCH_25	MCH	**MCH** (0,64)	**MCH** (0,92)	**MCH** (0,81)
MCH_27	MCH	**MCH** (0,69)	**MCH** (0,91)	**MCH** (0,83)
MCH_31	MCH	**MCH** (0,57)	**MCH** (0,78)	**MCH** (0,70)
MCH_47	MCH	**MCH** (0,52)	**MCH** (0,78)	**MCH** (0,68)
MCH_65	MCH	**MCH** (0,49)	**MCH** (0,81)	**MCH** (0,68)
MCH_66	MCH	**MCH** (0,91)	**MCH** (0,75)	**MCH** (0,81)
MCH_77	MCH	**MCH** (0,63)	**MCH** (0,84)	**MCH** (0,76)
MCH_100	MCH	**MCH** (0,88)	**MCH** (0,92)	**MCH** (0,91)
MCH_109	MCH	**MCH** (0,64)	**MCH** (0,50)	**MCH** (0,56)
Imágenes clasificadas correctamente solo por CNN-FINAL (14)				
Am_51	Am	**Am** (0,86)	**EAo** (0,44)	**Am** (0,47)
Am_94	Am	**Am** (0,97)	**HTA** (0,65)	**Am** (0,57)
Am_101	Am	**Am** (0,86)	**EAo** (0,45)	**Am** (0,47)
Am_103	Am	**Am** (0,56)	**HTA** (0,84)	**HTA** (0,59)
Am_159	Am	**Am** (0,88)	**EAo** (0,91)	**EAo** (0,57)
Am_161	Am	**Am** (0,94)	**EAo** (0,48)	**Am** (0,52)
Am_170	Am	**Am** (0,35)	**HTA** (0,55)	**Am** (0,37)
HTA_5	HTA	**HTA** (0,91)	**MCH** (0,58)	**HTA** (0,48)
HTA_25	HTA	**HTA** (0,48)	**Am** (0,75)	**Am** (0,58)
EAo_22	EAo	**EAo** (0,35)	**MCH** (0,64)	**MCH** (0,50)
EAo_75	EAo	**EAo** (0,56)	**MCH** (0,53)	**EAo** (0,50)
EAo_87	EAo	**EAo** (0,52)	**MCH** (0,53)	**MCH** (0,50)
EAo_174	EAo	**EAo** (0,46)	**HTA** (0,44)	**HTA** (0,37)
MCH_40	MCH	**MCH** (0,76)	**EAo** (0,58)	**MCH** (0,55)
Imágenes clasificadas correctamente solo por CVNXT-FINAL (21)				
HTA_13	HTA	**Am** (0,69)	**HTA** (0,56)	**Am** (0,54)
HTA_17	HTA	**Am** (0,49)	**HTA** (0,90)	**HTA** (0,72)
HTA_19	HTA	**EAo** (0,52)	**HTA** (0,71)	**HTA** (0,51)
HTA_21	HTA	**EAo** (0,51)	**HTA** (0,75)	**HTA** (0,54)
HTA_26	HTA	**Am** (0,74)	**HTA** (0,81)	**HTA** (0,53)
HTA_27	HTA	**Am** (0,44)	**HTA** (0,94)	**HTA** (0,73)
HTA_28	HTA	**EAo** (0,49)	**HTA** (0,76)	**HTA** (0,48)
HTA_31	HTA	**Am** (0,84)	**HTA** (0,84)	**HTA** (0,56)
HTA_83	HTA	**Am** (0,47)	**HTA** (0,89)	**HTA** (0,65)
HTA_89	HTA	**Am** (0,72)	**HTA** (0,76)	**HTA** (0,55)
HTA_136	HTA	**EAo** (0,44)	**HTA** (0,69)	**HTA** (0,59)
HTA_139	HTA	**EAo** (0,39)	**HTA** (0,40)	**HTA** (0,36)
EAo_15	EAo	**MCH** (0,52)	**EAo** (0,64)	**EAo** (0,55)
EAo_138	EAo	**Am** (0,81)	**EAo** (0,62)	**EAo** (0,42)
EAo_154	EAo	**Am** (0,37)	**EAo** (0,41)	**EAo** (0,39)
MCH_5	MCH	**EAo** (0,50)	**MCH** (0,63)	**MCH** (0,57)

Imagen	Clase real	CNN-FINAL	CVNXT-FINAL	Ensamble
MCH_16	MCH	**EAo** (0,57)	**MCH** (0,76)	**MCH** (0,62)
MCH_55	MCH	**EAo** (0,51)	**MCH** (0,63)	**MCH** (0,56)
MCH_68	MCH	**EAo** (0,62)	**MCH** (0,61)	**MCH** (0,52)
MCH_86	MCH	**EAo** (0,51)	**MCH** (0,54)	**MCH** (0,51)
MCH_103	MCH	**EAo** (0,44)	**MCH** (0,58)	**MCH** (0,46)
Imágenes clasificadas incorrectamente por ambos modelos (22)				
Am_157	Am	**HTA** (0,33)	**HTA** (0,66)	**HTA** (0,53)
Am_165	Am	**EAo** (0,41)	**EAo** (0,80)	**EAo** (0,64)
HTA_3	HTA	**Am** (0,85)	**Am** (0,98)	**Am** (0,92)
HTA_20	HTA	**Am** (0,91)	**Am** (0,96)	**Am** (0,94)
HTA_35	HTA	**Am** (0,97)	**Am** (0,93)	**Am** (0,95)
HTA_92	HTA	**Am** (0,60)	**Am** (0,80)	**Am** (0,72)
HTA_95	HTA	**Am** (0,83)	**Am** (0,89)	**Am** (0,87)
HTA_147	HTA	**EAo** (0,59)	**EAo** (0,66)	**EAo** (0,63)
HTA_169	HTA	**EAo** (0,49)	**EAo** (0,51)	**EAo** (0,50)
EAo_112	EAo	**HTA** (0,39)	**HTA** (0,64)	**HTA** (0,54)
EAo_144	EAo	**HTA** (0,56)	**HTA** (0,51)	**HTA** (0,53)
EAo_150	EAo	**Am** (0,90)	**Am** (0,48)	**Am** (0,65)
EAo_155	EAo	**HTA** (0,63)	**HTA** (0,70)	**HTA** (0,67)
EAo_171	EAo	**Am** (0,45)	**HTA** (0,52)	**HTA** (0,39)
MCH_29	MCH	**EAo** (0,54)	**EAo** (0,59)	**EAo** (0,57)
MCH_79	MCH	**Am** (0,41)	**EAo** (0,79)	**EAo** (0,56)
MCH_89	MCH	**EAo** (0,43)	**EAo** (0,72)	**EAo** (0,61)
MCH_105	MCH	**EAo** (0,49)	**HTA** (0,86)	**HTA** (0,66)
MCH_113	MCH	**HTA** (0,33)	**HTA** (0,91)	**HTA** (0,68)
MCH_121	MCH	**EAo** (0,41)	**EAo** (0,71)	**EAo** (0,59)
MCH_123	MCH	**Am** (0,58)	**HTA** (0,53)	**HTA** (0,42)
MCH_128	MCH	**Am** (0,43)	**HTA** (0,38)	**EAo** (0,34)

F Mapas de activación Grad-CAM

A continuación se presentan ejemplos adicionales de mapas de activación Grad-CAM del ensamble CNN-CVNXT sobre imágenes correctamente clasificadas del conjunto de prueba del dataset ICBA, complementarios a los presentados en la Figura 29. Las Figuras F.1 a F.4 presentan cuatro ejemplos para cada una de las clases consideradas.

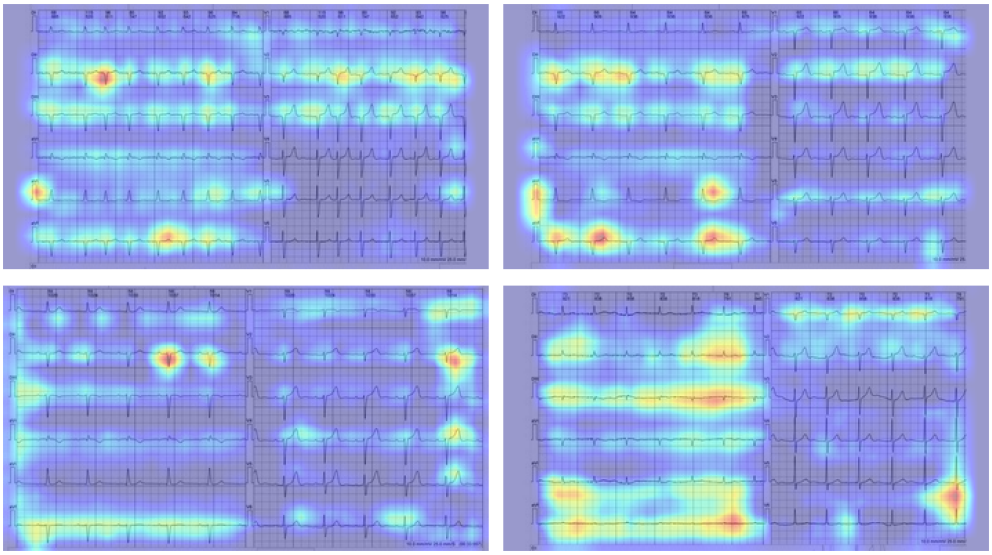

Figura F.1: Mapas de activación Grad-CAM del ensamble sobre imágenes de Am correctamente clasificadas.

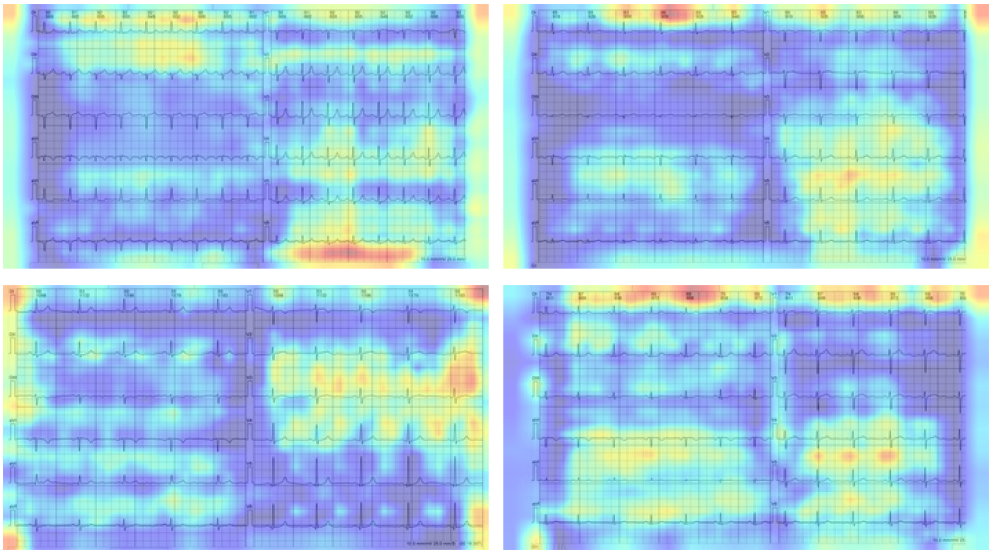

Figura F.2: Mapas de activación Grad-CAM del ensamble sobre imágenes de HTA correctamente clasificadas.

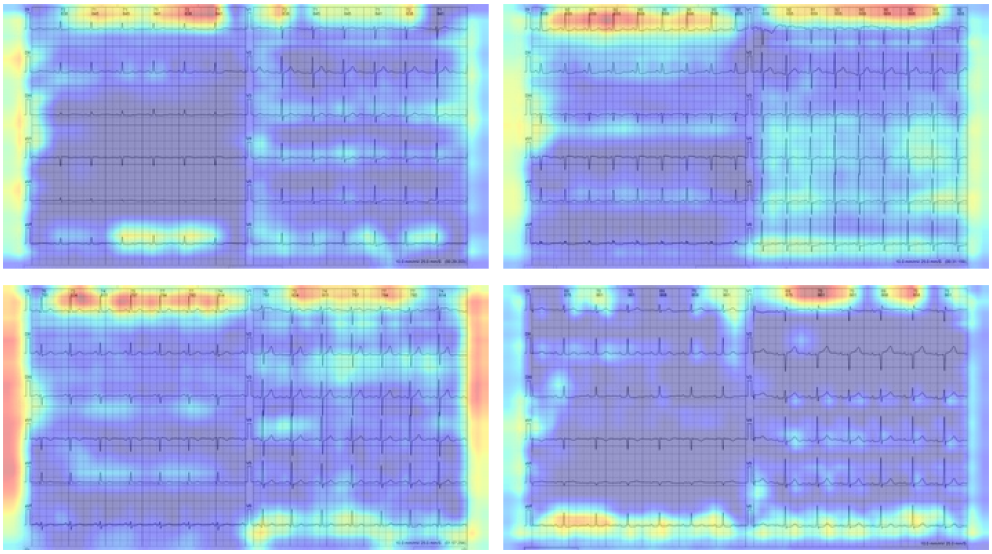

Figura F.3: Mapas de activación Grad-CAM del ensamble sobre imágenes de EAo correctamente clasificadas.

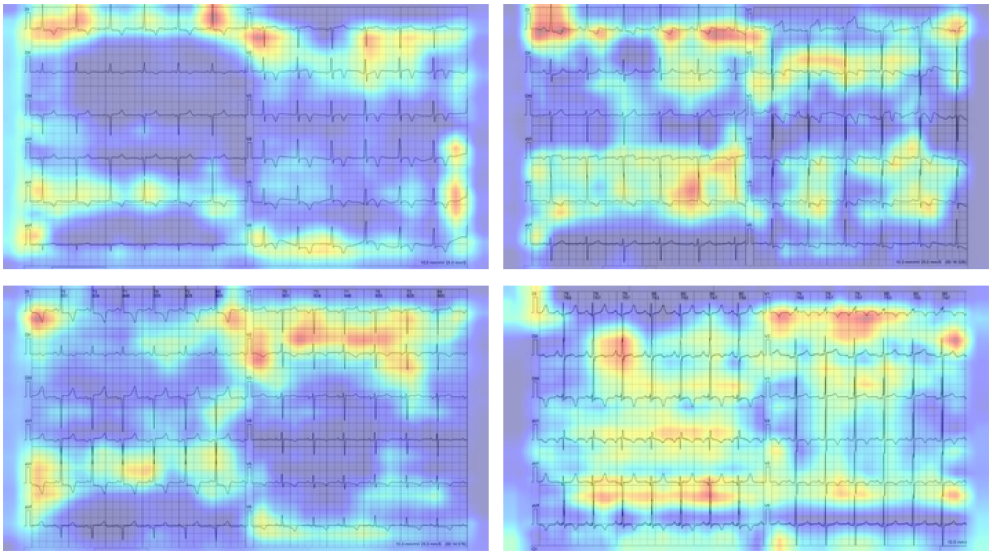

Figura F.4: Mapas de activación Grad-CAM del ensamble sobre imágenes de MCH correctamente clasificadas.